

TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO TIỂU LUẬN
MÔN PHÂN TÍCH DỮ LIỆU

ĐỀ TÀI

RÚT TRÍCH DỮ LIỆU VÀ TIỀN XỬ LÝ
DỮ LIỆU PIMA INDIANS DIABETES

Giảng viên hướng dẫn:

Nhóm thực hiện: Nhom01_SGU26_ML

Học phần: Học phần thay thế khóa luận

Phân công thành viên

Thành viên	Nhiệm vụ chính	Tỷ lệ
Chibang	Tổng hợp notebook, xây dựng pipeline tiền xử lý, tổng hợp báo cáo	25%
Duybao	Hỗ trợ kiểm tra notebook, đối chiếu kết quả và markdown diễn giải	25%
Tranhuyvu	Phân tích sâu cho nhóm biến BMI/Insulin, góp ý trực quan hóa	25%
Truongphat	Phân tích sâu cho nhóm biến Age/DPF, góp ý diễn giải kết quả	25%

Nhận xét của giảng viên

Lời mở đầu

Báo cáo này trình bày kết quả thực hiện bài tập Lab 03 với dữ liệu Pima Indians Diabetes. Nhóm tập trung vào hai mục tiêu: (1) xây dựng quy trình rút trích và tiền xử lý dữ liệu có thể tái lập; (2) đánh giá các chiến lược tiền xử lý dưới góc nhìn mô hình học máy baseline.

Lời cảm ơn

Nhóm xin chân thành cảm ơn giảng viên hướng dẫn đã cung cấp yêu cầu, tài liệu tham khảo và những góp ý quan trọng để nhóm hoàn thiện notebook và báo cáo.

Mục lục

Phân công thành viên	1
Nhận xét của giảng viên	2
Lời mở đầu	3
Lời cảm ơn	4
1 Tổng quan vấn đề	10
1.1 Lý do chọn đề tài	10
1.2 Mục tiêu nghiên cứu	11
1.3 Câu hỏi nghiên cứu	12
1.4 Đối tượng và phạm vi	12
1.5 Phương pháp tổng quát	13
1.6 Kết cấu báo cáo	14
2 Cơ sở lý thuyết và nghiên cứu liên quan	15
2.1 Tổng quan bài toán phân lớp trong dự đoán nguy cơ tái phát đường . .	15
2.2 Phân tích khám phá dữ liệu (EDA)	15
2.3 Cơ sở lý thuyết tiền xử lý dữ liệu	16
2.3.1 Missing ửn và chính sách <i>zero-as-missing</i>	16
2.3.2 Các chiến lược nội suy thiếu dữ liệu	16
2.3.3 Chuẩn hóa đặc trưng	17
2.4 Mô hình học máy baseline	17
2.4.1 Logistic Regression	17
2.4.2 Random Forest	18

2.5	Chỉ số đánh giá mô hình phân lớp	18
2.6	Nghiên cứu liên quan	19
3	Dữ liệu và phương pháp đề xuất	20
3.1	Nguồn dữ liệu	20
3.2	Mô tả thuộc tính	20
3.3	Kiểm tra chất lượng dữ liệu	21
3.4	Thiết kế thực nghiệm và tái lập	22
3.4.1	Không gian cấu hình thực nghiệm	23
3.4.2	Nguyên tắc tái lập	23
3.4.3	Code mô tả quy trình dữ liệu	24
3.5	EDA chuyên sâu theo nhóm biến	25
3.6	Quy trình tiền xử lý đề xuất	27
3.6.1	Luồng xử lý kỹ thuật	29
3.6.2	Ưu tiên biến cho diễn giải	29
4	Thực nghiệm và kết quả đạt được	30
4.1	Giới thiệu chương	30
4.2	Thiết lập thực nghiệm	30
4.2.1	Chiến lược chia dữ liệu	30
4.2.2	Tổ hợp cấu hình được so sánh	30
4.3	Kết quả EDA chính	31
4.3.1	Tổng quan bộ dữ liệu	31
4.3.2	Nhận xét về quality data	32
4.4	So sánh mô hình và chiến lược tiền xử lý	32
4.4.1	Bảng tổng hợp đầy đủ 12 cấu hình	32
4.4.2	Xếp hạng theo ROC-AUC và F1	34
4.4.3	Cấu hình đề xuất	35
4.4.4	So sánh theo họ mô hình (Logistic vs Random Forest)	35
4.5	Phân tích sai số và trade-off	36
4.5.1	Confusion matrix và ROC	36
4.5.2	Trade-off theo threshold	37

4.5.3	Nhận định overfitting/underfitting	39
4.6	Kết luận chương	39
5	Kết luận và khuyến nghị	40
5.1	Kết luận chung	40
5.2	Tóm tắt kết quả đạt được	40
5.3	Trả lời trực tiếp câu hỏi nghiên cứu (Q1/Q2/Q3)	41
5.4	Đóng góp của đề tài	41
5.5	Hạn chế nghiên cứu	42
5.6	Hướng phát triển và kiến nghị	42
5.6.1	Ngắn hạn (1–3 tháng)	42
5.6.2	Trung hạn (3–6 tháng)	43
5.6.3	Dài hạn (trên 6 tháng)	43

Danh sách hình vẽ

3.1	Thống kê missing ẩn và giá trị 0 theo thuộc tính	22
3.2	Tương quan của Age và quan hệ hồi quy Age-Glucose	25
3.3	Phân phối DPF theo outcome và các scatter trọng điểm	26
3.4	Quan hệ Glucose-BMI-Insulin theo outcome	26
3.5	Pipeline tiền xử lý và đánh giá mô hình	28
4.1	Phân bố lớp trong dữ liệu Pima	31
4.2	Ma trận tương quan sau khi áp dụng zero-as-missing	32
4.3	So sánh các cấu hình tiền xử lý + mô hình	35
4.4	Confusion matrix của cấu hình được chọn	36
4.5	Đường cong ROC cho các cấu hình dẫn đầu	37

Danh sách bảng

3.1	Mô tả các thuộc tính trong bộ dữ liệu Pima	21
3.2	Tỷ lệ giá trị 0 ở các biến sinh lý trọng điểm	21
3.3	Tỉ lệ chia tập và tỷ lệ lớp dương	23
3.4	Tương quan của biến đầu vào với outcome (zero-masked)	29
4.1	Kết quả đầy đủ 12 cấu hình tiền xử lý + mô hình	34
4.2	Precision-Recall-F1 theo ngưỡng của cấu hình tốt nhất	38

CHƯƠNG 1

Tổng quan vấn đề

1.1 Lý do chọn đề tài

Đái tháo đường là một bệnh mạn tính có tốc độ gia tăng nhanh, đồng thời tạo áp lực lớn lên hệ thống y tế do chi phí theo dõi và điều trị kéo dài. Không chỉ dừng lại ở bài toán kiểm soát đường huyết, bệnh còn liên quan chặt chẽ đến nhiều biến chứng nguy hiểm như tim mạch, suy thận, tổn thương thần kinh và giảm chất lượng sống lâu dài. Vì vậy, ở góc độ phòng ngừa và quản lý sức khỏe cộng đồng, phát hiện sớm nhóm bệnh nhân có nguy cơ cao luôn được xem là một ưu tiên quan trọng.

Trong thực hành lâm sàng hằng ngày, quyết định đánh giá nguy cơ thường dựa trên sự kết hợp của nhiều chỉ số y sinh và đặc điểm cá nhân như glucose huyết tương, chỉ số khối cơ thể (BMI), huyết áp, độ tuổi hoặc tiền sử gia đình. Tuy nhiên, dữ liệu thực tế thường có nhiều thách thức: phân phối không đồng đều, tồn tại giá trị bất thường và thiếu dữ liệu ẩn. Các yếu tố này khiến quá trình diễn giải nguy cơ trở nên phức tạp nếu chỉ dựa vào quan sát thủ công hoặc các ngưỡng đơn biến riêng lẻ.

Sự phát triển của khoa học dữ liệu và học máy mở ra một hướng tiếp cận phù hợp cho bài toán này. Thay vì xem từng biến độc lập, mô hình học máy có khả năng học từ quan hệ đa biến và lượng hóa xác suất rủi ro trên toàn bộ tập đặc trưng. Trong bối cảnh đó, mô hình không thay thế chẩn đoán của chuyên gia y tế, nhưng có thể đóng vai trò công cụ hỗ trợ ra quyết định, giúp tăng tính nhất quán và tính tái lập trong quá trình sàng lọc.

Từ góc nhìn học thuật, đề tài cũng phản ánh một bài toán điển hình trong phân tích dữ liệu y sinh: dữ liệu có kích thước vừa phải nhưng đòi hỏi quy trình tiền xử lý chặt chẽ, kiểm soát sai lệch và đánh giá mô hình cẩn trọng. Đây là môi trường phù hợp để kiểm chứng các lựa chọn kỹ thuật quan trọng, chẳng hạn cách xử lý missing data, chuẩn hóa đặc trưng và lựa chọn điểm cân bằng giữa precision và recall theo mục tiêu ứng dụng.

Bộ dữ liệu *Pima Indians Diabetes* được lựa chọn vì có tính chuẩn mực trong giáo dục và nghiên cứu [1, 2], cấu trúc rõ ràng, dễ tái lập thực nghiệm, và phù hợp để minh họa trọn vẹn một quy trình phân tích dữ liệu từ giai đoạn khám phá dữ liệu, tiền xử lý, xây dựng pipeline đến đánh giá mô hình. Việc chọn một bộ dữ liệu kinh điển còn giúp so sánh kết quả của nhóm với những nghiên cứu cùng dòng, qua đó nâng cao tính tham chiếu và tính học thuật của báo cáo.

1.2 Mục tiêu nghiên cứu

Đề tài hướng đến mục tiêu tổng quát là xây dựng một quy trình phân tích dữ liệu y sinh có tính hệ thống và khả năng tái lập nhằm dự đoán nguy cơ đái tháo đường trên bộ dữ liệu Pima. Quy trình này không chỉ tập trung vào hiệu năng dự báo, mà còn nhấn mạnh tính minh bạch trong từng bước xử lý để có thể kiểm chứng và mở rộng trong các nghiên cứu tiếp theo.

Từ mục tiêu tổng quát, nhóm triển khai các mục tiêu cụ thể theo các lớp công việc chính như sau:

- **Mục tiêu về dữ liệu:** Chuẩn hóa và kiểm soát chất lượng dữ liệu đầu vào, đặc biệt là xử lý các giá trị 0 bất thường ở biến sinh lý theo hướng *zero-as-missing*, nhằm giảm sai lệch diễn giải y học.
- **Mục tiêu về tiền xử lý:** Đánh giá tác động của các chiến lược nội suy thiếu dữ liệu (Median, KNN, Iterative/MICE) kết hợp với các phương pháp chuẩn hóa (StandardScaler, MinMaxScaler), từ đó xác định cấu hình tiền xử lý phù hợp cho bài toán phân lớp nhị phân.
- **Mục tiêu về mô hình hóa:** So sánh hai mô hình baseline là Logistic Regression và Random Forest trên cùng một thiết kế thực nghiệm để đánh giá khác biệt giữa mô hình tuyến tính dễ diễn giải và mô hình phi tuyến linh hoạt.
- **Mục tiêu về đánh giá:** Phân tích đầy đủ các chỉ số Accuracy, Precision, Recall, F1-score và ROC-AUC, đồng thời thảo luận trade-off giữa precision và recall khi thay đổi ngưỡng dự đoán theo định hướng sàng lọc nguy cơ.
- **Mục tiêu về tái lập:** Tổ chức thực nghiệm theo pipeline thống nhất và thông số cố định (`random_state`, tỷ lệ chia tập, cấu hình tiền xử lý), bảo đảm người đọc có thể tái tạo kết quả một cách nhất quán.

1.3 Câu hỏi nghiên cứu

Tương ứng với các mục tiêu nêu trên, nghiên cứu tập trung trả lời các câu hỏi sau:

1. Việc chuyển các giá trị 0 bất thường sang missing ẩn có giúp dữ liệu hợp lý hơn về mặt thống kê và có cải thiện chất lượng dự báo so với cách giữ nguyên dữ liệu thô hay không?
2. Trong các tổ hợp *imputer + scaler*, cấu hình nào mang lại sự cân bằng tốt nhất giữa độ ổn định của mô hình và hiệu năng dự báo trên dữ liệu chưa thấy?
3. Khi đặt trong cùng điều kiện thực nghiệm, Logistic Regression và Random Forest khác nhau như thế nào về khả năng tổng quát hóa, độ nhạy phát hiện lớp dương và mức độ ổn định giữa tập validation và test?
4. Khi thay đổi ngưỡng phân loại, trade-off giữa precision và recall biến thiên ra sao, và ngưỡng nào phù hợp hơn cho mục tiêu ưu tiên phát hiện sớm ca có nguy cơ?
5. Từ kết quả thực nghiệm, có thể rút ra khuyến nghị nào cho một quy trình baseline đáng tin cậy, làm nền cho các nghiên cứu mở rộng trong tương lai?

1.4 Đối tượng và phạm vi

Đối tượng nghiên cứu là bộ dữ liệu `pima-indians-diabetes.csv`, gồm 768 quan sát, 8 thuộc tính đầu vào dạng số và 1 biến mục tiêu nhị phân `outcome`. Các thuộc tính phản ánh thông tin nhân trắc và chỉ số sinh lý phổ biến như `glucose`, `blood_pressure`, `insulin`, `bmi`, `age`, cùng một số biến liên quan đến tiền sử.

Phạm vi nghiên cứu được xác định theo các chiều sau:

- **Phạm vi dữ liệu:** Chỉ sử dụng bộ dữ liệu Pima được cung cấp trong học phần, không kết hợp thêm nguồn dữ liệu bệnh án thực tế hoặc dữ liệu từ các hệ thống bệnh viện.
- **Phạm vi bài toán:** Tập trung vào phân lớp nhị phân (`outcome = 0/1`) cho mục tiêu sàng lọc nguy cơ; không thực hiện dự báo tiến triển theo thời gian và không xây dựng hệ thống chẩn đoán lâm sàng hoàn chỉnh.
- **Phạm vi phương pháp:** Ưu tiên các mô hình baseline có tính chuẩn mực trong học máy ứng dụng (Logistic Regression, Random Forest), kết hợp các kỹ thuật tiền xử lý phổ biến và dễ tái lập.

- **Phạm vi đánh giá:** Đánh giá trên các chỉ số phân lớp chuẩn và phân tích định lượng trade-off theo ngưỡng; không thực hiện kiểm định trên dữ liệu ngoại viện hoặc thử nghiệm triển khai thời gian thực.

Ngoài ra, nghiên cứu cũng xác định rõ các giới hạn: chưa đi sâu vào tối ưu siêu tham số quy mô lớn, chưa khảo sát các mô hình học sâu, chưa thực hiện hiệu chỉnh xác suất (probability calibration), và chưa đánh giá tác động công bằng mô hình theo từng nhóm dân số. Việc nêu rõ giới hạn giúp khoanh vùng đúng đóng góp của đề tài và tạo nền tảng cho định hướng phát triển ở các chương sau.

1.5 Phương pháp tổng quát

Toàn bộ nghiên cứu được triển khai bằng Python notebook theo một luồng kỹ thuật thống nhất, bảo đảm tính tái lập và khả năng kiểm tra chéo ở từng bước:

1. **Khảo sát dữ liệu ban đầu:** Nạp dữ liệu, kiểm tra kiểu dữ liệu, thống kê mô tả, tỷ lệ lớp, giá trị trùng lặp và các bất thường hiển nhiên.
2. **Xử lý missing ẩn theo ngữ cảnh y sinh:** Chuyển các giá trị 0 không hợp lý ở nhóm biến sinh lý sang giá trị thiếu để tránh làm sai lệch phân phối và ước lượng.
3. **Phân tích khám phá dữ liệu (EDA):** Trực quan hóa phân bố từng biến, phân tích tương quan giữa đặc trưng với *outcome*, và so sánh khác biệt giữa các nhóm lớp nhằm hình thành giả thuyết mô hình hóa.
4. **Thiết kế pipeline tiền xử lý:** Kết hợp có hệ thống giữa kỹ thuật nội suy thiếu dữ liệu và chuẩn hóa đặc trưng. Cách tổ chức theo pipeline giúp giảm nguy cơ rò rỉ dữ liệu và bảo đảm cùng một quy trình được áp dụng nhất quán giữa train, validation và test.
5. **Huấn luyện và so sánh mô hình baseline:** Triển khai các tổ hợp *imputer + scaler + model* theo cùng thiết kế, sau đó đánh giá trên nhiều chỉ số thay vì chỉ dựa vào một độ đo đơn lẻ.
6. **Phân tích ngưỡng và diễn giải kết quả:** Khảo sát độ nhạy của kết quả theo ngưỡng phân loại để lựa chọn cấu hình phù hợp hơn cho mục tiêu sàng lọc, đồng thời thảo luận ý nghĩa thực tiễn của các chỉ số đạt được.

Về mặt công cụ, nghiên cứu sử dụng hệ sinh thái Python và các thư viện chuẩn cho phân tích dữ liệu, trực quan hóa và học máy. Khung triển khai được xây dựng trên scikit-learn [3], trong khi nguyên lý mô hình hóa và đánh giá tham chiếu theo các tài

liệu kinh điển [4]. Cách tiếp cận này giúp cân bằng giữa tính học thuật và tính thực thi trong báo cáo.

1.6 Kết cấu báo cáo

Báo cáo được tổ chức thành 5 chương liên kết theo mạch từ tổng quan, cơ sở lý thuyết, triển khai thực nghiệm đến kết luận:

- **Chương 1 – Tổng quan vấn đề:** Trình bày bối cảnh, lý do chọn đề tài, mục tiêu, câu hỏi nghiên cứu, phạm vi thực hiện và phương pháp tổng quát.
- **Chương 2 – Cơ sở lý thuyết và nghiên cứu liên quan:** Hệ thống hóa các khái niệm nền tảng của phân tích dữ liệu và học máy trong bài toán phân lớp y sinh, đồng thời tóm lược các kỹ thuật được sử dụng.
- **Chương 3 – Dữ liệu và phương pháp đề xuất:** Mô tả chi tiết nguồn dữ liệu, đặc trưng đầu vào, quy trình kiểm tra chất lượng dữ liệu, thiết kế thực nghiệm và pipeline tiền xử lý.
- **Chương 4 – Thực nghiệm và kết quả đạt được:** Trình bày kết quả EDA, kết quả so sánh các cấu hình mô hình, phân tích định lượng theo chỉ số và thảo luận các điểm mạnh, điểm hạn chế.
- **Chương 5 – Kết luận và khuyến nghị:** Tổng kết đóng góp chính, nêu giới hạn của đề tài và đề xuất các hướng phát triển tiếp theo để nâng cao khả năng ứng dụng.

CHƯƠNG 2

Cơ sở lý thuyết và nghiên cứu liên quan

2.1 Tổng quan bài toán phân lớp trong dự đoán nguy cơ đái tháo đường

Bài toán dự đoán nguy cơ đái tháo đường trong nghiên cứu này được mô hình hóa dưới dạng phân lớp nhị phân: với mỗi quan sát lâm sàng, mô hình cần dự đoán nhãn *outcome* thuộc lớp âm tính (0) hoặc dương tính (1). Về bản chất, đây là bài toán học có giám sát (*supervised learning*), trong đó dữ liệu huấn luyện đã có sẵn nhãn mục tiêu.

Khác với các bài toán phân lớp ảnh hoặc văn bản, dữ liệu y sinh dạng bảng thường có số chiều không lớn nhưng chứa nhiều đặc điểm thống kê đặc thù: phân phối lệch, nhiễu đo lường, outlier, missing ẩn và tương quan chéo giữa các biến. Do vậy, hiệu quả mô hình không chỉ phụ thuộc vào thuật toán học máy mà còn phụ thuộc mạnh vào chất lượng tiền xử lý và thiết kế quy trình đánh giá.

Bộ dữ liệu *Pima Indians Diabetes* là một benchmark kinh điển trong học máy y sinh [1, 2], được sử dụng rộng rãi để kiểm chứng các chiến lược tiền xử lý và mô hình phân lớp. Việc lựa chọn bộ dữ liệu này giúp nghiên cứu đảm bảo tính so sánh, tính tái lập và phù hợp với mục tiêu xây dựng một baseline đáng tin cậy.

2.2 Phân tích khám phá dữ liệu (EDA)

Phân tích khám phá dữ liệu (*Exploratory Data Analysis – EDA*) là bước nền tảng trước khi huấn luyện mô hình. Mục tiêu của EDA là hiểu rõ cấu trúc dữ liệu, phát hiện bất thường, và hình thành giả thuyết ban đầu về mối quan hệ giữa biến đầu vào và biến mục tiêu. Trong bối cảnh y sinh, EDA còn đóng vai trò kiểm tra tính hợp lý của dữ liệu theo ngữ cảnh chuyên ngành, tránh diễn giải sai lệch.

Các thành phần EDA chính trong bài toán này bao gồm:

- **Thống kê mô tả:** giá trị trung bình, trung vị, độ lệch chuẩn, khoảng tứ phân vị và biên min-max cho từng biến.
- **Phân bố theo biến:** trực quan hóa histogram/boxplot để nhận diện phân phối lệch, đuôi dài và outlier.
- **Phân bố lớp mục tiêu:** đánh giá mức độ cân bằng giữa hai lớp *outcome* để dự báo rủi ro thiên lệch mô hình.
- **Tương quan và quan hệ đa biến:** xây dựng ma trận tương quan để xác định biến có liên hệ mạnh với *outcome*, đồng thời rà soát khả năng đa cộng tuyến.

Kết quả EDA không chỉ phục vụ mô tả dữ liệu, mà còn định hướng trực tiếp cho các quyết định kỹ thuật ở các bước sau: chọn chiến lược xử lý missing, chọn phương pháp chuẩn hóa, và xác định kỳ vọng hợp lý cho hiệu năng mô hình baseline.

2.3 Cơ sở lý thuyết tiền xử lý dữ liệu

2.3.1 Missing ẩn và chính sách *zero-as-missing*

Trong bộ dữ liệu Pima, một số biến sinh lý có giá trị 0 không hợp lý về mặt y học, điển hình là *glucose*, *blood_pressure*, *skin_thickness*, *insulin*, *bmi*. Những giá trị này thường phản ánh dữ liệu thiếu hoặc lỗi đo lường hơn là giá trị thực của bệnh nhân.

Nếu giữ nguyên các giá trị này như quan sát hợp lệ, các chỉ số thống kê có thể bị lệch đáng kể, kéo theo sai lệch ở bước học mô hình. Vì vậy, nghiên cứu áp dụng chính sách *zero-as-missing*: chuyển các giá trị 0 bất thường về dạng thiếu dữ liệu trước khi nội suy. Đây là một bước quan trọng để đưa dữ liệu về gần hơn với thực tế lâm sàng.

2.3.2 Các chiến lược nội suy thiếu dữ liệu

Sau khi xác định missing ẩn, nghiên cứu so sánh ba chiến lược nội suy phổ biến:

- **Median Imputation:** thay giá trị thiếu bằng trung vị của biến. Phương pháp này đơn giản, ổn định và ít nhạy cảm với outlier, phù hợp khi dữ liệu có phân phối lệch.
- **KNN Imputation:** ước lượng giá trị thiếu dựa trên các quan sát gần nhất trong không gian đặc trưng. Cách tiếp cận này có thể bảo toàn cấu trúc cục bộ của dữ liệu nhưng phụ thuộc vào lựa chọn khoảng cách và mức chuẩn hóa.

- **Iterative Imputation (MICE):** nội suy lặp bằng cách mô hình hóa từng biến thiếu dựa trên các biến còn lại. Phương pháp này tận dụng quan hệ đa biến tốt hơn, nhưng chi phí tính toán cao hơn và nhạy với cấu hình mô hình phụ trợ.

2.3.3 Chuẩn hóa đặc trưng

Do các biến đầu vào có thang đo khác nhau (ví dụ glucose, insulin, age), việc chuẩn hóa là cần thiết để tránh hiện tượng một số biến có độ lớn tuyệt đối chi phối quá trình học. Nghiên cứu khảo sát hai lựa chọn chuẩn hóa:

- **StandardScaler:** đưa dữ liệu về trung bình 0, độ lệch chuẩn 1, công thức

$$x' = \frac{x - \mu}{\sigma}$$

phù hợp khi dữ liệu gần phân phối chuẩn hoặc cần ổn định gradient.

- **MinMaxScaler:** ánh xạ dữ liệu về khoảng $[0, 1]$, công thức

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

phù hợp khi muốn giữ nguyên thứ tự và biên tương đối của biến.

Trong thực nghiệm, chuẩn hóa luôn được đặt trong pipeline để bảo đảm phép biến đổi được học từ tập train và áp dụng nhất quán cho validation/test, hạn chế rò rỉ dữ liệu.

2.4 Mô hình học máy baseline

2.4.1 Logistic Regression

Logistic Regression là mô hình phân lớp tuyến tính phổ biến, ước lượng xác suất thuộc lớp dương thông qua hàm sigmoid:

$$P(y = 1|x) = \sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$$

Ưu điểm của Logistic Regression là dễ diễn giải, tốc độ huấn luyện nhanh và thường hoạt động tốt trên dữ liệu tabular cỡ vừa. Trong bối cảnh nghiên cứu, mô hình này đóng vai trò chuẩn tham chiếu tuyến tính để so sánh với các mô hình phi tuyến.

2.4.2 Random Forest

Random Forest là phương pháp ensemble kết hợp nhiều cây quyết định được huấn luyện trên các mẫu bootstrap và tập đặc trưng ngẫu nhiên. Kết quả dự đoán cuối cùng được tổng hợp theo cơ chế bỏ phiếu đa số (classification). Nhờ cơ chế tổ hợp, Random Forest thường:

- giảm overfitting so với cây quyết định đơn lẻ;
- nắm bắt tốt quan hệ phi tuyến và tương tác giữa các biến;
- ít yêu cầu giả định phân phối dữ liệu;
- cung cấp chỉ báo *feature importance* phục vụ diễn giải.

Tuy nhiên, đổi lại mô hình có thể khó diễn giải hơn Logistic Regression và nhạy cảm với lựa chọn siêu tham số (số cây, độ sâu cây, tiêu chí chia nhánh).

2.5 Chỉ số đánh giá mô hình phân lớp

Đánh giá mô hình trong bài toán y sinh cần đa tiêu chí thay vì chỉ dựa trên một chỉ số đơn lẻ. Với ma trận nhầm lẫn gồm TP, TN, FP, FN , các chỉ số được sử dụng như sau:

- **Accuracy:**

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

đo tỷ lệ dự đoán đúng tổng quát.

- **Precision:**

$$\text{Precision} = \frac{TP}{TP + FP}$$

phản ánh mức độ tin cậy của dự đoán dương tính.

- **Recall (Sensitivity):**

$$\text{Recall} = \frac{TP}{TP + FN}$$

phản ánh khả năng phát hiện đúng ca dương tính thực sự.

- **F1-score:**

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

cân bằng giữa precision và recall.

- **ROC-AUC:** diện tích dưới đường cong ROC, đo khả năng phân biệt hai lớp trên nhiều ngưỡng khác nhau.

Trong bối cảnh sàng lọc nguy cơ, recall thường được ưu tiên để giảm bỏ sót ca bệnh tiềm năng; tuy nhiên precision cũng cần được theo dõi để tránh tăng quá nhiều cảnh báo sai. Vì vậy, nghiên cứu sử dụng đồng thời nhiều chỉ số để lựa chọn cấu hình phù hợp nhất.

2.6 Nghiên cứu liên quan

Nghiên cứu ứng dụng học máy cho bài toán dự đoán đái tháo đường đã được quan tâm từ sớm. Công trình của Smith và cộng sự [2] là một trong những nghiên cứu tiêu biểu sử dụng dữ liệu Pima để dự báo nguy cơ khởi phát bệnh, qua đó đặt nền tảng cho hướng tiếp cận dựa trên dữ liệu trong bối cảnh y sinh.

Trong các nghiên cứu sau này, bộ dữ liệu Pima tiếp tục được dùng rộng rãi để so sánh các kỹ thuật tiền xử lý và thuật toán phân lớp. Một xu hướng nhất quán là hiệu năng mô hình chịu ảnh hưởng lớn bởi chất lượng xử lý dữ liệu đầu vào, đặc biệt là cách xử lý missing, chuẩn hóa biến và chiến lược đánh giá theo ngưỡng. Nhiều nghiên cứu ghi nhận các mô hình phi tuyến như Random Forest có thể đạt độ chính xác cao hơn mô hình tuyến tính trong dữ liệu có tương tác biến phức tạp; ngược lại, Logistic Regression vẫn giữ vai trò quan trọng nhờ tính diễn giải và tính ổn định khi thiết lập baseline.

So với các công bố chỉ tập trung vào so sánh thuật toán, báo cáo này nhấn mạnh cách tiếp cận theo pipeline tái lập: kết hợp phân tích EDA, xử lý missing theo ngữ cảnh y sinh, so sánh nhiều cấu hình *imputer + scaler + model*, và phân tích trade-off chỉ số theo mục tiêu ứng dụng. Hướng tiếp cận này phù hợp với tinh thần thực nghiệm chặt chẽ trong các tài liệu học máy kinh điển [4] và triển khai thực tiễn trên hệ sinh thái scikit-learn [3].

CHƯƠNG 3

Dữ liệu và phương pháp đề xuất

3.1 Nguồn dữ liệu

Nghiên cứu sử dụng bộ dữ liệu chuẩn *Pima Indians Diabetes* trong học phần, bao gồm hai tệp:

- `Lab_03/data/pima-indians-diabetes.csv`
- `Lab_03/data/pima-indians-diabetes.names`

Tệp `.csv` chứa dữ liệu định lượng đã được cấu trúc theo hàng-cột; tệp `.names` mô tả ý nghĩa thuộc tính và bối cảnh thu thập dữ liệu. Theo mô tả gốc, bộ dữ liệu gồm 768 quan sát, 8 thuộc tính đầu vào dạng số và 1 biến mục tiêu nhị phân `outcome`. Việc lựa chọn bộ dữ liệu này phù hợp với mục tiêu xây dựng baseline vì dữ liệu có kích thước vừa phải, đủ để thử nghiệm nhiều chiến lược tiền xử lý nhưng vẫn kiểm soát tốt khả năng tái lập.

3.2 Mô tả thuộc tính

Các biến đầu vào đại diện cho nhóm chỉ số nhân trắc và sinh lý cơ bản thường dùng trong đánh giá nguy cơ đái tháo đường. Bảng 3.1 tóm tắt ý nghĩa từng thuộc tính trong bộ dữ liệu.

Bảng 3.1: Mô tả các thuộc tính trong bộ dữ liệu Pima

Thuộc tính	Ý nghĩa
pregnancies	Số lần mang thai
glucose	Nồng độ glucose huyết tương (2h OGTT)
blood_pressure	Huyết áp tâm trương (mm Hg)
skin_thickness	Độ dày nếp da cơ tay sau (mm)
insulin	Nồng độ insulin huyết thanh (2h)
bmi	Chỉ số khối cơ thể
diabetes_pedigree_function	Hệ số tiền sử gia đình
age	Tuổi
outcome	Nhân phân lớp (0/1)


Về mặt phân tích, có thể tạm chia các biến thành ba nhóm: (i) đặc điểm nhân khẩu học (**age**), (ii) đặc điểm tiền sử (**pregnancies**, **diabetes_pedigree_function**), và (iii) đặc điểm sinh lý cận lâm sàng (**glucose**, **blood_pressure**, **skin_thickness**, **insulin**, **bmi**). Cách phân nhóm này giúp định hướng rõ hơn cho EDA và xử lý missing theo ngữ cảnh y sinh.

3.3 Kiểm tra chất lượng dữ liệu

Kết quả tái lập từ notebook cho thấy bộ dữ liệu không có dòng trùng lặp và không có giá trị NaN tường minh trong tệp CSV gốc. Tuy nhiên, kiểm tra ngữ nghĩa dữ liệu cho thấy nhiều biến sinh lý chứa giá trị 0 không hợp lý về mặt lâm sàng. Vì vậy, nghiên cứu áp dụng chính sách *zero-as-missing* để xem các giá trị này là missing ẩn, tránh làm lệch thống kê mô tả và quá trình huấn luyện.

Bảng 3.2: Tỷ lệ giá trị 0 ở các biến sinh lý trọng điểm

Biến	Số lượng 0	Tỷ lệ (%)
insulin	374	48.70
skin_thickness	227	29.56
blood_pressure	35	4.56
bmi	11	1.43
glucose	5	0.65



Hình 3.1: Thống kê missing ẩn và giá trị 0 theo thuộc tính

Từ Bảng 3.2 có thể thấy mức độ missing ẩn phân bố không đồng đều giữa các biến. `insulin` và `skin_thickness` là hai biến bị ảnh hưởng mạnh nhất, trong khi `glucose` và `bmi` có tỷ lệ thấp hơn. Quan sát này là cơ sở để không dùng một chiến lược nội suy duy nhất theo mặc định, mà so sánh nhiều phương án imputation trong cùng thiết kế thực nghiệm.

Trong Hình 3.1, có thể thấy cấu trúc thiếu dữ liệu mang tính hệ thống chứ không ngẫu nhiên. Cụ thể, các cột liên quan đến cơ chế chuyển hóa (`insulin`) và đo nếp da (`skin_thickness`) xuất hiện cột missing vượt trội so với các biến còn lại, hàm ý rằng mức độ khó thu thập hoặc thiếu nhất quán quy trình đo có thể cao hơn ở các chỉ số này. Insight quan trọng là nếu giữ nguyên giá trị 0 như quan sát hợp lệ, mô hình sẽ có xu hướng học một “tín hiệu giả” rằng “insulin cực thấp” hoặc “độ dày nếp da bằng 0” xảy ra thường xuyên trong thực tế, từ đó làm méo ranh giới phân lớp. Do đó, hình này không chỉ có ý nghĩa mô tả mà còn là bằng chứng phương pháp luận cho quyết định *zero-as-missing* và việc so sánh đa chiến lược imputation ở phần thực nghiệm.

3.4 Thiết kế thực nghiệm và tái lập

Để bảo đảm tính công bằng khi so sánh mô hình, nghiên cứu giữ nguyên thiết kế thực nghiệm theo notebook gốc và triển khai thống nhất trên mọi cấu hình:

1. Chuyển 0 -> NaN cho các biến sinh lý bất thường.
2. Chia dữ liệu theo tỉ lệ train/validation/test = 60/20/20 với `stratify` và `random_state=42`.
3. Tạo pipeline kết hợp *imputer + scaler + model*.

4. So sánh 12 tổ hợp cấu hình (3 imputer x 2 scaler x 2 model).

Việc chia tập theo **stratify** giúp duy trì tỷ lệ lớp dương/âm tương đối ổn định giữa các tập, nhờ đó kết quả đánh giá ít bị nhiễu bởi sai lệch phân bố lớp. Bảng 3.3 cho thấy tỷ lệ **outcome=1** giữa train, validation và test gần như tương đương.

Bảng 3.3: Tỷ lệ chia tập và tỷ lệ lớp dương

Tập dữ liệu	Số mẫu	Tỷ lệ outcome=1
Train	460	0.3478
Validation	154	0.3506
Test	154	0.3506

3.4.1 Không gian cấu hình thực nghiệm

Mỗi thí nghiệm được xác định bởi một tổ hợp *imputer + scaler + model*. Cụ thể:

- **Imputer:** Median, KNN, Iterative (MICE).
- **Scaler:** StandardScaler, MinMaxScaler.
- **Model:** Logistic Regression, Random Forest.

Tổng cộng có $3 \times 2 \times 2 = 12$ cấu hình. Tất cả cấu hình được huấn luyện trên cùng tập train, chọn theo validation và báo cáo cuối cùng trên test để giảm rủi ro overfitting trong khâu lựa chọn mô hình.

3.4.2 Nguyên tắc tái lập

Để tăng khả năng tái lập kết quả giữa các lần chạy và giữa các môi trường máy khác nhau, nghiên cứu áp dụng:

- Cố định **random_state=42** cho các bước có ngẫu nhiên.
- Dùng pipeline thống nhất để mọi phép biến đổi đều học từ train và áp dụng cho validation/test.
- So sánh mô hình trên cùng một bộ chỉ số và cùng cách chia dữ liệu.

3.4.3 Code mô tả quy trình dữ liệu

Để liên kết trực tiếp giữa mô tả phương pháp và mã triển khai, báo cáo trích một số đoạn code cốt lõi từ `Nhom01_SGU26_ML/Lab_03/pima_indians_diabetes_lab03.ipynb` và `Lab_03/pima_logistic_baseline_core.py`.

```
1 X = df[feature_columns].copy()
2 y = df["outcome"].astype(int)
3
4 X[zero_as_missing_columns] = X[zero_as_missing_columns].replace
   (0, np.nan)
5
6 X_train_val, X_test, y_train_val, y_test = train_test_split(
7     X, y, test_size=0.2, random_state=random_state, stratify=y
8 )
9 X_train, X_val, y_train, y_val = train_test_split(
10     X_train_val, y_train_val, test_size=0.25,
11     random_state=random_state, stratify=y_train_val
12 )
```

Listing 3.1: Nạp dữ liệu, áp dụng zero-as-missing và chia train/val/test có stratify

Đoạn mã trên thể hiện ba quyết định kỹ thuật quan trọng: (i) tách rõ biến đầu vào và biến mục tiêu, (ii) chuyển missing ẩn theo quy tắc *zero-as-missing*, và (iii) chia dữ liệu theo hai bước để đạt đúng tỉ lệ 60/20/20 trong khi vẫn giữ phân bố lớp dương ổn định giữa train/validation/test.

```
1 def make_pipeline(penalty: str) -> Pipeline:
2     if penalty == "l2":
3         lr = LogisticRegression(
4             penalty="l2", solver="lbfgs", C=1.0,
5             max_iter=5000, random_state=RANDOM_STATE
6         )
7     elif penalty == "l1":
8         lr = LogisticRegression(
9             penalty="l1", solver="saga", C=1.0,
10            max_iter=10000, random_state=RANDOM_STATE
11        )
12
13    return Pipeline(
14        steps=[
15            ("imputer", SimpleImputer(strategy="median")),
16            ("scaler", StandardScaler()),
```

```

17         ("clf", lr),
18     ]
19 )

```

Listing 3.2: Định nghĩa pipeline baseline (imputer + scaler + Logistic Regression)


Code block này cho thấy cách nhóm đóng gói toàn bộ bước tiền xử lý và mô hình hóa trong một pipeline thống nhất. Cách làm này giúp loại bỏ sai khác do thao tác thủ công giữa các lần chạy, đồng thời hạn chế rò rỉ dữ liệu vì mọi phép biến đổi đều được *fit* trên train trước khi áp dụng sang validation/test.

3.5 EDA chuyên sâu theo nhóm biến

Để phản ánh đầy đủ các phân tích trong notebook, nghiên cứu tổ chức EDA theo nhóm biến thay vì khảo sát rời rạc từng cột. Cách tiếp cận theo nhóm giúp bộc lộ rõ hơn mối quan hệ giữa đặc trưng và **outcome**, đồng thời liên kết trực tiếp với giả thuyết mô hình hóa ở các bước sau.

Ba cụm phân tích chính gồm:


- Nhóm Age: tương quan theo biến và hồi quy Age-Glucose.
- Nhóm DPF: phân phối theo outcome và tỷ lệ mắc bệnh theo quartile.
- Nhóm Glucose-BMI-Insulin: phân tán theo outcome sau khi áp dụng zero-masked.



Hình 3.2: Tương quan của Age và quan hệ hồi quy Age-Glucose


Trong Hình 3.2, có thể quan sát hai lớp thông tin quan trọng. Thứ nhất, ở phần tương quan, **age** có liên hệ dương với **outcome** nhưng mức độ không quá mạnh, cho thấy tuổi tác là yếu tố rủi ro nền chứ không phải biến quyết định duy nhất. Thứ hai, ở đồ thị hồi quy Age-Glucose, xu hướng tăng nhẹ của glucose theo tuổi phản ánh mối liên hệ

chuyển hóa hợp lý về mặt sinh học, nhưng độ phân tán điểm lớn cho thấy cùng một nhóm tuổi có thể tồn tại nhiều mức glucose khác nhau. Insight rút ra là mô hình tuyến tính đơn giản theo một biến sẽ khó đủ sức phân tách lớp; thay vào đó cần học quan hệ đa biến (tuổi, glucose, BMI, insulin...) và cả tương tác giữa chúng.



Hình 3.3: Phân phối DPF theo outcome và các scatter trọng điểm

Trong Hình 3.3, vai trò của `diabetes_pedigree_function` (DPF) được thể hiện như một chỉ báo rủi ro nền theo tiền sử gia đình. Phân phối DPF giữa hai lớp có xu hướng dịch chuyển: nhóm `outcome=1` thường tập trung nhiều hơn ở các khoảng DPF cao, dù vẫn tồn tại vùng chồng lấp. Sự chồng lấp này là một insight quan trọng: DPF có giá trị phân biệt nhưng không đủ để phân lớp độc lập. Các scatter trọng điểm cho thấy khi DPF cao đồng thời đi kèm glucose hoặc BMI cao, mật độ điểm lớp dương tăng rõ hơn. Điều này củng cố giả thuyết rằng nguy cơ đái tháo đường là kết quả của tương tác nhiều yếu tố, không phải tác động tuyến tính một chiều.




Hình 3.4: Quan hệ Glucose-BMI-Insulin theo outcome

Trong Hình 3.4, `glucose` là trục phân tách nổi bật nhất giữa hai lớp, phù hợp với kết quả tương quan ở Bảng 3.4 ($\text{corr} = 0.4947$). Tuy nhiên, biên phân tách không tuyến tính tuyệt đối: trong vùng glucose trung gian, hai lớp còn chồng lấp đáng kể và cần thêm thông tin từ BMI/insulin để tăng độ phân biệt. Một quan sát quan trọng khác là

sau khi áp dụng *zero-as-missing* và nội suy, cấu trúc phân tán trở nên “liên tục” hơn, giảm cụm điểm bất thường tại giá trị 0 ở insulin. Insight thực nghiệm từ hình này là cấu hình tiền xử lý ảnh hưởng trực tiếp đến hình học không gian đặc trưng; khi hình học dữ liệu hợp lý hơn, mô hình học máy có điều kiện tốt hơn để học ranh giới quyết định ổn định.

3.6 Quy trình tiền xử lý đề xuất

Quy trình tiền xử lý được thiết kế theo nguyên tắc *thống nhất – mô-đun – tái lập*. Thay vì xử lý rời từng bước, nghiên cứu đóng gói toàn bộ chuỗi biến đổi vào pipeline để giảm lỗi thao tác thủ công và hạn chế rò rỉ dữ liệu.



Hình 3.5: Pipeline tiền xử lý và đánh giá mô hình

Trong Hình 3.5, luồng kỹ thuật từ dữ liệu thô đến đánh giá mô hình được tổ chức dưới dạng pipeline khép kín. Ý nghĩa cốt lõi của kiến trúc này là tách bạch rõ các pha *fit* và *transform*: imputer/scaler chỉ học tham số trên train, sau đó áp dụng sang validation/test. Nhờ vậy, nghiên cứu tránh được lỗi rò rỉ dữ liệu (data leakage) – một lỗi phổ biến khiến chỉ số đánh giá “đẹp giả” nhưng không tái lập khi triển khai thực tế. Ở góc độ vận hành, pipeline còn giúp đảm bảo mọi cấu hình thử nghiệm được chạy trên cùng quy trình xử lý, làm cho so sánh giữa 12 tổ hợp trở nên công bằng và có ý nghĩa thống kê hơn.

3.6.1 Luồng xử lý kỹ thuật

Pipeline tiền xử lý và huấn luyện được thực hiện theo chuỗi:

1. Chuẩn hóa dữ liệu đầu vào và chuyển missing   n theo chính sách *zero-as-missing*.
2.   p dụng imputation để khôi phục giá trị thiếu.
3. Chuẩn hóa thang đo đặc trưng.
4. Huấn luyện mô hình và sinh xác suất dự đoán.
5.   ánh giá theo bộ chỉ số phân lớp và phân tích ngưỡng.

3.6.2 Ưu tiên biến cho diễn giải

Ngoài ma trận tương quan đầy đủ, notebook còn xuất bảng tương quan riêng theo `outcome` để ưu tiên biến trong phần diễn giải kết quả:

B  ng 3.4: Tương quan của biến đầu vào với outcome (zero-masked)

Bi��n	Corr với outcome
glucose	0.4947
bmi	0.3137
insulin	0.3035
skin_thickness	0.2595
age	0.2384
pregnancies	0.2219

Kết quả ở B  ng 3.4 cho thấy `glucose` c   mức tương quan cao nhất với biến mục tiêu, tiếp theo là `bmi` và `insulin`. Tuy nhiên, nghiên cứu không loại bỏ sớm các biến c   tương quan thấp hơn, vì các mô hình phi tuyến như Random Forest c   thể khai thác tương tác biến mà tương quan tuyến tính đơn biến không phản   nh đầy đủ.

CHƯƠNG 4

Thực nghiệm và kết quả đạt được

4.1 Giới thiệu chương

Chương này trình bày toàn bộ kết quả thực nghiệm nhằm trả lời các câu hỏi nghiên cứu đã nêu ở Chương 1: (i) tác động của chiến lược xử lý missing ẩn, (ii) hiệu quả của các tổ hợp tiền xử lý, (iii) mức độ phù hợp giữa Logistic Regression và Random Forest, và (iv) trade-off giữa precision–recall khi điều chỉnh ngưỡng.

Khác với cách báo cáo chỉ nêu chỉ số cuối cùng, chương này tập trung vào diễn giải theo chuỗi: chất lượng dữ liệu → hành vi của mô hình → ý nghĩa thực tiễn trong bối cảnh sàng lọc nguy cơ. Các kết quả được trình bày theo cùng một thiết kế tái lập đã xây dựng ở Chương 3 để bảo đảm tính nhất quán giữa các cấu hình.

4.2 Thiết lập thực nghiệm

4.2.1 Chiến lược chia dữ liệu

Dữ liệu được chia theo tỉ lệ 60/20/20 với *stratify* trên nhãn `outcome` để giữ ổn định tỉ lệ lớp dương tính giữa các tập.

- Train: 460 mẫu
- Validation: 154 mẫu
- Test: 154 mẫu

4.2.2 Tổ hợp cấu hình được so sánh

Không gian thực nghiệm được xây dựng theo nguyên tắc *đổi một thành phần – giữ nguyên phần còn lại* để có thể quy trách nhiệm cho từng quyết định kỹ thuật:

- Imputation: Median, KNN, Iterative(MICE)
- Scaling: StandardScaler, MinMaxScaler
- Model: Logistic Regression, Random Forest


Tổng cộng 12 cấu hình được đánh giá với cùng một seed và cùng một split để đảm bảo công bằng.

Với thiết kế này, khác biệt về kết quả phản ánh chủ yếu tác động của pipeline tiền xử lý và họ mô hình, không bị nhiễu bởi thay đổi dữ liệu đầu vào hay ngẫu nhiên trong chia tập.

4.3 Kết quả EDA chính

4.3.1 Tổng quan bộ dữ liệu

Bộ dữ liệu có 768 dòng và 9 cột (8 biến đầu vào và 1 biến đầu ra). Phân bố lớp: class 0 = 500 mẫu (65.1%), class 1 = 268 mẫu (34.9%).




Hình 4.1: Phân bố lớp trong dữ liệu Pima

Trong Hình 4.1, có thể thấy lớp âm (outcome=0) chiếm ưu thế so với lớp dương. Mức mất cân bằng không quá cực đoan nhưng đủ lớn để khiến accuracy dễ “đẹp giả” nếu mô hình thiên về dự đoán lớp đa số. Insight chính từ hình này là các chỉ số như recall, precision và F1 cần được ưu tiên khi đánh giá, thay vì chỉ nhìn accuracy.

4.3.2 Nhận xét về quality data

Số dòng trùng lặp bằng 0. Các cột có số lượng 0 cao nhất là `insulin` và `skin_thickness`, do đó cần xử lý missing ẩn trước huấn luyện.



Hình 4.2: Ma trận tương quan sau khi áp dụng zero-as-missing

Trong Hình 4.2, `glucose` là biến thể hiện quan hệ tuyến tính rõ nhất với `outcome`, trong khi các biến khác như `bmi`, `insulin`, `age` có mức liên hệ trung bình. Tuy vậy, ma trận cũng cho thấy không có biến đơn lẻ nào đủ sức giải thích hoàn toàn nhãn đầu ra. Điều này hàm ý mô hình cần khai thác tương tác đa biến và phi tuyến, là lý do Random Forest được đưa vào so sánh cùng Logistic Regression.

4.4 So sánh mô hình và chiến lược tiền xử lý

4.4.1 Bảng tổng hợp đầy đủ 12 cấu hình

Khác với bản rút gọn trước đây (top-5), bảng dưới đây tổng hợp đầy đủ 12 tổ hợp (*imputer* x *scaler* x *model*) với các chỉ số quan trọng trên validation và test.

```
1 def evaluate_strategy(imputer_name: str, scaler_name: str,  
    model_name: str):  
2     if imputer_name == "median":
```

```

3         imputer = SimpleImputer(strategy="median")
4     elif imputer_name == "knn":
5         imputer = KNNImputer(n_neighbors=5)
6     elif imputer_name == "iterative":
7         imputer = IterativeImputer(random_state=random_state,
8                                     max_iter=10)
9
10    scaler = StandardScaler() if scaler_name == "standard" else
11        MinMaxScaler()
12    model = build_model(model_name)
13
14    pipe = Pipeline(
15        steps=[("imputer", imputer), ("scaler", scaler), ("
16            model", model)]
17    )
18    pipe.fit(X_train, y_train)
19
20    y_val_pred = pipe.predict(X_val)
21    y_val_prob = pipe.predict_proba(X_val)[: , 1]
22    y_test_pred = pipe.predict(X_test)
23    y_test_prob = pipe.predict_proba(X_test)[: , 1]
24
25    metrics = {
26        "imputer": imputer_name,
27        "scaler": scaler_name,
28        "model": model_name,
29        "val_f1": f1_score(y_val, y_val_pred),
30        "val_roc_auc": roc_auc_score(y_val, y_val_prob),
31        "test_f1": f1_score(y_test, y_test_pred),
32        "test_roc_auc": roc_auc_score(y_test, y_test_prob),
33    }
34    return metrics

```

Listing 4.1: Hàm đánh giá một chiến lược imputer + scaler + model

Đoạn code trên là lõi của vòng so sánh 12 cấu hình trong notebook. Điểm quan trọng là mọi cấu hình đều đi qua cùng quy trình *fit-predict-evaluate*, nên các chỉ số ở Bảng 4.1 phản ánh đúng tác động của từng lựa chọn imputer/scaler/model, không bị sai lệch do khác biệt quy trình xử lý.

Bảng 4.1: Kết quả đầy đủ 12 cấu hình tiền xử lý + mô hình

Imputer	Scaler	Model	Val AUC	Test AUC	Acc	Prec	Rec	F1
KNN	MinMax	Random Forest	0.8700	0.8170	0.7403	0.6458	0.5741	0.6078
KNN	Standard	Random Forest	0.8690	0.8168	0.7403	0.6458	0.5741	0.6078
Median	Standard	Logistic Regression	0.8498	0.8167	0.7078	0.6000	0.5000	0.5455
Iterative	MinMax	Random Forest	0.8572	0.8156	0.7273	0.6250	0.5556	0.5882
KNN	Standard	Logistic Regression	0.8526	0.8154	0.7143	0.6136	0.5000	0.5510
Iterative	Standard	Random Forest	0.8556	0.8153	0.7273	0.6250	0.5556	0.5882
Median	MinMax	Random Forest	0.8596	0.8149	0.7338	0.6383	0.5556	0.5941
Iterative	Standard	Logistic Regression	0.8476	0.8148	0.7143	0.6190	0.4815	0.5417
Median	Standard	Random Forest	0.8604	0.8136	0.7338	0.6383	0.5556	0.5941
KNN	MinMax	Logistic Regression	0.8730	0.8117	0.7208	0.6341	0.4815	0.5474
Median	MinMax	Logistic Regression	0.8659	0.8098	0.7273	0.6500	0.4815	0.5532
Iterative	MinMax	Logistic Regression	0.8709	0.8093	0.7208	0.6279	0.5000	0.5567


Bảng 4.1 cho thấy một số xu hướng ổn định:

- Nhóm **Random Forest** nhìn chung cho F1 cao hơn nhóm Logistic Regression trong cùng điều kiện imputer/scaler.
- **KNN Imputer** khi kết hợp Random Forest tạo top cấu hình theo test ROC-AUC.
- Chênh lệch giữa StandardScaler và MinMaxScaler trong cùng một mô hình không lớn, gợi ý rằng với Pima, lựa chọn imputer và model ảnh hưởng mạnh hơn lựa chọn scaler.

Một điểm quan trọng là khác biệt test ROC-AUC giữa các cấu hình đứng đầu khá nhỏ (xung quanh 0.81–0.82). Vì vậy, quyết định “cấu hình tốt nhất” cần dựa thêm vào mục tiêu ứng dụng (ưu tiên recall hay precision), không nên chỉ bám một con số đơn lẻ.

4.4.2 Xếp hạng theo ROC-AUC và F1

Các cấu hình dẫn đầu tiếp tục tập trung ở nhóm **KNN Imputer + Random Forest**, cho thấy dữ liệu Pima hưởng lợi từ nội suy theo lân cận khi kết hợp với mô hình phi tuyến.



Hình 4.3: So sánh các cấu hình tiền xử lý + mô hình

Trong Hình 4.3, thứ hạng theo ROC-AUC và F1 không hoàn toàn trùng nhau. Một số cấu hình có AUC tốt nhưng F1 thấp hơn do điểm cân bằng precision–recall tại ngưỡng 0.5 chưa tối ưu. Insight này củng cố rằng ở bài toán sàng lọc, cần đọc song song cả chỉ số phân biệt ngưỡng–độc-lập (AUC) và chỉ số tại ngưỡng vận hành (F1/Recall).

4.4.3 Cấu hình đề xuất

Cấu hình tốt nhất theo test ROC-AUC: **KNN Imputer + MinMaxScaler + Random Forest**.

- Validation ROC-AUC: 0.8700
- Test ROC-AUC: 0.8170
- Test Accuracy: 0.7403
- Test F1: 0.6078
- Test Precision: 0.6458
- Test Recall: 0.5741

Về mặt ý nghĩa, cấu hình này thể hiện sự cân bằng khá tốt giữa năng lực phân biệt lớp (AUC) và hiệu năng vận hành tại ngưỡng mặc định. Tuy nhiên, recall 0.5741 vẫn cho thấy mô hình còn bỏ sót một phần đáng kể ca dương, do đó cần bước tinh chỉnh ngưỡng nếu mục tiêu ưu tiên phát hiện sớm.

4.4.4 So sánh theo họ mô hình (Logistic vs Random Forest)

Khi gộp trung bình theo họ mô hình trên toàn bộ 12 cấu hình:


- **Logistic Regression:** test ROC-AUC trung bình 0.8129, test F1 trung bình 0.5492.
- **Random Forest:** test ROC-AUC trung bình 0.8155, test F1 trung bình 0.5967.

Random Forest nhỉnh hơn nhẹ về AUC và rõ hơn về F1, phù hợp với mục tiêu cân bằng precision/recall.

Diễn giải theo góc độ học máy, kết quả này nhất quán với đặc trưng dữ liệu y sinh dạng bảng: quan hệ giữa biến đầu vào và nhãn thường không thuần tuyến tính, do đó mô hình ensemble phi tuyến có lợi thế. Tuy vậy, Logistic Regression vẫn hữu ích như baseline để diễn giải và làm chuẩn đối chiếu trong các vòng cải tiến sau.

4.5 Phân tích sai số và trade-off

4.5.1 Confusion matrix và ROC




Hình 4.4: Confusion matrix của cấu hình được chọn

Trong Hình 4.4, mô hình tạo số lượng dự đoán đúng lớp âm khá cao ($TN = 86$), nhưng vẫn còn bỏ sót ca dương ($FN = 23$). Mẫu hình lỗi này thường gặp khi dữ liệu có chồng lấp giữa hai lớp và ngưỡng phân loại đặt ở mức mặc định 0.5.

Với ngưỡng mặc định 0.5, confusion matrix của cấu hình tốt nhất cho thấy:

- $TN = 86$, $FP = 17$
- $FN = 23$, $TP = 31$

Mô hình vẫn bỏ sót một phần ca dương (FN), do đó việc điều chỉnh threshold là cần thiết khi bài toán ưu tiên sàng lọc.



Hình 4.5: Đường cong ROC cho các cấu hình dẫn đầu

Trong Hình 4.5, các đường ROC của nhóm cấu hình dẫn đầu nằm khá gần nhau trên phần lớn miền ngưỡng, cho thấy mức độ chênh lệch tổng quát hóa không lớn. Điều này xác nhận rằng khác biệt giữa “top 1” và “top 3” chủ yếu là khác biệt tinh, và việc chọn cấu hình cuối nên dựa thêm trên tiêu chí nghiệp vụ (ưu tiên giảm FN hay FP).

4.5.2 Trade-off theo threshold

Notebook quét ngưỡng từ 0.30 đến 0.70 (bước 0.05), kết quả như Bảng 4.2.

```
1 thresholds = np.arange(0.30, 0.75, 0.05)
2 threshold_rows = []
3 for thr in thresholds:
```

```

4     pred_thr = (best_artifacts["y_test_prob"] >= thr).astype(
5         int)
6     threshold_rows.append(
7         {
8             "threshold": round(float(thr), 2),
9             "precision": precision_score(y_test, pred_thr),
10            "recall": recall_score(y_test, pred_thr),
11            "f1": f1_score(y_test, pred_thr),
12        }
13    )
14 threshold_df = pd.DataFrame(threshold_rows)

```

Listing 4.2: Quét threshold để phân tích trade-off precision/recall

Code block này cho thấy bảng trade-off không được nhập thủ công mà được sinh trực tiếp từ xác suất dự đoán của cấu hình tốt nhất. Nhờ đó, các mốc threshold trong Bảng 4.2 có thể tái tạo hoàn toàn, đồng thời tạo nền để mở rộng sang các tiêu chí chọn ngưỡng khác (ví dụ: tối đa recall trong ràng buộc precision tối thiểu).

Bảng 4.2: Precision-Recall-F1 theo ngưỡng của cấu hình tốt nhất

Threshold	Precision	Recall	F1
0.30	0.5789	0.8148	0.6769
0.35	0.5970	0.7407	0.6612
0.40	0.6167	0.6852	0.6491
0.45	0.6296	0.6296	0.6296
0.50	0.6458	0.5741	0.6078
0.55	0.6429	0.5000	0.5625
0.60	0.6944	0.4630	0.5556
0.65	0.7188	0.4259	0.5349
0.70	0.7500	0.3333	0.4615

Bảng 4.2 cho thấy quy luật rõ ràng: khi giảm threshold, recall tăng nhưng precision giảm; khi tăng threshold, precision tăng nhưng recall giảm mạnh. Đây là trade-off cốt lõi của bài toán sàng lọc.

Ngưỡng 0.50 chưa tối ưu theo F1; ngưỡng 0.30 cho F1 cao nhất (0.6769) và recall cao (0.8148), phù hợp kịch bản ưu tiên phát hiện ca dương. Trong môi trường ứng dụng thực tế, nhóm ngưỡng 0.30–0.40 là lựa chọn hợp lý cho pha sàng lọc ban đầu, sau đó kết hợp bước kiểm tra y khoa chuyên sâu để giảm ảnh hưởng của false positive.

4.5.3 Nhận định overfitting/underfitting

Chênh lệch `val_roc_auc - test_roc_auc` xấp xỉ 0.053. Điều này cho thấy dấu hiệu overfitting nhẹ đến trung bình, cần tiếp tục kiểm chứng bằng cross-validation và tuning hệ thống trong bước tiếp theo.

Với mức chênh này, mô hình chưa rơi vào overfitting nặng nhưng đã có dấu hiệu “lạc quan hóa” trên validation. Để cải thiện độ ổn định, các bước tiếp theo nên gồm: (i) cross-validation nhiều fold, (ii) tuning có kiểm soát cho Random Forest, và (iii) xem xét calibration xác suất để tối ưu quyết định ngưỡng theo mục tiêu sàng lọc.

4.6 Kết luận chương

Từ toàn bộ thực nghiệm, có thể rút ra bốn kết luận chính:

- Chính sách *zero-as-missing* là cần thiết và có tác động thực chất đến chất lượng mô hình.
- Tổ hợp **KNN Imputer + MinMaxScaler + Random Forest** đạt hiệu năng tốt nhất theo test ROC-AUC trong không gian 12 cấu hình.
- Random Forest nhìn chung ổn định hơn Logistic Regression về F1, phản ánh lợi thế trong dữ liệu có quan hệ phi tuyến.
- Điều chỉnh threshold mang lại cải thiện lớn cho mục tiêu sàng lọc; ngưỡng 0.30 phù hợp hơn ngưỡng mặc định 0.5 khi ưu tiên recall.

Các kết quả này tạo nền tảng trực tiếp cho Chương 5, nơi báo cáo tổng hợp đóng góp, nêu giới hạn và đề xuất hướng phát triển tiếp theo.

CHƯƠNG 5

Kết luận và khuyến nghị

5.1 Kết luận chung

Đề tài đã hoàn thành mục tiêu xây dựng một quy trình phân tích dữ liệu tái lập cho bài toán dự đoán nguy cơ đái tháo đường trên bộ dữ liệu Pima, đi từ kiểm tra chất lượng dữ liệu, xử lý missing   n, phân tích khám phá dữ liệu, đến huấn luyện và đánh giá mô hình baseline. Trọng tâm của nghiên cứu không chỉ nằm ở việc tìm cấu hình có chỉ số cao nhất, mà còn ở việc làm rõ “vì sao cấu hình đó hoạt động tốt” và “khi nào nên điều chỉnh ngưỡng dự đoán” theo mục tiêu sàng lọc.

Kết quả thực nghiệm cho thấy chất lượng dữ liệu và chiến lược tiền xử lý có tác động trực tiếp đến hiệu năng mô hình. Việc kết hợp *zero-as-missing* với pipeline *imputation + scaling* giúp giảm nhiễu từ các giá trị phi sinh lý, từ đó tạo nền tảng ổn định hơn cho cả Logistic Regression và Random Forest. Nhìn tổng thể, đề tài đã cung cấp được một baseline đáng tin cậy cho các bước phát triển sâu hơn trong những nghiên cứu tiếp theo.

5.2 Tóm tắt kết quả đạt được

Nghiên cứu đạt được các kết quả chính sau:

1. **Hoàn thiện quy trình thực nghiệm tái lập:** xây dựng pipeline nhất quán cho toàn bộ chuỗi xử lý và đánh giá, bảo đảm khả năng kiểm chứng kết quả giữa các lần chạy.
2. **So sánh hệ thống 12 cấu hình:** tổ hợp giữa 3 chiến lược imputation, 2 scaler và 2 họ mô hình được đánh giá trên cùng điều kiện chia dữ liệu để bảo đảm tính công bằng.
3. **Xác định cấu hình tốt nhất theo test ROC-AUC:** KNN Imputer +

MinMaxScaler + Random Forest đạt `val_roc_auc = 0.8700`, `test_roc_auc = 0.8170`, `test_accuracy = 0.7403`, `test_f1 = 0.6078`.

4. **Làm rõ hành vi mô hình theo ngưỡng:** phân tích confusion matrix, ROC và bảng trade-off theo threshold cho thấy ngưỡng mặc định 0.5 chưa tối ưu nếu mục tiêu ưu tiên phát hiện sớm ca dương.

Kết quả trên xác nhận rằng chênh lệch giữa các cấu hình top đầu tương đối nhỏ về AUC, nhưng có thể khác nhau đáng kể về recall/F1 tại ngưỡng vận hành. Vì vậy, quyết định cuối cùng nên gắn với bối cảnh sử dụng (sàng lọc hay chẩn đoán xác nhận), thay vì chọn theo một chỉ số đơn lẻ.

5.3 Trả lời trực tiếp câu hỏi nghiên cứu (Q1/Q2/Q3)

- **Q1 – Zero-as-missing có hữu ích không?** Có. Việc chuyển 0 -> NaN cho các biến sinh lý có giá trị 0 bất thường giúp giảm nhiễu và cải thiện tính hợp lý của dữ liệu đầu vào. Thực nghiệm cho thấy các cấu hình sau xử lý missing ẩn đạt mức AUC ổn định quanh 0.81 trên test, đồng thời tạo nền tảng tốt hơn cho phân tách lớp.
- **Q2 – Tổ hợp preprocessing/model nào tốt nhất?** Cấu hình tốt nhất là **KNN + MinMax + Random Forest** với `val_roc_auc=0.8700`, `test_roc_auc=0.8170`, `test_accuracy=0.7403`.
- **Q3 – Trade-off precision/recall thay đổi ra sao theo threshold?** Khi giảm ngưỡng từ 0.50 xuống 0.30, recall tăng mạnh từ 0.5741 lên 0.8148, trong khi precision giảm từ 0.6458 xuống 0.5789; F1 cải thiện từ 0.6078 lên 0.6769. Điều này cho thấy ngưỡng thấp hơn phù hợp hơn cho kịch bản sàng lọc ban đầu, nơi giảm bỏ sót ca dương là ưu tiên chính.

5.4 Đóng góp của đề tài

Đề tài mang lại các đóng góp ở cả hai khía cạnh học thuật và ứng dụng:

- **Đóng góp phương pháp:** Chuẩn hóa quy trình thực hành từ EDA đến đánh giá mô hình baseline trong một pipeline có khả năng tái lập.
- **Đóng góp thực nghiệm:** Cung cấp so sánh định lượng đầy đủ cho 12 cấu hình tiền xử lý + mô hình trong cùng điều kiện dữ liệu.

- **Đóng góp diễn giải:** Bổ sung phân tích theo confusion matrix, ROC và threshold trade-off, giúp kết quả không dừng ở “chỉ số đẹp” mà chuyển thành khuyến nghị vận hành cụ thể.
- **Đóng góp học phần:** Nâng mức báo cáo hóa từ notebook thực hành lên báo cáo học thuật hoàn chỉnh, thuận lợi cho giảng dạy, thảo luận và mở rộng nghiên cứu.

5.5 Hạn chế nghiên cứu

Mặc dù đạt kết quả tích cực, nghiên cứu vẫn tồn tại một số giới hạn cần lưu ý:

1. **Giới hạn dữ liệu:** Quy mô mẫu còn nhỏ (768 quan sát), chưa đại diện cho nhiều quần thể bệnh nhân khác nhau, do đó khả năng khái quát hóa ngoài bộ dữ liệu gốc còn hạn chế.
2. **Giới hạn giả định xử lý dữ liệu:** Chính sách *zero-as-missing* phù hợp về ngữ cảnh phần lớn biến sinh lý, nhưng vẫn có rủi ro sai lệch nếu tồn tại trường hợp đo thực sự rất thấp hoặc bằng 0.
3. **Giới hạn đánh giá:** Kết quả hiện tại dựa trên một lần chia train/validation/test; chưa có kiểm chứng lặp nhiều lần bằng cross-validation nên độ ổn định thống kê cần được xác nhận thêm.
4. **Giới hạn tối ưu mô hình:** Chưa triển khai tuning tham số hệ thống và calibration xác suất, vì vậy hiệu năng mô hình vẫn còn dư địa cải thiện.

5.6 Hướng phát triển và kiến nghị

Xuất phát từ các hạn chế nêu trên, nghiên cứu đề xuất hướng phát triển theo ba giai đoạn:

5.6.1 Ngắn hạn (1–3 tháng)

- Áp dụng **Stratified K-Fold Cross-Validation** để kiểm chứng độ ổn định kết quả.
- Thực hiện **hyperparameter tuning** có kiểm soát cho Logistic Regression và Random Forest.
- Bổ sung **probability calibration** (Platt/Isotonic) để tối ưu quyết định theo ngưỡng.

5.6.2 Trung hạn (3–6 tháng)

- Thử nghiệm thêm các mô hình boosting như XGBoost/LightGBM và so sánh với baseline hiện tại.
- Khảo sát kỹ thuật cân bằng lớp và đánh giá độ nhạy kết quả theo nhiều chiến lược sampling khác nhau.
- Chuẩn hóa bộ tiêu chí chọn ngưỡng theo mục tiêu nghiệp vụ (ưu tiên recall, ưu tiên precision, hoặc cân bằng F1).

5.6.3 Dài hạn (trên 6 tháng)

- Mở rộng dữ liệu và kiểm tra **external validity** trên nguồn độc lập để tăng khả năng tổng quát hóa.
- Đóng gói pipeline suy luận thành công cụ hỗ trợ quyết định có khả năng chạy lặp lại, giám sát và báo cáo tự động.
- Xây dựng khung kiểm soát chất lượng dữ liệu đầu vào và cảnh báo drift nếu triển khai trong môi trường thực tế.

Về khuyến nghị ứng dụng, mô hình hiện tại nên được sử dụng như công cụ sàng lọc và tham chiếu định lượng ban đầu, không thay thế hoàn toàn đánh giá chuyên môn y tế. Cách tiếp cận kết hợp giữa mô hình dự báo và thẩm định lâm sàng sẽ giúp tận dụng ưu thế của dữ liệu mà vẫn đảm bảo an toàn trong quyết định cuối cùng.

Tài liệu tham khảo

- [1] National Institute of Diabetes and Digestive and Kidney Diseases. Pima indians diabetes database, 1990. UCI-style dataset description distributed with course materials.
- [2] J. W. Smith, J. E. Everhart, W. C. Dickson, W. C. Knowler, and R. S. Johannes. Using the adap learning algorithm to forecast the onset of diabetes mellitus. *Proceedings of the Symposium on Computer Applications and Medical Care*, pages 261–265, 1988.
- [3] Fabian Pedregosa et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [4] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2 edition, 2009.