

TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO TIỂU LUẬN
MÔN PHÂN TÍCH DỮ LIỆU

ĐỀ TÀI

RÚT TRÍCH DỮ LIỆU VÀ TIỀN XỬ LÝ
DỮ LIỆU PIMA INDIANS DIABETES

Giảng viên hướng dẫn:

Nhóm thực hiện: Nhom01_SGU26_ML

Học phần: Học phần thay thế khóa luận

Phân công thành viên

Thành viên	Nhiệm vụ chính	Tỷ lệ
Chibang	Tổng hợp notebook, xây dựng pipeline tiền xử lý, tổng hợp báo cáo	25%
Duybao	Hỗ trợ kiểm tra notebook, đối chiếu kết quả và markdown diễn giải	25%
Tranhuyvu	Phân tích sâu cho nhóm biến BMI/Insulin, góp ý trực quan hóa	25%
Truongphat	Phân tích sâu cho nhóm biến Age/DPF, góp ý diễn giải kết quả	25%

Nhận xét của giảng viên

Lời mở đầu

Báo cáo này trình bày kết quả thực hiện bài tập Lab 03 với dữ liệu Pima Indians Diabetes. Nhóm tập trung vào hai mục tiêu: (1) xây dựng quy trình rút trích và tiền xử lý dữ liệu có thể tái lập; (2) đánh giá các chiến lược tiền xử lý dưới góc nhìn mô hình học máy baseline.

Lời cảm ơn

Nhóm xin chân thành cảm ơn giảng viên hướng dẫn đã cung cấp yêu cầu, tài liệu tham khảo và những góp ý quan trọng để nhóm hoàn thiện notebook và báo cáo.

Mục lục

Phân công thành viên	1
Nhận xét của giảng viên	2
Lời mở đầu	3
Lời cảm ơn	4
1 Tổng quan vấn đề	9
1.1 Lý do chọn đề tài	9
1.2 Mục tiêu nghiên cứu	10
1.3 Câu hỏi nghiên cứu	11
1.4 Đối tượng và phạm vi	11
1.5 Phương pháp tổng quát	12
1.6 Kết cấu báo cáo	13
2 Cơ sở lý thuyết và nghiên cứu liên quan	14
2.1 Tổng quan phân tích dữ liệu trong bài toán phân lớp	14
2.2 Phân tích khám phá dữ liệu (EDA)	14
2.3 Xử lý missing data	14
2.4 Chuẩn hóa dữ liệu	15
2.5 Chỉ số đánh giá mô hình	15
2.6 Mô hình baseline	15
3 Dữ liệu và phương pháp đề xuất	16
3.1 Nguồn dữ liệu	16
3.2 Mô tả thuộc tính	16

3.3	Kiểm tra chất lượng dữ liệu	17
3.4	Thiết kế thực nghiệm và tái lập	17
3.5	EDA chuyên sâu theo nhóm biến	18
3.6	Quy trình tiền xử lý đề xuất	20
4	Thực nghiệm và kết quả đạt được	22
4.1	Thiết lập thực nghiệm	22
4.1.1	Chiến lược chia dữ liệu	22
4.1.2	Tổ hợp cấu hình được so sánh	22
4.2	Kết quả EDA chính	22
4.2.1	Tổng quan bộ dữ liệu	22
4.2.2	Nhận xét về quality data	23
4.3	So sánh mô hình và chiến lược tiền xử lý	24
4.3.1	Bảng tổng hợp đầy đủ 12 cấu hình	24
4.3.2	Xếp hạng theo ROC-AUC và F1	24
4.3.3	Cấu hình đề xuất	24
4.3.4	So sánh theo họ mô hình (Logistic vs Random Forest)	25
4.4	Phân tích sai số và trade-off	26
4.4.1	Confusion matrix và ROC	26
4.4.2	Trade-off theo threshold	27
4.4.3	Nhận định overfitting/underfitting	28
5	Kết luận và khuyến nghị	29
5.1	Kết luận chung	29
5.2	Tóm tắt kết quả đạt được	29
5.3	Trả lời trực tiếp câu hỏi nghiên cứu (Q1/Q2/Q3)	29
5.4	Đóng góp của đề tài	30
5.5	Hạn chế nghiên cứu	30
5.6	Hướng phát triển và kiến nghị	30

Danh sách hình vẽ

3.1	Thống kê missing ẩn và giá trị 0 theo thuộc tính	17
3.2	Tương quan của Age và quan hệ hồi quy Age-Glucose	18
3.3	Phân phối DPF theo outcome và các scatter trọng điểm	19
3.4	Quan hệ Glucose-BMI-Insulin theo outcome	19
3.5	Pipeline tiền xử lý và đánh giá mô hình	20
4.1	Phân bố lớp trong dữ liệu Pima	23
4.2	Ma trận tương quan sau khi áp dụng zero-as-missing	23
4.3	So sánh các cấu hình tiền xử lý + mô hình	24
4.4	Confusion matrix của cấu hình được chọn	26
4.5	Đường cong ROC cho các cấu hình dẫn đầu	27

Danh sách bảng

3.1	Mô tả các thuộc tính trong bộ dữ liệu Pima	16
3.2	Tỷ lệ giá trị 0 ở các biến sinh lý trọng điểm	17
3.3	Tỉ lệ chia tập và tỷ lệ lớp dương	18
3.4	Tương quan của biến đầu vào với outcome (zero-masked)	21
4.1	Kết quả đầy đủ 12 cấu hình tiền xử lý + mô hình	24
4.2	Precision-Recall-F1 theo ngưỡng của cấu hình tốt nhất	27

CHƯƠNG 1

Tổng quan vấn đề

1.1 Lý do chọn đề tài

Đái tháo đường là một bệnh mạn tính có tốc độ gia tăng nhanh, đồng thời tạo áp lực lớn lên hệ thống y tế do chi phí theo dõi và điều trị kéo dài. Không chỉ dừng lại ở bài toán kiểm soát đường huyết, bệnh còn liên quan chặt chẽ đến nhiều biến chứng nguy hiểm như tim mạch, suy thận, tổn thương thần kinh và giảm chất lượng sống lâu dài. Vì vậy, ở góc độ phòng ngừa và quản lý sức khỏe cộng đồng, phát hiện sớm nhóm bệnh nhân có nguy cơ cao luôn được xem là một ưu tiên quan trọng.

Trong thực hành lâm sàng hằng ngày, quyết định đánh giá nguy cơ thường dựa trên sự kết hợp của nhiều chỉ số y sinh và đặc điểm cá nhân như glucose huyết tương, chỉ số khối cơ thể (BMI), huyết áp, độ tuổi hoặc tiền sử gia đình. Tuy nhiên, dữ liệu thực tế thường có nhiều thách thức: phân phối không đồng đều, tồn tại giá trị bất thường và thiếu dữ liệu ẩn. Các yếu tố này khiến quá trình diễn giải nguy cơ trở nên phức tạp nếu chỉ dựa vào quan sát thủ công hoặc các ngưỡng đơn biến riêng lẻ.

Sự phát triển của khoa học dữ liệu và học máy mở ra một hướng tiếp cận phù hợp cho bài toán này. Thay vì xem từng biến độc lập, mô hình học máy có khả năng học từ quan hệ đa biến và lượng hóa xác suất rủi ro trên toàn bộ tập đặc trưng. Trong bối cảnh đó, mô hình không thay thế chẩn đoán của chuyên gia y tế, nhưng có thể đóng vai trò công cụ hỗ trợ ra quyết định, giúp tăng tính nhất quán và tính tái lập trong quá trình sàng lọc.

Từ góc nhìn học thuật, đề tài cũng phản ánh một bài toán điển hình trong phân tích dữ liệu y sinh: dữ liệu có kích thước vừa phải nhưng đòi hỏi quy trình tiền xử lý chặt chẽ, kiểm soát sai lệch và đánh giá mô hình cẩn trọng. Đây là môi trường phù hợp để kiểm chứng các lựa chọn kỹ thuật quan trọng, chẳng hạn cách xử lý missing data, chuẩn hóa đặc trưng và lựa chọn điểm cân bằng giữa precision và recall theo mục tiêu ứng dụng.

Bộ dữ liệu *Pima Indians Diabetes* được lựa chọn vì có tính chuẩn mực trong giáo dục và nghiên cứu [1, 2], cấu trúc rõ ràng, dễ tái lập thực nghiệm, và phù hợp để minh họa trọn vẹn một quy trình phân tích dữ liệu từ giai đoạn khám phá dữ liệu, tiền xử lý, xây dựng pipeline đến đánh giá mô hình. Việc chọn một bộ dữ liệu kinh điển còn giúp so sánh kết quả của nhóm với những nghiên cứu cùng dòng, qua đó nâng cao tính tham chiếu và tính học thuật của báo cáo.

1.2 Mục tiêu nghiên cứu

Đề tài hướng đến mục tiêu tổng quát là xây dựng một quy trình phân tích dữ liệu y sinh có tính hệ thống và khả năng tái lập nhằm dự đoán nguy cơ đái tháo đường trên bộ dữ liệu Pima. Quy trình này không chỉ tập trung vào hiệu năng dự báo, mà còn nhấn mạnh tính minh bạch trong từng bước xử lý để có thể kiểm chứng và mở rộng trong các nghiên cứu tiếp theo.

Từ mục tiêu tổng quát, nhóm triển khai các mục tiêu cụ thể theo các lớp công việc chính như sau:

- **Mục tiêu về dữ liệu:** Chuẩn hóa và kiểm soát chất lượng dữ liệu đầu vào, đặc biệt là xử lý các giá trị 0 bất thường ở biến sinh lý theo hướng *zero-as-missing*, nhằm giảm sai lệch diễn giải y học.
- **Mục tiêu về tiền xử lý:** Đánh giá tác động của các chiến lược nội suy thiếu dữ liệu (Median, KNN, Iterative/MICE) kết hợp với các phương pháp chuẩn hóa (StandardScaler, MinMaxScaler), từ đó xác định cấu hình tiền xử lý phù hợp cho bài toán phân lớp nhị phân.
- **Mục tiêu về mô hình hóa:** So sánh hai mô hình baseline là Logistic Regression và Random Forest trên cùng một thiết kế thực nghiệm để đánh giá khác biệt giữa mô hình tuyến tính dễ diễn giải và mô hình phi tuyến linh hoạt.
- **Mục tiêu về đánh giá:** Phân tích đầy đủ các chỉ số Accuracy, Precision, Recall, F1-score và ROC-AUC, đồng thời thảo luận trade-off giữa precision và recall khi thay đổi ngưỡng dự đoán theo định hướng sàng lọc nguy cơ.
- **Mục tiêu về tái lập:** Tổ chức thực nghiệm theo pipeline thống nhất và thông số cố định (`random_state`, tỷ lệ chia tập, cấu hình tiền xử lý), bảo đảm người đọc có thể tái tạo kết quả một cách nhất quán.

1.3 Câu hỏi nghiên cứu

Tương ứng với các mục tiêu nêu trên, nghiên cứu tập trung trả lời các câu hỏi sau:

1. Việc chuyển các giá trị 0 bất thường sang missing ẩn có giúp dữ liệu hợp lý hơn về mặt thống kê và có cải thiện chất lượng dự báo so với cách giữ nguyên dữ liệu thô hay không?
2. Trong các tổ hợp *imputer + scaler*, cấu hình nào mang lại sự cân bằng tốt nhất giữa độ ổn định của mô hình và hiệu năng dự báo trên dữ liệu chưa thấy?
3. Khi đặt trong cùng điều kiện thực nghiệm, Logistic Regression và Random Forest khác nhau như thế nào về khả năng tổng quát hóa, độ nhạy phát hiện lớp dương và mức độ ổn định giữa tập validation và test?
4. Khi thay đổi ngưỡng phân loại, trade-off giữa precision và recall biến thiên ra sao, và ngưỡng nào phù hợp hơn cho mục tiêu ưu tiên phát hiện sớm ca có nguy cơ?
5. Từ kết quả thực nghiệm, có thể rút ra khuyến nghị nào cho một quy trình baseline đáng tin cậy, làm nền cho các nghiên cứu mở rộng trong tương lai?

1.4 Đối tượng và phạm vi

Đối tượng nghiên cứu là bộ dữ liệu `pima-indians-diabetes.csv`, gồm 768 quan sát, 8 thuộc tính đầu vào dạng số và 1 biến mục tiêu nhị phân `outcome`. Các thuộc tính phản ánh thông tin nhân trắc và chỉ số sinh lý phổ biến như `glucose`, `blood_pressure`, `insulin`, `bmi`, `age`, cùng một số biến liên quan đến tiền sử.

Phạm vi nghiên cứu được xác định theo các chiều sau:

- **Phạm vi dữ liệu:** Chỉ sử dụng bộ dữ liệu Pima được cung cấp trong học phần, không kết hợp thêm nguồn dữ liệu bệnh án thực tế hoặc dữ liệu từ các hệ thống bệnh viện.
- **Phạm vi bài toán:** Tập trung vào phân lớp nhị phân (`outcome = 0/1`) cho mục tiêu sàng lọc nguy cơ; không thực hiện dự báo tiến triển theo thời gian và không xây dựng hệ thống chẩn đoán lâm sàng hoàn chỉnh.
- **Phạm vi phương pháp:** Ưu tiên các mô hình baseline có tính chuẩn mực trong học máy ứng dụng (Logistic Regression, Random Forest), kết hợp các kỹ thuật tiền xử lý phổ biến và dễ tái lập.

- **Phạm vi đánh giá:** Đánh giá trên các chỉ số phân lớp chuẩn và phân tích định lượng trade-off theo ngưỡng; không thực hiện kiểm định trên dữ liệu ngoại viện hoặc thử nghiệm triển khai thời gian thực.

Ngoài ra, nghiên cứu cũng xác định rõ các giới hạn: chưa đi sâu vào tối ưu siêu tham số quy mô lớn, chưa khảo sát các mô hình học sâu, chưa thực hiện hiệu chỉnh xác suất (probability calibration), và chưa đánh giá tác động công bằng mô hình theo từng nhóm dân số. Việc nêu rõ giới hạn giúp khoanh vùng đúng đóng góp của đề tài và tạo nền tảng cho định hướng phát triển ở các chương sau.

1.5 Phương pháp tổng quát

Toàn bộ nghiên cứu được triển khai bằng Python notebook theo một luồng kỹ thuật thống nhất, bảo đảm tính tái lập và khả năng kiểm tra chéo ở từng bước:

1. **Khảo sát dữ liệu ban đầu:** Nạp dữ liệu, kiểm tra kiểu dữ liệu, thống kê mô tả, tỷ lệ lớp, giá trị trùng lặp và các bất thường hiển nhiên.
2. **Xử lý missing ẩn theo ngữ cảnh y sinh:** Chuyển các giá trị 0 không hợp lý ở nhóm biến sinh lý sang giá trị thiếu để tránh làm sai lệch phân phối và ước lượng.
3. **Phân tích khám phá dữ liệu (EDA):** Trực quan hóa phân bố từng biến, phân tích tương quan giữa đặc trưng với *outcome*, và so sánh khác biệt giữa các nhóm lớp nhằm hình thành giả thuyết mô hình hóa.
4. **Thiết kế pipeline tiền xử lý:** Kết hợp có hệ thống giữa kỹ thuật nội suy thiếu dữ liệu và chuẩn hóa đặc trưng. Cách tổ chức theo pipeline giúp giảm nguy cơ rò rỉ dữ liệu và bảo đảm cùng một quy trình được áp dụng nhất quán giữa train, validation và test.
5. **Huấn luyện và so sánh mô hình baseline:** Triển khai các tổ hợp *imputer + scaler + model* theo cùng thiết kế, sau đó đánh giá trên nhiều chỉ số thay vì chỉ dựa vào một độ đo đơn lẻ.
6. **Phân tích ngưỡng và diễn giải kết quả:** Khảo sát độ nhạy của kết quả theo ngưỡng phân loại để lựa chọn cấu hình phù hợp hơn cho mục tiêu sàng lọc, đồng thời thảo luận ý nghĩa thực tiễn của các chỉ số đạt được.

Về mặt công cụ, nghiên cứu sử dụng hệ sinh thái Python và các thư viện chuẩn cho phân tích dữ liệu, trực quan hóa và học máy. Khung triển khai được xây dựng trên scikit-learn [3], trong khi nguyên lý mô hình hóa và đánh giá tham chiếu theo các tài

liệu kinh điển [4]. Cách tiếp cận này giúp cân bằng giữa tính học thuật và tính thực thi trong báo cáo.

1.6 Kết cấu báo cáo

Báo cáo được tổ chức thành 5 chương liên kết theo mạch từ tổng quan, cơ sở lý thuyết, triển khai thực nghiệm đến kết luận:

- **Chương 1 – Tổng quan vấn đề:** Trình bày bối cảnh, lý do chọn đề tài, mục tiêu, câu hỏi nghiên cứu, phạm vi thực hiện và phương pháp tổng quát.
- **Chương 2 – Cơ sở lý thuyết và nghiên cứu liên quan:** Hệ thống hóa các khái niệm nền tảng của phân tích dữ liệu và học máy trong bài toán phân lớp y sinh, đồng thời tóm lược các kỹ thuật được sử dụng.
- **Chương 3 – Dữ liệu và phương pháp đề xuất:** Mô tả chi tiết nguồn dữ liệu, đặc trưng đầu vào, quy trình kiểm tra chất lượng dữ liệu, thiết kế thực nghiệm và pipeline tiền xử lý.
- **Chương 4 – Thực nghiệm và kết quả đạt được:** Trình bày kết quả EDA, kết quả so sánh các cấu hình mô hình, phân tích định lượng theo chỉ số và thảo luận các điểm mạnh, điểm hạn chế.
- **Chương 5 – Kết luận và khuyến nghị:** Tổng kết đóng góp chính, nêu giới hạn của đề tài và đề xuất các hướng phát triển tiếp theo để nâng cao khả năng ứng dụng.

CHƯƠNG 2

Cơ sở lý thuyết và nghiên cứu liên quan

2.1 Tổng quan bài toán phân lớp trong dự đoán nguy cơ đái tháo đường

Bài toán dự đoán nguy cơ đái tháo đường trong nghiên cứu này được mô hình hóa dưới dạng phân lớp nhị phân: với mỗi quan sát lâm sàng, mô hình cần dự đoán nhãn *outcome* thuộc lớp âm tính (0) hoặc dương tính (1). Về bản chất, đây là bài toán học có giám sát (*supervised learning*), trong đó dữ liệu huấn luyện đã có sẵn nhãn mục tiêu.

Khác với các bài toán phân lớp ảnh hoặc văn bản, dữ liệu y sinh dạng bảng thường có số chiều không lớn nhưng chứa nhiều đặc điểm thống kê đặc thù: phân phối lệch, nhiễu đo lường, outlier, missing ẩn và tương quan chéo giữa các biến. Do vậy, hiệu quả mô hình không chỉ phụ thuộc vào thuật toán học máy mà còn phụ thuộc mạnh vào chất lượng tiền xử lý và thiết kế quy trình đánh giá.

Bộ dữ liệu *Pima Indians Diabetes* là một benchmark kinh điển trong học máy y sinh [1, 2], được sử dụng rộng rãi để kiểm chứng các chiến lược tiền xử lý và mô hình phân lớp. Việc lựa chọn bộ dữ liệu này giúp nghiên cứu đảm bảo tính so sánh, tính tái lập và phù hợp với mục tiêu xây dựng một baseline đáng tin cậy.

2.2 Phân tích khám phá dữ liệu (EDA)

Phân tích khám phá dữ liệu (*Exploratory Data Analysis – EDA*) là bước nền tảng trước khi huấn luyện mô hình. Mục tiêu của EDA là hiểu rõ cấu trúc dữ liệu, phát hiện bất thường, và hình thành giả thuyết ban đầu về mối quan hệ giữa biến đầu vào và biến mục tiêu. Trong bối cảnh y sinh, EDA còn đóng vai trò kiểm tra tính hợp lý của dữ liệu theo ngữ cảnh chuyên ngành, tránh diễn giải sai lệch.

Các thành phần EDA chính trong bài toán này bao gồm:

- **Thống kê mô tả:** giá trị trung bình, trung vị, độ lệch chuẩn, khoảng tứ phân vị và biên min-max cho từng biến.
- **Phân bố theo biến:** trực quan hóa histogram/boxplot để nhận diện phân phối lệch, đuôi dài và outlier.
- **Phân bố lớp mục tiêu:** đánh giá mức độ cân bằng giữa hai lớp *outcome* để dự báo rủi ro thiên lệch mô hình.
- **Tương quan và quan hệ đa biến:** xây dựng ma trận tương quan để xác định biến có liên hệ mạnh với *outcome*, đồng thời rà soát khả năng đa cộng tuyến.

Kết quả EDA không chỉ phục vụ mô tả dữ liệu, mà còn định hướng trực tiếp cho các quyết định kỹ thuật ở các bước sau: chọn chiến lược xử lý missing, chọn phương pháp chuẩn hóa, và xác định kỳ vọng hợp lý cho hiệu năng mô hình baseline.

2.3 Cơ sở lý thuyết tiền xử lý dữ liệu

2.3.1 Missing ẩn và chính sách *zero-as-missing*

Trong bộ dữ liệu Pima, một số biến sinh lý có giá trị 0 không hợp lý về mặt y học, điển hình là *glucose*, *blood_pressure*, *skin_thickness*, *insulin*, *bmi*. Những giá trị này thường phản ánh dữ liệu thiếu hoặc lỗi đo lường hơn là giá trị thực của bệnh nhân.

Nếu giữ nguyên các giá trị này như quan sát hợp lệ, các chỉ số thống kê có thể bị lệch đáng kể, kéo theo sai lệch ở bước học mô hình. Vì vậy, nghiên cứu áp dụng chính sách *zero-as-missing*: chuyển các giá trị 0 bất thường về dạng thiếu dữ liệu trước khi nội suy. Đây là một bước quan trọng để đưa dữ liệu về gần hơn với thực tế lâm sàng.

2.3.2 Các chiến lược nội suy thiếu dữ liệu

Sau khi xác định missing ẩn, nghiên cứu so sánh ba chiến lược nội suy phổ biến:

- **Median Imputation:** thay giá trị thiếu bằng trung vị của biến. Phương pháp này đơn giản, ổn định và ít nhạy cảm với outlier, phù hợp khi dữ liệu có phân phối lệch.
- **KNN Imputation:** ước lượng giá trị thiếu dựa trên các quan sát gần nhất trong không gian đặc trưng. Cách tiếp cận này có thể bảo toàn cấu trúc cục bộ của dữ liệu nhưng phụ thuộc vào lựa chọn khoảng cách và mức chuẩn hóa.

- **Iterative Imputation (MICE):** nội suy lặp bằng cách mô hình hóa từng biến thiếu dựa trên các biến còn lại. Phương pháp này tận dụng quan hệ đa biến tốt hơn, nhưng chi phí tính toán cao hơn và nhạy với cấu hình mô hình phụ trợ.

2.3.3 Chuẩn hóa đặc trưng

Do các biến đầu vào có thang đo khác nhau (ví dụ glucose, insulin, age), việc chuẩn hóa là cần thiết để tránh hiện tượng một số biến có độ lớn tuyệt đối chi phối quá trình học. Nghiên cứu khảo sát hai lựa chọn chuẩn hóa:

- **StandardScaler:** đưa dữ liệu về trung bình 0, độ lệch chuẩn 1, công thức

$$x' = \frac{x - \mu}{\sigma}$$

phù hợp khi dữ liệu gần phân phối chuẩn hoặc cần ổn định gradient.

- **MinMaxScaler:** ánh xạ dữ liệu về khoảng $[0, 1]$, công thức

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

phù hợp khi muốn giữ nguyên thứ tự và biên tương đối của biến.

Trong thực nghiệm, chuẩn hóa luôn được đặt trong pipeline để bảo đảm phép biến đổi được học từ tập train và áp dụng nhất quán cho validation/test, hạn chế rò rỉ dữ liệu.

2.4 Mô hình học máy baseline

2.4.1 Logistic Regression

Logistic Regression là mô hình phân lớp tuyến tính phổ biến, ước lượng xác suất thuộc lớp dương thông qua hàm sigmoid:

$$P(y = 1|x) = \sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$$

Ưu điểm của Logistic Regression là dễ diễn giải, tốc độ huấn luyện nhanh và thường hoạt động tốt trên dữ liệu tabular cỡ vừa. Trong bối cảnh nghiên cứu, mô hình này đóng vai trò chuẩn tham chiếu tuyến tính để so sánh với các mô hình phi tuyến.

2.4.2 Random Forest

Random Forest là phương pháp ensemble kết hợp nhiều cây quyết định được huấn luyện trên các mẫu bootstrap và tập đặc trưng ngẫu nhiên. Kết quả dự đoán cuối cùng được tổng hợp theo cơ chế bỏ phiếu đa số (classification). Nhờ cơ chế tổ hợp, Random Forest thường:

- giảm overfitting so với cây quyết định đơn lẻ;
- nắm bắt tốt quan hệ phi tuyến và tương tác giữa các biến;
- ít yêu cầu giả định phân phối dữ liệu;
- cung cấp chỉ báo *feature importance* phục vụ diễn giải.

Tuy nhiên, đổi lại mô hình có thể khó diễn giải hơn Logistic Regression và nhạy cảm với lựa chọn siêu tham số (số cây, độ sâu cây, tiêu chí chia nhánh).

2.5 Chỉ số đánh giá mô hình phân lớp

Đánh giá mô hình trong bài toán y sinh cần đa tiêu chí thay vì chỉ dựa trên một chỉ số đơn lẻ. Với ma trận nhầm lẫn gồm TP, TN, FP, FN , các chỉ số được sử dụng như sau:

- **Accuracy:**

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

đo tỷ lệ dự đoán đúng tổng quát.

- **Precision:**

$$\text{Precision} = \frac{TP}{TP + FP}$$

phản ánh mức độ tin cậy của dự đoán dương tính.

- **Recall (Sensitivity):**

$$\text{Recall} = \frac{TP}{TP + FN}$$

phản ánh khả năng phát hiện đúng ca dương tính thực sự.

- **F1-score:**

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

cân bằng giữa precision và recall.

- **ROC-AUC:** diện tích dưới đường cong ROC, đo khả năng phân biệt hai lớp trên nhiều ngưỡng khác nhau.

Trong bối cảnh sàng lọc nguy cơ, recall thường được ưu tiên để giảm bỏ sót ca bệnh tiềm năng; tuy nhiên precision cũng cần được theo dõi để tránh tăng quá nhiều cảnh báo sai. Vì vậy, nghiên cứu sử dụng đồng thời nhiều chỉ số để lựa chọn cấu hình phù hợp nhất.

2.6 Nghiên cứu liên quan

Nghiên cứu ứng dụng học máy cho bài toán dự đoán đái tháo đường đã được quan tâm từ sớm. Công trình của Smith và cộng sự [2] là một trong những nghiên cứu tiêu biểu sử dụng dữ liệu Pima để dự báo nguy cơ khởi phát bệnh, qua đó đặt nền tảng cho hướng tiếp cận dựa trên dữ liệu trong bối cảnh y sinh.

Trong các nghiên cứu sau này, bộ dữ liệu Pima tiếp tục được dùng rộng rãi để so sánh các kỹ thuật tiền xử lý và thuật toán phân lớp. Một xu hướng nhất quán là hiệu năng mô hình chịu ảnh hưởng lớn bởi chất lượng xử lý dữ liệu đầu vào, đặc biệt là cách xử lý missing, chuẩn hóa biến và chiến lược đánh giá theo ngưỡng. Nhiều nghiên cứu ghi nhận các mô hình phi tuyến như Random Forest có thể đạt độ chính xác cao hơn mô hình tuyến tính trong dữ liệu có tương tác biến phức tạp; ngược lại, Logistic Regression vẫn giữ vai trò quan trọng nhờ tính diễn giải và tính ổn định khi thiết lập baseline.

So với các công bố chỉ tập trung vào so sánh thuật toán, báo cáo này nhấn mạnh cách tiếp cận theo pipeline tái lập: kết hợp phân tích EDA, xử lý missing theo ngữ cảnh y sinh, so sánh nhiều cấu hình *imputer + scaler + model*, và phân tích trade-off chỉ số theo mục tiêu ứng dụng. Hướng tiếp cận này phù hợp với tinh thần thực nghiệm chặt chẽ trong các tài liệu học máy kinh điển [4] và triển khai thực tiễn trên hệ sinh thái scikit-learn [3].

CHƯƠNG 3

Dữ liệu và phương pháp đề xuất

3.1 Nguồn dữ liệu

Dữ liệu được sử dụng trong bài này gồm:

- `Lab_03/data/pima-indians-diabetes.csv`
- `Lab_03/data/pima-indians-diabetes.names`

Theo file mô tả, bộ dữ liệu có 768 quan sát, 8 thuộc tính số học và 1 biến mục tiêu `outcome`.

3.2 Mô tả thuộc tính

Bảng 3.1: Mô tả các thuộc tính trong bộ dữ liệu Pima


Thuộc tính	Ý nghĩa
<code>pregnancies</code>	Số lần mang thai
<code>glucose</code>	Nồng độ glucose huyết tương (2h OGTT)
<code>blood_pressure</code>	Huyết áp tâm trương (mm Hg)
<code>skin_thickness</code>	Độ dày nếp da cơ tay sau (mm)
<code>insulin</code>	Nồng độ insulin huyết thanh (2h)
<code>bmi</code>	Chỉ số khối cơ thể
<code>diabetes_pedigree_function</code>	Hệ số tiền sử gia đình
<code>age</code>	Tuổi
<code>outcome</code>	Nhãn phân lớp (0/1)

3.3 Kiểm tra chất lượng dữ liệu

Kết quả tái lập từ notebook cho thấy **không có dòng trùng lặp** và **không có NaN tường minh** trong CSV gốc. Tuy nhiên, nhiều cột sinh lý chứa giá trị 0 bất thường, được xem như missing ẩn theo chính sách *zero-as-missing*.

Bảng 3.2: Tỷ lệ giá trị 0 ở các biến sinh lý trọng điểm

Biến	Số lượng 0	Tỷ lệ (%)
insulin	374	48.70
skin_thickness	227	29.56
blood_pressure	35	4.56
bmi	11	1.43
glucose	5	0.65



Hình 3.1: Thống kê missing ẩn và giá trị 0 theo thuộc tính

3.4 Thiết kế thực nghiệm và tái lập

Thiết kế thực nghiệm giữ nguyên theo notebook để đảm bảo tái lập:

1. Chuyển 0 -> NaN cho các biến sinh lý bất thường.
2. Chia dữ liệu theo tỉ lệ train/validation/test = 60/20/20 với `stratify` và `random_state=42`.
3. Tạo pipeline kết hợp *imputer + scaler + model*.

4. So sánh 12 tổ hợp cấu hình (3 imputer x 2 scaler x 2 model).


Bảng 3.3: Tỷ lệ chia tập và tỷ lệ lớp dương

Tập dữ liệu	Số mẫu	Tỷ lệ outcome=1
Train	460	0.3478
Validation	154	0.3506
Test	154	0.3506


3.5 EDA chuyên sâu theo nhóm biến

Để phản ánh đầy đủ các phân tích trong notebook, báo cáo bổ sung các hình chuyên sâu:


- Nhóm Age: tương quan theo biến và hồi quy Age-Glucose.
- Nhóm DPF: phân phối theo outcome và tỷ lệ mắc bệnh theo quartile.
- Nhóm Glucose-BMI-Insulin: phân tán theo outcome sau khi áp dụng zero-masked.



Hình 3.2: Tương quan của Age và quan hệ hồi quy Age-Glucose




Hình 3.3: Phân phối DPF theo outcome và các scatter trọng điểm



Hình 3.4: Quan hệ Glucose-BMI-Insulin theo outcome

3.6 Quy trình tiền xử lý đề xuất



Hình 3.5: Pipeline tiền xử lý và đánh giá mô hình

Ngoài ma trận tương quan đầy đủ, notebook còn xuất bảng tương quan theo **outcome** để ưu tiên biến khi diễn giải:

Bảng 3.4: Tương quan của biến đầu vào với outcome (zero-masked)

Biến	Corr với outcome
glucose	0.4947
bmi	0.3137
insulin	0.3035
skin_thickness	0.2595
age	0.2384
pregnancies	0.2219

CHƯƠNG 4

Thực nghiệm và kết quả đạt được

4.1 Thiết lập thực nghiệm

4.1.1 Chiến lược chia dữ liệu

Dữ liệu được chia theo tỉ lệ 60/20/20 với *stratify* trên nhãn `outcome` để giữ ổn định tỉ lệ lớp dương tính giữa các tập.

- Train: 460 mẫu
- Validation: 154 mẫu
- Test: 154 mẫu

4.1.2 Tổ hợp cấu hình được so sánh


- Imputation: Median, KNN, Iterative(MICE)
- Scaling: StandardScaler, MinMaxScaler
- Model: Logistic Regression, Random Forest

Tổng cộng 12 cấu hình được đánh giá với cùng một seed và cùng một split để đảm bảo công bằng.

4.2 Kết quả EDA chính

4.2.1 Tổng quan bộ dữ liệu


Bộ dữ liệu có 768 dòng và 9 cột (8 biến đầu vào và 1 biến đầu ra). Phân bố lớp: class 0 = 500 mẫu (65.1%), class 1 = 268 mẫu (34.9%).



Hình 4.1: Phân bố lớp trong dữ liệu Pima

4.2.2 Nhận xét về quality data

Số dòng trùng lặp bằng 0. Các cột có số lượng 0 cao nhất là `insulin` và `skin_thickness`, do đó cần xử lý missing ẩn trước huấn luyện.



Hình 4.2: Ma trận tương quan sau khi áp dụng zero-as-missing

4.3 So sánh mô hình và chiến lược tiền xử lý

4.3.1 Bảng tổng hợp đầy đủ 12 cấu hình


Khác với bản rút gọn trước đây (top-5), bảng dưới đây tổng hợp đầy đủ 12 tổ hợp (*imputer* x *scaler* x *model*) với các chỉ số quan trọng trên validation và test.

Bảng 4.1: Kết quả đầy đủ 12 cấu hình tiền xử lý + mô hình

Imputer	Scaler	Model	Val AUC	Test AUC	Acc	Prec	Rec	F1
KNN	MinMax	Random Forest	0.8700	0.8170	0.7403	0.6458	0.5741	0.6078
KNN	Standard	Random Forest	0.8690	0.8168	0.7403	0.6458	0.5741	0.6078
Median	Standard	Logistic Regression	0.8498	0.8167	0.7078	0.6000	0.5000	0.5455
Iterative	MinMax	Random Forest	0.8572	0.8156	0.7273	0.6250	0.5556	0.5882
KNN	Standard	Logistic Regression	0.8526	0.8154	0.7143	0.6136	0.5000	0.5510
Iterative	Standard	Random Forest	0.8556	0.8153	0.7273	0.6250	0.5556	0.5882
Median	MinMax	Random Forest	0.8596	0.8149	0.7338	0.6383	0.5556	0.5941
Iterative	Standard	Logistic Regression	0.8476	0.8148	0.7143	0.6190	0.4815	0.5417
Median	Standard	Random Forest	0.8604	0.8136	0.7338	0.6383	0.5556	0.5941
KNN	MinMax	Logistic Regression	0.8730	0.8117	0.7208	0.6341	0.4815	0.5474
Median	MinMax	Logistic Regression	0.8659	0.8098	0.7273	0.6500	0.4815	0.5532
Iterative	MinMax	Logistic Regression	0.8709	0.8093	0.7208	0.6279	0.5000	0.5567

4.3.2 Xếp hạng theo ROC-AUC và F1

Các cấu hình dẫn đầu tiếp tục tập trung ở nhóm **KNN Imputer + Random Forest**, cho thấy dữ liệu Pima hưởng lợi từ nội suy theo lân cận khi kết hợp với mô hình phi tuyến.



Hình 4.3: So sánh các cấu hình tiền xử lý + mô hình

4.3.3 Cấu hình đề xuất

Cấu hình tốt nhất theo test ROC-AUC: **KNN Imputer + MinMaxScaler + Random Forest**.

- Validation ROC-AUC: 0.8700
- Test ROC-AUC: 0.8170
- Test Accuracy: 0.7403
- Test F1: 0.6078
- Test Precision: 0.6458
- Test Recall: 0.5741

4.3.4 So sánh theo họ mô hình (Logistic vs Random Forest)


Khi gộp trung bình theo họ mô hình trên toàn bộ 12 cấu hình:

- **Logistic Regression:** test ROC-AUC trung bình 0.8129, test F1 trung bình 0.5492.
- **Random Forest:** test ROC-AUC trung bình 0.8155, test F1 trung bình 0.5967.

Random Forest nhỉnh hơn nhẹ về AUC và rõ hơn về F1, phù hợp với mục tiêu cân bằng precision/recall.

4.4 Phân tích sai số và trade-off

4.4.1 Confusion matrix và ROC




Hình 4.4: Confusion matrix của cấu hình được chọn

Với ngưỡng mặc định 0.5, confusion matrix của cấu hình tốt nhất cho thấy:

- $TN = 86$, $FP = 17$
- $FN = 23$, $TP = 31$

Mô hình vẫn bỏ sót một phần ca dương (FN), do đó việc điều chỉnh threshold là cần thiết khi bài toán ưu tiên sàng lọc.



Hình 4.5: Đường cong ROC cho các cấu hình dẫn đầu

4.4.2 Trade-off theo threshold

Notebook quét ngưỡng từ 0.30 đến 0.70 (bước 0.05), kết quả như Bảng 4.2.

Bảng 4.2: Precision-Recall-F1 theo ngưỡng của cấu hình tốt nhất

Threshold	Precision	Recall	F1
0.30	0.5789	0.8148	0.6769
0.35	0.5970	0.7407	0.6612
0.40	0.6167	0.6852	0.6491
0.45	0.6296	0.6296	0.6296
0.50	0.6458	0.5741	0.6078
0.55	0.6429	0.5000	0.5625
0.60	0.6944	0.4630	0.5556
0.65	0.7188	0.4259	0.5349
0.70	0.7500	0.3333	0.4615

Ngưỡng 0.50 chưa tối ưu theo F1; ngưỡng 0.30 cho F1 cao nhất (0.6769) và recall cao (0.8148), phù hợp kịch bản ưu tiên phát hiện ca dương để sàng lọc ban đầu.

4.4.3 Nhận định overfitting/underfitting

Chênh lệch `val_roc_auc` - `test_roc_auc` xấp xỉ 0.053. Điều này cho thấy dấu hiệu overfitting nhẹ đến trung bình, cần tiếp tục kiểm chứng bằng cross-validation và tuning hệ thống trong bước tiếp theo.

CHƯƠNG 5

Kết luận và khuyến nghị

5.1 Kết luận chung

Báo cáo đã hoàn thành quy trình rút trích dữ liệu và tiền xử lý cho bài toán dự đoán tiểu đường trên bộ dữ liệu Pima. Kết quả cho thấy việc kết hợp *zero-as-missing* với pipeline imputation + scaling là cần thiết để nâng cao tính nhất quán của dữ liệu và hiệu năng mô hình baseline.

5.2 Tóm tắt kết quả đạt được

- Hoàn thiện notebook phân tích theo hướng báo cáo học thuật.
- So sánh 12 cấu hình tiền xử lý và mô hình trên cùng điều kiện chia dữ liệu.
- Đề xuất cấu hình KNN + MinMax + Random Forest cho kết quả test ROC-AUC cao nhất.
- Bổ sung phân tích confusion matrix, ROC và threshold trade-off.

5.3 Trả lời trực tiếp câu hỏi nghiên cứu (Q1/Q2/Q3)

- **Q1 – Zero-as-missing có hữu ích không?** Có. Việc chuyển 0 -> NaN cho các biến sinh lý giúp mô hình đạt mức AUC ổn định (test ROC-AUC quanh 0.81) thay vì dễ nhiễu từ giá trị 0 phi sinh lý.
- **Q2 – Tổ hợp preprocessing/model nào tốt nhất?** Cấu hình tốt nhất là **KNN + MinMax + Random Forest** với `val_roc_auc=0.8700`, `test_roc_auc=0.8170`, `test_accuracy=0.7403`.

- **Q3 – Trade-off precision/recall thay đổi ra sao theo threshold?** Khi giảm ngưỡng từ 0.50 xuống 0.30, recall tăng mạnh từ 0.5741 lên 0.8148, trong khi precision giảm từ 0.6458 xuống 0.5789; F1 cải thiện từ 0.6078 lên 0.6769.

5.4 Đóng góp của đề tài

- Chuẩn hóa quy trình thực hành từ EDA đến đánh giá mô hình baseline.
- Cung cấp khung đánh giá dễ tái lập cho các bài toán phân lớp y sinh tương tự.
- Tăng tính báo cáo hóa của notebook để phục vụ trình bày học phần.

5.5 Hạn chế nghiên cứu

1. Quy mô dữ liệu còn nhỏ (768 mẫu), chưa đại diện cho nhiều quần thể bệnh nhân.
2. Giả định *zero-as-missing* có thể gây sai lệch nếu tồn tại trường hợp đo thực sự bằng 0.
3. Đánh giá hiện tại dựa trên một lần chia train/validation/test, chưa có CV lặp lại.
4. Chưa tiến hành tuning tham số hệ thống và calibration xác suất.

5.6 Hướng phát triển và kiến nghị

1. Áp dụng Stratified K-Fold CV để kiểm chứng độ ổn định kết quả.
2. Mở rộng tuning tham số cho Logistic Regression và Random Forest.
3. Thử nghiệm thêm các mô hình boosting (XGBoost/LightGBM) và kỹ thuật cân bằng lớp.
4. Mở rộng bộ dữ liệu và kiểm tra external validity trên nguồn độc lập.
5. Đóng gói pipeline suy luận và tạo báo cáo tự động để tăng khả năng triển khai.

Tài liệu tham khảo

- [1] National Institute of Diabetes and Digestive and Kidney Diseases. Pima indians diabetes database, 1990. UCI-style dataset description distributed with course materials.
- [2] J. W. Smith, J. E. Everhart, W. C. Dickson, W. C. Knowler, and R. S. Johannes. Using the adap learning algorithm to forecast the onset of diabetes mellitus. *Proceedings of the Symposium on Computer Applications and Medical Care*, pages 261–265, 1988.
- [3] Fabian Pedregosa et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [4] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2 edition, 2009.