

TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO TIỂU LUẬN
MÔN PHÂN TÍCH DỮ LIỆU

ĐỀ TÀI

RÚT TRÍCH DỮ LIỆU VÀ TIỀN XỬ LÝ
DỮ LIỆU PIMA INDIANS DIABETES

Giảng viên hướng dẫn:

Nhóm thực hiện: Nhom01_SGU26_ML

Học phần: Học phần thay thế khóa luận

Phân công thành viên

Thành viên	Nhiệm vụ chính	Tỷ lệ
Chibang	Tổng hợp notebook, xây dựng pipeline tiền xử lý, tổng hợp báo cáo	25%
Duybao	Hỗ trợ kiểm tra notebook, đối chiếu kết quả và markdown diễn giải	25%
Tranhuyvu	Phân tích sâu cho nhóm biến BMI/Insulin, góp ý trực quan hóa	25%
Truongphat	Phân tích sâu cho nhóm biến Age/DPF, góp ý diễn giải kết quả	25%

Nhận xét của giảng viên

Lời mở đầu

Báo cáo này trình bày kết quả thực hiện bài tập Lab 03 với dữ liệu Pima Indians Diabetes. Nhóm tập trung vào hai mục tiêu: (1) xây dựng quy trình rút trích và tiền xử lý dữ liệu có thể tái lập; (2) đánh giá các chiến lược tiền xử lý dưới góc nhìn mô hình học máy baseline.

Lời cảm ơn

Nhóm xin chân thành cảm ơn giảng viên hướng dẫn đã cung cấp yêu cầu, tài liệu tham khảo và những góp ý quan trọng để nhóm hoàn thiện notebook và báo cáo.

Mục lục

Phân công thành viên	1
Nhận xét của giảng viên	2
Lời mở đầu	3
Lời cảm ơn	4
1 Tổng quan vấn đề	9
1.1 Lý do chọn đề tài	9
1.2 Mục tiêu nghiên cứu	9
1.3 Câu hỏi nghiên cứu	9
1.4 Đối tượng và phạm vi	10
1.5 Phương pháp tổng quát	10
1.6 Kết cấu báo cáo	10
2 Cơ sở lý thuyết và nghiên cứu liên quan	11
2.1 Tổng quan phân tích dữ liệu trong bài toán phân lớp	11
2.2 Phân tích khám phá dữ liệu (EDA)	11
2.3 Xử lý missing data	11
2.4 Chuẩn hóa dữ liệu	12
2.5 Chỉ số đánh giá mô hình	12
2.6 Mô hình baseline	12
3 Dữ liệu và phương pháp đề xuất	13
3.1 Nguồn dữ liệu	13
3.2 Mô tả thuộc tính	13

3.3	Kiểm tra chất lượng dữ liệu	14
3.4	Quy trình tiền xử lý đề xuất	14
4	Thực nghiệm và kết quả đạt được	16
4.1	Thiết lập thực nghiệm	16
4.1.1	Chiến lược chia dữ liệu	16
4.1.2	Tổ hợp cấu hình được so sánh	16
4.2	Kết quả EDA chính	16
4.2.1	Tổng quan bộ dữ liệu	16
4.2.2	Nhận xét về quality data	17
4.3	So sánh mô hình và chiến lược tiền xử lý	18
4.3.1	Xếp hạng theo ROC-AUC	18
4.3.2	Cấu hình đề xuất	19
4.4	Phân tích sai số và trade-off	19
4.4.1	Confusion matrix và ROC	19
4.4.2	Trade-off theo threshold	20
4.4.3	Nhận định overfitting/underfitting	20
5	Kết luận và khuyến nghị	21
5.1	Kết luận chung	21
5.2	Tóm tắt kết quả đạt được	21
5.3	Đóng góp của đề tài	21
5.4	Hạn chế nghiên cứu	22
5.5	Hướng phát triển và kiến nghị	22

Danh sách hình vẽ

3.1	Thống kê missing ẩn và giá trị 0 theo thuộc tính	14
3.2	Pipeline tiền xử lý và đánh giá mô hình	15
4.1	Phân bố lớp trong dữ liệu Pima	17
4.2	Ma trận tương quan sau khi áp dụng zero-as-missing	17
4.3	So sánh các cấu hình tiền xử lý + mô hình	18
4.4	Confusion matrix của cấu hình được chọn	19
4.5	Đường cong ROC cho các cấu hình dẫn đầu	20

Danh sách bảng

3.1	Mô tả các thuộc tính trong bộ dữ liệu Pima	13
4.1	Top cấu hình theo test ROC-AUC (trích từ notebook)	18

CHƯƠNG 1

Tổng quan vấn đề

1.1 Lý do chọn đề tài

Bệnh tiểu đường là một trong những bệnh mạn tính phổ biến và có xu hướng gia tăng. Việc xây dựng mô hình hỗ trợ dự đoán nguy cơ dựa trên dữ liệu y sinh có ý nghĩa thực tiễn trong sàng lọc sớm. Bộ dữ liệu Pima Indians Diabetes được sử dụng rộng rãi trong giáo dục và nghiên cứu vì có cấu trúc gọn, dễ tái lập và phù hợp để trình bày đầy đủ quy trình rút trích dữ liệu và tiền xử lý.

1.2 Mục tiêu nghiên cứu

- Xây dựng quy trình phân tích và tiền xử lý dữ liệu Pima có thể tái lập.
- Đánh giá ảnh hưởng của các chiến lược xử lý missing (Median, KNN, Iterative/MICE) và chuẩn hóa (StandardScaler, MinMaxScaler).
- So sánh hiệu năng giữa hai mô hình baseline: Logistic Regression và Random Forest.

1.3 Câu hỏi nghiên cứu

1. Chính sách *zero-as-missing* có cải thiện tính hợp lý thống kê và kết quả mô hình hay không?
2. Tổ hợp *imputer + scaler + model* nào phù hợp nhất với dữ liệu Pima trong điều kiện baseline?
3. Trade-off giữa precision và recall thay đổi như thế nào khi điều chỉnh threshold?

1.4 Đối tượng và phạm vi

Đối tượng nghiên cứu là bộ dữ liệu `pima-indians-diabetes.csv` (768 mẫu, 8 thuộc tính đầu vào và 1 nhãn đầu ra). Báo cáo giới hạn trong phạm vi xử lý dữ liệu, EDA và đánh giá baseline; chưa mở rộng sang hyperparameter tuning toàn diện hoặc bộ dữ liệu ngoài.

1.5 Phương pháp tổng quát

Nhóm sử dụng Python notebook để triển khai toàn bộ quy trình: nạp dữ liệu, phân tích mô tả, làm sạch dữ liệu, tạo pipeline tiền xử lý, chia tập train/validation/test và so sánh định lượng.

1.6 Kết cấu báo cáo

Báo cáo gồm 5 chương:

- Chương 1: Tổng quan vấn đề.
- Chương 2: Cơ sở lý thuyết và các khái niệm liên quan.
- Chương 3: Dữ liệu và phương pháp đề xuất.
- Chương 4: Thực nghiệm và kết quả đạt được.
- Chương 5: Kết luận và khuyến nghị.

CHƯƠNG 2

Cơ sở lý thuyết và nghiên cứu liên quan

2.1 Tổng quan phân tích dữ liệu trong bài toán phân lớp

Với bài toán phân lớp nhị phân, quy trình phân tích dữ liệu thường gồm: (1) kiểm tra chất lượng dữ liệu; (2) phân tích mô tả và trực quan hóa; (3) xử lý missing/outlier; (4) xây dựng và đánh giá mô hình. Bộ dữ liệu Pima là một benchmark phổ biến trong công bố học máy y sinh [1, 2].

2.2 Phân tích khám phá dữ liệu (EDA)

EDA giúp xác định tính chất dữ liệu trước khi huấn luyện:

- **Thống kê mô tả:** trung bình, độ lệch chuẩn, quartile.
- **Phân bố lớp:** mức độ cân bằng giữa lớp âm và dương.
- **Tương quan:** xác định biến có liên hệ mạnh với biến mục tiêu.

2.3 Xử lý missing data

Trong bộ Pima, một số biến y sinh có giá trị 0 không hợp lý về sinh lý (*glucose*, *blood_pressure*, *skin_thickness*, *insulin*, *bmi*). Do đó, báo cáo áp dụng quy ước *zero-as-missing* và so sánh 3 chiến lược nội suy:

- **Median Imputation:** đơn giản, bền vững với phân bố lệch.
- **KNN Imputation:** nội suy dựa trên mẫu lân cận.
- **Iterative Imputation (MICE):** nội suy lặp dựa trên quan hệ giữa các biến.

2.4 Chuẩn hóa dữ liệu

Do thang đo các biến khác nhau, báo cáo so sánh:

- **StandardScaler**: đưa về trung bình 0, độ lệch chuẩn 1.
- **MinMaxScaler**: đưa về khoảng $[0,1]$.

Bước này giúp mô hình học máy (đặc biệt mô hình dựa trên khoảng cách/gradient) hoạt động ổn định và công bằng hơn giữa các biến.

2.5 Chỉ số đánh giá mô hình

Báo cáo sử dụng các chỉ số:

- **Accuracy**: tỷ lệ dự đoán đúng tổng quát.
- **Precision**: độ chính xác của dự đoán dương tính.
- **Recall**: khả năng phát hiện dương tính thực tế.
- **F1-score**: cân bằng giữa precision và recall.
- **ROC-AUC**: năng lực phân biệt hai lớp trên nhiều threshold.

2.6 Mô hình baseline

- **Logistic Regression**: mô hình tuyến tính để diễn giải và làm mốc so sánh.
- **Random Forest**: mô hình phi tuyến, mạnh trong bối cảnh quan hệ biến phức tạp.

Khung triển khai được xây dựng trên thư viện scikit-learn [3], trong khi các nguyên lý đánh giá và mô hình hóa tham khảo theo tài liệu kinh điển [4].

CHƯƠNG 3

Dữ liệu và phương pháp đề xuất

3.1 Nguồn dữ liệu

Dữ liệu được sử dụng trong bài này gồm:

- `Lab_03/data/pima-indians-diabetes.csv`
- `Lab_03/data/pima-indians-diabetes.names`

Theo file mô tả, bộ dữ liệu có 768 quan sát, 8 thuộc tính số học và 1 biến mục tiêu `outcome`.

3.2 Mô tả thuộc tính


Bảng 3.1: Mô tả các thuộc tính trong bộ dữ liệu Pima

Thuộc tính	Ý nghĩa
<code>pregnancies</code>	Số lần mang thai
<code>glucose</code>	Nồng độ glucose huyết tương (2h OGTT)
<code>blood_pressure</code>	Huyết áp tâm trương (mm Hg)
<code>skin_thickness</code>	Độ dày nếp da cơ tay sau (mm)
<code>insulin</code>	Nồng độ insulin huyết thanh (2h)
<code>bmi</code>	Chỉ số khối cơ thể
<code>diabetes_pedigree_function</code>	Hệ số tiền sử gia đình
<code>age</code>	Tuổi
<code>outcome</code>	Nhãn phân lớp (0/1)

3.3 Kiểm tra chất lượng dữ liệu

Kết quả từ notebook cho thấy:

- Số dòng trùng lặp: 0.
- Không có NaN tường minh trong CSV gốc, nhưng có nhiều giá trị 0 bất thường sinh lý.
- Các cột có tỷ lệ 0 cao: `insulin` và `skin_thickness`.



Hình 3.1: Thống kê missing ẩn và giá trị 0 theo thuộc tính

3.4 Quy trình tiền xử lý đề xuất

Quy trình được đề xuất và triển khai trong notebook:

1. Chuyển 0 -> NaN cho các biến sinh lý bất thường.
2. Chia dữ liệu theo tỉ lệ train/validation/test = 60/20/20 (stratified).
3. Tạo pipeline kết hợp *imputer* + *scaler* + *model*.
4. So sánh 12 tổ hợp cấu hình (3 imputer x 2 scaler x 2 model).

Pipeline tiền xử lý và đánh giá mô hình (Lab 03)



Hình 3.2: Pipeline tiền xử lý và đánh giá mô hình

CHƯƠNG 4

Thực nghiệm và kết quả đạt được

4.1 Thiết lập thực nghiệm

4.1.1 Chiến lược chia dữ liệu

Dữ liệu được chia theo tỉ lệ 60/20/20 với *stratify* trên nhãn `outcome` để giữ ổn định tỉ lệ lớp dương tính giữa các tập.

- Train: 460 mẫu
- Validation: 154 mẫu
- Test: 154 mẫu

4.1.2 Tổ hợp cấu hình được so sánh


- Imputation: Median, KNN, Iterative(MICE)
- Scaling: StandardScaler, MinMaxScaler
- Model: Logistic Regression, Random Forest

Tổng cộng 12 cấu hình được đánh giá với cùng một seed và cùng một split để đảm bảo công bằng.

4.2 Kết quả EDA chính

4.2.1 Tổng quan bộ dữ liệu


Bộ dữ liệu có 768 dòng và 9 cột (8 biến đầu vào và 1 biến đầu ra). Phân bố lớp: class 0 = 500 mẫu (65.1%), class 1 = 268 mẫu (34.9%).



Hình 4.1: Phân bố lớp trong dữ liệu Pima

4.2.2 Nhận xét về quality data

Số dòng trùng lặp bằng 0. Các cột có số lượng 0 cao nhất là `insulin` và `skin_thickness`, do đó cần xử lý missing ẩn trước huấn luyện.



Hình 4.2: Ma trận tương quan sau khi áp dụng zero-as-missing


4.3 So sánh mô hình và chiến lược tiền xử lý

4.3.1 Xếp hạng theo ROC-AUC

Kết quả trong notebook cho thấy các cấu hình dẫn đầu (theo test ROC-AUC) tập trung ở tổ hợp KNN imputer + Random Forest.

Bảng 4.1: Top cấu hình theo test ROC-AUC (trích từ notebook)

Imputer	Scaler	Model	Test ROC-AUC
KNN	MinMax	Random Forest	0.8170
KNN	Standard	Random Forest	0.8168
Median	Standard	Logistic Regression	0.8167
Iterative	MinMax	Random Forest	0.8156
KNN	Standard	Logistic Regression	0.8154



Hình 4.3: So sánh các cấu hình tiền xử lý + mô hình


4.3.2 Cấu hình đề xuất

Cấu hình tốt nhất theo test ROC-AUC: **KNN Imputer + MinMaxScaler + Random Forest**.


- Validation ROC-AUC: 0.8700
- Test ROC-AUC: 0.8170
- Test F1: 0.6078
- Test Precision: 0.6458
- Test Recall: 0.5741

4.4 Phân tích sai số và trade-off

4.4.1 Confusion matrix và ROC



Hình 4.4: Confusion matrix của cấu hình được chọn



Hình 4.5: Đường cong ROC cho các cấu hình dẫn đầu

4.4.2 Trade-off theo threshold

Notebook đã thực hiện quét threshold và chỉ ra rằng threshold 0.50 chưa chắc tối ưu. Điểm cân bằng F1 tốt nhất trong quá trình quét nằm quanh threshold xấp xỉ 0.30, cho thấy nếu ưu tiên phát hiện ca dương tính thì có thể đánh đổi precision để tăng recall.

4.4.3 Nhận định overfitting/underfitting

Chênh lệch `val_roc_auc` - `test_roc_auc` xấp xỉ 0.053. Điều này cho thấy dấu hiệu overfitting nhẹ đến trung bình, cần tiếp tục kiểm chứng bằng cross-validation và tuning hệ thống trong bước tiếp theo.

CHƯƠNG 5

Kết luận và khuyến nghị

5.1 Kết luận chung

Báo cáo đã hoàn thành quy trình rút trích dữ liệu và tiền xử lý cho bài toán dự đoán tiểu đường trên bộ dữ liệu Pima. Kết quả cho thấy việc kết hợp *zero-as-missing* với pipeline imputation + scaling là cần thiết để nâng cao tính nhất quán của dữ liệu và hiệu năng mô hình baseline.

5.2 Tóm tắt kết quả đạt được

- Hoàn thiện notebook phân tích theo hướng báo cáo học thuật.
- So sánh 12 cấu hình tiền xử lý và mô hình trên cùng điều kiện chia dữ liệu.
- Đề xuất cấu hình KNN + MinMax + Random Forest cho kết quả test ROC-AUC cao nhất.
- Bổ sung phân tích confusion matrix, ROC và threshold trade-off.

5.3 Đóng góp của đề tài

- Chuẩn hóa quy trình thực hành từ EDA đến đánh giá mô hình baseline.
- Cung cấp khung đánh giá dễ tái lập cho các bài toán phân lớp y sinh tương tự.
- Tăng tính báo cáo hóa của notebook để phục vụ trình bày học phần.

5.4 Hạn chế nghiên cứu

1. Quy mô dữ liệu còn nhỏ (768 mẫu), chưa đại diện cho nhiều quần thể bệnh nhân.
2. Giả định *zero-as-missing* có thể gây sai lệch nếu tồn tại trường hợp đo thực sự bằng 0.
3. Đánh giá hiện tại dựa trên một lần chia train/validation/test, chưa có CV lặp lại.
4. Chưa tiến hành tuning tham số hệ thống và calibration xác suất.

5.5 Hướng phát triển và kiến nghị

1. Áp dụng Stratified K-Fold CV để kiểm chứng độ ổn định kết quả.
2. Mở rộng tuning tham số cho Logistic Regression và Random Forest.
3. Thử nghiệm thêm các mô hình boosting (XGBoost/LightGBM) và kỹ thuật cân bằng lớp.
4. Mở rộng bộ dữ liệu và kiểm tra external validity trên nguồn độc lập.
5. Đóng gói pipeline suy luận và tạo báo cáo tự động để tăng khả năng triển khai.

Tài liệu tham khảo

- [1] National Institute of Diabetes and Digestive and Kidney Diseases. Pima indians diabetes database, 1990. UCI-style dataset description distributed with course materials.
- [2] J. W. Smith, J. E. Everhart, W. C. Dickson, W. C. Knowler, and R. S. Johannes. Using the adap learning algorithm to forecast the onset of diabetes mellitus. *Proceedings of the Symposium on Computer Applications and Medical Care*, pages 261–265, 1988.
- [3] Fabian Pedregosa et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [4] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2 edition, 2009.