

TRUONG DAI HOC SAI GON
KHOA CONG NGHE THONG TIN

**BAO CAO TIEU LUAN
MON PHAN TICH DU LIEU**

DE TAI

**RUT TRICH DU LIEU VA TIEN XU LY
DU LIEU PIMA INDIANS DIABETES**

Giang vien huong dan:

Nhom thuc hien: Nhom01_SGU26_ML

Hoc phan: Hoc phan thay the khoa luan

Phan cong thanh vien

Thanh vien	Nhiem vu chinh	Ty le
Chibang	Tong hop notebook, xay dung pipeline tien xu ly, tong hop bao cao	25%
Duybao	Ho trokiem tra notebook, doi chieu ket qua va markdown dien giai	25%
Tranhuyvu	Phan tich sau cho nhom bien BMI/Insulin, gop y truc quan hoa	25%
Truongphat	Phan tich sau cho nhom bien Age/DPF, gop y dien giai ket qua	25%

Nhan xet cua giang vien

Loi mo dau

Bao cao nay trinh bay ket qua thuc hien bai tap Lab 03 voi du lieu Pima Indians Diabetes. Nhom tap trung vao hai muc tieu: (1) xay dung quy trinh rut trich va tien xu ly du lieu co the tai lap; (2) danh gia cac chien luoc tien xu ly duoi goc nhin mo hinh hoc may baseline.

Loi cam on

Nhom xin chan thanh cam on giang vien huong dan da cung cap yeu cau, tai lieu tham khao va nhung gop y quan trong de nhom hoan thien notebook va bao cao.

Contents

Phan cong thanh vien	1
Nhan xet cua giang vien	2
Loi mo dau	3
Loi cam on	4
1 Tong quan van de	9
1.1 Ly do chon de tai	9
1.2 Muc tieu nghien cuu	9
1.3 Cau hoi nghien cuu	9
1.4 Doi tuong va pham vi	10
1.5 Phuong phap tong quat	10
1.6 Ket cau bao cao	10
2 Co so ly thuyet va nghien cuu lien quan	11
2.1 Tong quan phan tich du lieu trong bai toan phan lop	11
2.2 Phan tich kham pha du lieu (EDA)	11
2.3 Xu ly missing data	11
2.4 Chuan hoa du lieu	12
2.5 Chi so danh gia mo hinh	12
2.6 Mo hinh baseline	12
3 Du lieu va phuong phap de xuat	13
3.1 Nguon du lieu	13
3.2 Mo ta thuoc tinh	13

3.3	Kiem tra chat luong du lieu	14
3.4	Quy trình tien xu ly de xuat	14
4	Thuc nghiem va ket qua dat duoc	16
4.1	Thiet lap thuc nghiem	16
4.1.1	Chien luoc chia du lieu	16
4.1.2	To hop cau hinh duoc so sanh	16
4.2	Ket qua EDA chinh	16
4.2.1	Tong quan bo du lieu	16
4.2.2	Nhan xet ve quality data	17
4.3	So sanh mo hinh va chien luoc tien xu ly	17
4.3.1	Xep hang theo ROC-AUC	17
4.3.2	Cau hinh de xuat	18
4.4	Phan tich sai so va trade-off	19
4.4.1	Confusion matrix va ROC	19
4.4.2	Trade-off theo threshold	19
4.4.3	Nhan dinh overfitting/underfitting	19
5	Ket luan va khuyen nghi	20
5.1	Ket luan chung	20
5.2	Tom tat ket qua dat duoc	20
5.3	Dong gop cua de tai	20
5.4	Han che nghien cuu	21
5.5	Huong phat trien va kien nghi	21

List of Figures

3.1	Thống kê missing an và giá trị 0 theo thuộc tính	14
3.2	Pipeline tiền xử lý và đánh giá mô hình	15
4.1	Phân bố lớp trong dữ liệu Pima	17
4.2	Mã trận tương quan sau khi áp dụng zero-as-missing	17
4.3	So sánh các cấu hình tiền xử lý + mô hình	18
4.4	Confusion matrix của cấu hình được chọn	19
4.5	Đường cong ROC cho các cấu hình dẫn đầu	19

List of Tables

3.1	Mo ta cac thuoc tinh trong bo du lieu Pima	13
4.1	Top cau hinh theo test ROC-AUC (trich tu notebook)	18

CHUONG 1

Tong quan van de

1.1 Ly do chon de tai

Benh tieu duong la mot trong nhung benh man tinh pho bien va co xu huong gia tang. Viec xay dung mo hinh ho tro du doan nguy co dua tren du lieu y sinh co y nghia thuc tien trong sang loc som. Bo du lieu Pima Indians Diabetes duoc su dung rong rai trong giao duc va nghien cuu vi co cau truc gon, de tai lap va phu hop de trinh bay day du quy trinh rut trich du lieu va tien xu ly.

1.2 Muc tieu nghien cuu

- Xay dung quy trinh phan tich va tien xu ly du lieu Pima co the tai lap.
- Danh gia anh huong cua cac chien luoc xu ly missing (Median, KNN, Iterative/MICE) va chuan hoa (StandardScaler, MinMaxScaler).
- So sanh hieu nang giua hai mo hinh baseline: Logistic Regression va Random Forest.

1.3 Cau hoi nghien cuu

1. Chinh sach *zero-as-missing* co cai thien tinh hop ly thong ke va ket qua mo hinh hay khong?
2. To hop *imputer + scaler + model* nao phu hop nhat voi du lieu Pima trong dieu kien baseline?
3. Trade-off giua precision va recall thay doi nhu the nao khi dieu chinh threshold?

1.4 Đối tượng và phạm vi

Đối tượng nghiên cứu là bộ dữ liệu `pima-indians-diabetes.csv` (768 mẫu, 8 thuộc tính đầu vào và 1 nhãn đầu ra). Báo cáo giới hạn trong phạm vi xử lý dữ liệu, EDA và đánh giá baseline; chưa mở rộng sang hyperparameter tuning toàn diện hoặc bộ dữ liệu ngoài.

1.5 Phương pháp tổng quát

Nhóm sử dụng Python notebook để triển khai toàn bộ quy trình: nạp dữ liệu, phân tích mô tả, làm sạch dữ liệu, tạo pipeline tiền xử lý, chia tập train/validation/test và so sánh dinh dưỡng.

1.6 Kết cấu báo cáo

Báo cáo gồm 5 chương:

- Chương 1: Tổng quan vấn đề.
- Chương 2: Cơ sở lý thuyết và các khái niệm liên quan.
- Chương 3: Dữ liệu và phương pháp đề xuất.
- Chương 4: Thực nghiệm và kết quả đạt được.
- Chương 5: Kết luận và khuyến nghị.

CHUONG 2

Co so ly thuyet va nghien cuu lien quan

2.1 Tong quan phan tich du lieu trong bai toan phan lop

Voi bai toan phan lop nhi phan, quy trình phan tich du lieu thuong gom: (1)kiem tra chat luong du lieu; (2) phan tich mo ta va truc quan hoa; (3) xu ly missing/outlier; (4) xay dung va danh gia mo hinh. Bo du lieu Pima la mot benchmark pho bien trong cong bo hoc may y sinh [1, 2].

2.2 Phan tich kham pha du lieu (EDA)

EDA giup xac dinh tinh chat du lieu truoc khi huan luyen:

- **Thong ke mo ta:** trung binh, do lech chuan, quartile.
- **Phan bo lop:** muc do can bang giua lop am va duong.
- **Tuong quan:** xac dinh bien co lien he manh voi bien muc tieu.

2.3 Xu ly missing data

Trong bo Pima, mot so bien y sinh co gia tri 0 khong hop ly ve sinh ly (`glucose`, `blood_pressure`, `skin_thickness`, `insulin`, `bmi`). Do do, bao cao ap dung quy uoc *zero-as-missing* va so sanh 3 chien luoc noi suy:

- **Median Imputation:** don gian, ben vung voi phan bo lech.
- **KNN Imputation:** noi suy dua tren mau lan can.
- **Iterative Imputation (MICE):** noi suy lap dua tren quan he giua cac bien.

2.4 Chuan hoa du lieu

Do thang do cac bien khac nhau, bao cao so sanh:

- **StandardScaler**: dua ve trung binh 0, do lech chuan 1.
- **MinMaxScaler**: dua ve khoang $[0,1]$.

Buoc nay giup mo hinh hoc may (dac biet mo hinh dua tren khoang cach/gradient) hoạt động ổn định và công bằng hơn giữa các biến.

2.5 Chi so danh gia mo hinh

Bao cao su dung cac chi so:

- **Accuracy**: ty le du doan dung tong quat.
- **Precision**: do chinh xac cua du doan duong tinh.
- **Recall**: kha nang phat hien duong tinh thuc te.
- **F1-score**: can bang giua precision va recall.
- **ROC-AUC**: nang luc phan biet hai lop tren nhieu threshold.

2.6 Mo hinh baseline

- **Logistic Regression**: mo hinh tuyen tinh de dien giai va lam moc so sanh.
- **Random Forest**: mo hinh phi tuyen, manh trong boi canh quan he bien phuc tap.

Khung trien khai duoc xay dung tren thu vien scikit-learn [3], trong khi cac nguyen ly danh gia va mo hinh hoa tham khao theo tai lieu kinh dien [4].

CHUONG 3

Du lieu va phuong phap de xuat

3.1 Nguon du lieu

Du lieu duoc su dung trong bai nay gom:

- `Lab_03/data/pima-indians-diabetes.csv`
- `Lab_03/data/pima-indians-diabetes.names`

Theo file mo ta, bo du lieu co 768 quan sat, 8 thuoc tinh so hoc va 1 bien muc tieu outcome.

3.2 Mo ta thuoc tinh

Table 3.1: Mo ta cac thuoc tinh trong bo du lieu Pima

Thuoc tinh	Y nghia
pregnancies	So lan mang thai
glucose	Nong do glucose huyet tuong (2h OGTT)
blood_pressure	Huyet ap tam truong (mm Hg)
skin_thickness	Do day nep da co tay sau (mm)
insulin	Nong do insulin huyet thanh (2h)
bmi	Chi so khoi co the
diabetes_pedigree_function	Hetien su gia dinh
age	Tuoi
outcome	Nhan phan lop (0/1)

3.3 Kiểm tra chất lượng dữ liệu

Kết quả từ notebook cho thấy:

- Số dòng trung lặp: 0.
- Không có NaN tương minh trong CSV gốc, nhưng có nhiều giá trị 0 bất thường sinh lý.
- Các cột có tỷ lệ 0 cao: `insulin` và `skin_thickness`.




Figure 3.1: Thống kê missing và giá trị 0 theo thuộc tính

3.4 Quy trình tiền xử lý để xuất

Quy trình được đề xuất và triển khai trong notebook:

1. Chuyển 0 → NaN cho các biến sinh lý bất thường.
2. Chia dữ liệu theo tỉ lệ train/validation/test = 60/20/20 (stratified).
3. Tạo pipeline kết hợp *imputer* + *scaler* + *model*.
4. So sánh 12 tổ hợp cấu hình (3 imputer x 2 scaler x 2 model).




Figure 3.2: Pipeline tien xu ly va danh gia mo hinh

CHUONG 4

Thuc nghiem va ket qua dat duoc

4.1 Thiet lap thuc nghiem

4.1.1 Chien luoc chia du lieu

Du lieu duoc chia theo ti le 60/20/20 voi *stratify* tren nhan `outcome` de giu on dinh ti le lop duong tinh giua cac tap.

- Train: 460 mau
- Validation: 154 mau
- Test: 154 mau

4.1.2 To hop cau hinh duoc so sanh

- Imputation: Median, KNN, Iterative(MICE)
- Scaling: StandardScaler, MinMaxScaler
- Model: Logistic Regression, Random Forest

Tong cong 12 cau hinh duoc danh gia voi cung mot seed va cung mot split de dam bao cong bang.

4.2 Ket qua EDA chinh

4.2.1 Tong quan bo du lieu

Bo du lieu co 768 dong va 9 cot (8 bien dau vao va 1 bien dau ra). Phan bo lop: class 0 = 500 mau (65.1%), class 1 = 268 mau (34.9%).




Figure 4.1: Phan bo lop trong du lieu Pima

4.2.2 Nhan xet ve quality data

So dong trung lap bang 0. Cac cot co so luong 0 cao nhat la `insulin` va `skin_thickness`, do do can xu ly missing an truoc huan luyen.




Figure 4.2: Ma tran tuong quan sau khi ap dung zero-as-missing

4.3 So sanh mo hinh va chien luoc tien xu ly

4.3.1 Xep hang theo ROC-AUC

Ket qua trong notebook cho thay cac cau hinh dan dau (theo test ROC-AUC) tap trung o to hop KNN imputer + Random Forest.

Table 4.1: Top cau hinh theo test ROC-AUC (trich tu notebook)

Imputer	Scaler	Model	Test ROC-AUC
KNN	MinMax	Random Forest	0.8170
KNN	Standard	Random Forest	0.8168
Median	Standard	Logistic Regres- sion	0.8167
Iterative	MinMax	Random Forest	0.8156
KNN	Standard	Logistic Regres- sion	0.8154




Figure 4.3: So sanh cac cau hinh tien xu ly + mo hinh

4.3.2 Cau hinh de xuat

Cau hinh tot nhat theo test ROC-AUC: **KNN Imputer + MinMaxScaler + Random Forest**.

- Validation ROC-AUC: 0.8700
- Test ROC-AUC: 0.8170
- Test F1: 0.6078
- Test Precision: 0.6458
- Test Recall: 0.5741

4.4 Phan tich sai so va trade-off

4.4.1 Confusion matrix va ROC




Figure 4.4: Confusion matrix cua cau hinh duoc chon




Figure 4.5: Duong cong ROC cho cac cau hinh dan dau

4.4.2 Trade-off theo threshold

Notebook da thuc hien quet threshold va chi ra rang threshold 0.50 chua chac toi uu. Diem can bang F1 tot nhat trong qua trinh quet nam quanh threshold xap xi 0.30, cho thay neu uu tien phat hien ca duong tinh thi co the danh doi precision de tang recall.

4.4.3 Nhan dinh overfitting/underfitting

Chenh lech `val_roc_auc` - `test_roc_auc` xap xi 0.053. Dieu nay cho thay dau hieu overfitting nhe den trung binh, can tiep tục kiểm chứng bằng cross-validation và tuning hệ thống trong bước tiếp theo.

CHUONG 5

Ket luan va khuyen nghi

5.1 Ket luan chung

Bao cao da hoan thanh quy trinh rut trich du lieu va tien xu ly cho bai toan du doan tieu duong tren bo du lieu Pima. Ket qua cho thay viec ket hop *zero-as-missing* voi pipeline imputation + scaling la can thiet de nang cao tinh nhat quan cua du lieu va hieu nang mo hinh baseline.

5.2 Tom tat ket qua dat duoc

- Hoan thien notebook phan tich theo huong bao cao hoc thuat.
- So sanh 12 cau hinh tien xu ly va mo hinh tren cung dieu kien chia du lieu.
- De xuat cau hinh KNN + MinMax + Random Forest cho ket qua test ROC-AUC cao nhat.
- Bo sung phan tich confusion matrix, ROC va threshold trade-off.

5.3 Dong gop cua de tai

- Chuan hoa quy trinh thuc hanh tu EDA den danh gia mo hinh baseline.
- Cung cap khung danh gia de tai lap cho cac bai toan phan lop y sinh tuong tu.
- Tang tinh bao cao hoa cua notebook de phuc vu trinh bay hoc phan.

5.4 Hạn chế nghiên cứu

1. Quy mô dữ liệu còn nhỏ (768 mẫu), chưa đại diện cho nhiều quần thể bệnh nhân.
2. Gia đình *zero-as-missing* có thể gây sai lệch nếu tồn tại trường hợp do thực sự bằng 0.
3. Đánh giá hiện tại dựa trên một lần chia train/validation/test, chưa có CV lặp lại.
4. Chưa tiến hành tuning tham số hệ thống và calibration xác suất.

5.5 Hướng phát triển và kiến nghị

1. Áp dụng Stratified K-Fold CV để kiểm chứng độ ổn định kết quả.
2. Mở rộng tuning tham số cho Logistic Regression và Random Forest.
3. Thử nghiệm thêm các mô hình boosting (XGBoost/LightGBM) và kỹ thuật cân bằng lớp.
4. Mở rộng bộ dữ liệu và kiểm tra external validity trên nguồn độc lập.
5. Đóng gói pipeline suy luận và tạo báo cáo tự động để tăng khả năng triển khai.

Bibliography

- [1] National Institute of Diabetes and Digestive and Kidney Diseases. Pima indians diabetes database, 1990. UCI-style dataset description distributed with course materials.
- [2] J. W. Smith, J. E. Everhart, W. C. Dickson, W. C. Knowler, and R. S. Johannes. Using the adap learning algorithm to forecast the onset of diabetes mellitus. *Proceedings of the Symposium on Computer Applications and Medical Care*, pages 261–265, 1988.
- [3] Fabian Pedregosa et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [4] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2 edition, 2009.