

Bài tập môn Máy học — Bài 01 & Bài 02

Lời giải

Họ tên: ... Mã SV: ...

Bài tập 01

Phần 1. Tổng quan về máy học

Câu 1.1 (a) Phân loại và gom cụm. Phân loại (classification) là bài toán *có giám sát*: tập huấn có nhãn đúng; mô hình học hàm từ đặc trưng sang nhãn rời rạc. Ví dụ: dự đoán email là spam hay không từ nội dung. Gom cụm (clustering) là *không giám sát*: không có nhãn sẵn; thuật toán nhóm các điểm tương tự nhau. Ví dụ: phân khách hàng thành vài nhóm mua sắm dựa trên hành vi, chưa biết trước tên nhóm.

(b) Bốn thang đo Stevens — ví dụ thực tế.

1. *Định danh* (nominal): chỉ phân loại, không có thứ tự. Ví dụ: mã màu mắt (nâu, xanh...).
2. *Thứ tự* (ordinal): thứ tự có nghĩa, khoảng cách số chưa chắc đồng nghĩa. Ví dụ: mức độ hài lòng (kém — trung bình — tốt).
3. *Khoảng* (interval): thứ tự và *chênh lệch* có nghĩa; tỷ số giữa hai giá trị thường không có nghĩa; không có “không” tuyệt đối theo nghĩa vật lý. Ví dụ: nhiệt độ độ C (0°C không phải “không nhiệt”).
4. *Tỷ lệ* (ratio): có điểm không tuyệt đối, tỷ số có nghĩa. Ví dụ: thu nhập (0 nghĩa là không có thu nhập), khối lượng.

(c) Quy trình CRISP-DM (các bước chính).

1. *Hiểu nghiệp vụ*: xác định mục tiêu, tiêu chí thành công, ràng buộc.
2. *Hiểu dữ liệu*: thu thập, khám phá sơ bộ, chất lượng ban đầu.
3. *Chuẩn bị dữ liệu*: làm sạch, tích hợp, biến đổi, rời rạc hóa nếu cần.

4. *Mô hình hóa*: chọn kỹ thuật, huấn luyện, điều chỉnh tham số.
5. *Đánh giá*: kiểm tra đủ tốt với mục tiêu nghiệp vụ, không chỉ độ chính xác kỹ thuật.
6. *Triển khai*: đưa vào vận hành, giám sát và cập nhật chu trình nếu dữ liệu hoặc nghiệp vụ thay đổi.

(d) **Phân loại và hồi quy**. Phân loại: đầu ra là nhãn lớp rời rạc. Ví dụ: chẩn đoán có/không bệnh. Hồi quy: đầu ra là biến liên tục (hoặc số thực). Ví dụ: dự báo giá nhà từ diện tích và vị trí.

(e) **Chất lượng dữ liệu và xử lý thường gặp**.

- *Nhiều*: sai lệch ngẫu nhiên — làm mịn, lọc, hoặc thu thập lại.
- *Giá trị ngoại lai (outliers)*: điểm bất thường — kiểm tra lỗi nhập, cắt/winsorize, hoặc mô hình chịu ngoại lai.
- *Thiếu giá trị*: điền (mean/median/mode), mô hình hỗ trợ thiếu, hoặc loại bỏ có kiểm soát.
- *Trùng lặp*: gộp hoặc xóa bản ghi trùng để tránh lệch trọng số.

(f) **Rò rỉ dữ liệu (data leakage)**. Là khi thông tin từ “tương lai” hoặc từ nhãn lọt vào đặc trưng huấn luyện, làm đánh giá quá lạc quan và mô hình kém khi áp dụng thật. Nguy hiểm vì ta tưởng mô hình tốt nhưng trên dữ liệu mới sẽ sai. Ví dụ: dùng cột “tổng chi phương điều trị” để dự đoán “có nhập viện hay không” khi cột đó chỉ có sau khi điều trị — đã mang thông tin kết quả.

Phần 2. Phân tích khám phá và tiền xử lý

Câu 2.1

Dãy tuổi đã sắp tăng ($n = 27$):

13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25, 25, 30, 33, 33,
35, 35, 35, 36, 40, 45, 46, 52, 70.

(a) **Trung bình, trung vị, mốt**.

Tổng các giá trị bằng 809, nên trung bình mẫu

$$\bar{x} = \frac{809}{27} \approx 29,96.$$

Vì n lẻ, trung vị là phần tử vị trí thứ $\frac{n+1}{2} = 14$ trên dãy đã sắp, đó là 25.

Đếm tần số: 25 và 35 mỗi giá trị xuất hiện 4 lần; các giá trị khác không quá 2 lần. Vậy có hai mốt: 25 và 35 (đa mốt).

(b) Tứ phân vị Q_1, Q_3 .

Có hai quy ước phổ biến; đề cho phép xấp xỉ.

Cách vị trí nguyên (1-based): Q_1 ứng vị trí $\frac{1}{4}(n+1) = 7 \Rightarrow$ giá trị thứ 7 là 20. Q_3 ứng vị trí $\frac{3}{4}(n+1) = 21 \Rightarrow$ giá trị thứ 21 là 35. Khi đó $IQR = 35 - 20 = 15$.

Cách nội suy tuyến tính giữa hai quan sát kề: vị trí Q_1 là 7,5 nên $Q_1 = \frac{20+21}{2} = 20,5$; vị trí Q_3 là 20,5 nên $Q_3 = \frac{35+35}{2} = 35$ và $IQR = 14,5$.

(c) Boxplot và nhận xét.

Năm số tóm tắt: min = 13, trung vị = 25, max = 70; Q_1, Q_3 chọn một trong hai cách trên (minh họa: $Q_1 = 20,5, Q_3 = 35$ nếu nội suy). Với $IQR = 14,5$, ngưỡng trên Tukey $Q_3 + 1,5 \cdot IQR = 56,75$; vì $70 > 56,75$ nên 70 thường được xem là ngoại lai phía trên. Trung bình ($\approx 29,96$) lớn hơn trung vị (25) — phân bố *lệch phải* (đuôi dài về giá trị lớn).

(d) Rời rạc hóa $k = 4$.

Chia độ rộng đều: min = 13, max = 70, bước $w = \frac{70-13}{4} = 14,25$. Các khoảng (ý niệm các nửa khoảng có thể ghi theo quy ước lớp):

$$(13; 27,25], \quad (27,25; 41,5], \quad (41,5; 55,75], \quad (55,75; 70].$$

Số mẫu từng khoảng: 14, 9, 3, 1 (tổng 27).

Chia gần tần số đều: chia 27 mẫu thành $7+7+7+6$ theo thứ tự đã sắp: nhóm 1 — 13 đến 20; nhóm 2 — 21 đến 25; nhóm 3 — 30 đến 35; nhóm 4 — 36 đến 70.

Câu 2.2

Bước 1 — Thang đo của V . Các giá trị $1, \dots, 5$ có thứ tự và khoảng cách giữa hai mức liên kề đều bằng 1, nên hiệu có ý nghĩa; không có “số không” tuyệt đối theo nghĩa tỷ lệ vật lý, và tỷ số $2/1$ chưa hẳn mang nghĩa “gấp đôi khối lượng”. Vì vậy V phù hợp *thang khoảng* (interval), hơn là thuần định danh/thứ tự, và không cần là thang tỷ lệ.

Bước 2 — Cùng thang khoảng với V . Hai biểu diễn cùng thang khoảng nếu tồn tại $a > 0, b$ sao cho $W = aV + b$ đúng trên cả năm mức $V \in \{1, \dots, 5\}$.

- $W_1 = 100V$ (lấy $a = 100, b = 0$) — cùng thang khoảng.
- $W_2 = V + 9$ — cùng.
- W_3 : dãy 8, 13, 45, 6, 7 không tăng dần cùng V , không tồn tại a, b để $W = aV + b$ — không cùng.

- $W_4 = V^2$: các bước $W(2) - W(1) = 3$, $W(3) - W(2) = 5$ khác nhau — không tuyến tính theo V — *không cùng thang khoảng*.
- $W_5 = 2V - 12$ — *cùng*.
- $W_6 = 3V$ — *cùng*.

Kết luận: Cùng thang khoảng với V : W_1, W_2, W_5, W_6 . Không: W_3, W_4 .

Phần 3. Huấn luyện và đánh giá

Câu 3.1

Nhãn thực $ABCABCABCA$, nhãn dự đoán $ACCBBAABCC$ ($n = 10$).

Duyệt từng mẫu và đếm (hàng = thực, cột = dự):

	dự A	dự B	dự C
thực A	2	1	1
thực B	0	2	1
thực C	1	0	2

Số đúng trên đường chéo: $2 + 2 + 2 = 6$.

$$\text{Accuracy} = \frac{6}{10} = 0,6.$$

Với mỗi lớp k : TP_k là ô (k, k) , FN_k là tổng hàng trừ TP_k , FP_k là tổng cột trừ TP_k ;

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k}, \quad F1_k = \frac{2P_k R_k}{P_k + R_k}.$$

- Lớp A : $TP = 2$, $FP = 1$, $FN = 2 \Rightarrow P = \frac{2}{3}$, $R = \frac{1}{2}$, $F1 \approx 0,571$.
- Lớp B : $TP = 2$, $FP = 1$, $FN = 1 \Rightarrow P = R = \frac{2}{3}$, $F1 \approx 0,667$.
- Lớp C : $TP = 2$, $FP = 2$, $FN = 1 \Rightarrow P = 0,5$, $R = \frac{2}{3}$, $F1 \approx 0,571$.

Câu 3.2 (hồ sơ 14 mẫu và danh sách quy tắc)

Quy tắc theo thứ tự: (1) nếu thuộc tính *outlook* là *overcast* thì *play* là *yes*; (2) nếu không thỏa (1) và *windy* là đúng thì *play* là *no*; (3) nếu không thỏa (1)–(2) và *outlook* là *sunny* thì *no*; (4) còn lại thì *yes*.

Áp dụng từng dòng (tóm tắt kết quả dự đoán so với thực tế):

STT	outlook	windy	dự đoán	thực	đúng?
1	sunny	F	no	no	OK
2	sunny	T	no	no	OK
3	overcast	F	yes	yes	OK
4	rainy	F	yes	yes	OK
5	rainy	F	yes	yes	OK
6	rainy	T	no	no	OK
7	overcast	T	yes	yes	OK
8	sunny	F	no	no	OK
9	sunny	F	no	yes	Sai
10	rainy	F	yes	yes	OK
11	sunny	T	no	yes	Sai
12	overcast	T	yes	yes	OK
13	overcast	F	yes	yes	OK
14	rainy	T	no	no	OK

Lớp dương: nhãn *play* là *yes*. Ma trận nhầm lẫn 2×2 (hàng = thực, cột = dự):

	dự yes	dự no
thực yes	7	2
thực no	0	5

TP = 7, FN = 2, FP = 0, TN = 5, $N = 14$.

$$\text{Accuracy} = \frac{12}{14} = \frac{6}{7} \approx 0,857, \quad P = \frac{7}{7} = 1, \quad R = \frac{7}{9} = \frac{7}{9} \approx 0,778,$$

$$\text{Specificity} = \frac{5}{5} = 1, \quad F1 = \frac{2PR}{P+R} = \frac{7}{8} = 0,875.$$

Bài tập 02

Dữ liệu (10 mẫu)

ID	Tuổi	Lương	Điểm	Giới tính	Mua hàng
1	25	8000	7,5	Nam	Yes
2	30	?	8,0	Nữ	No
3	22	5000	6,5	Nam	Yes
4	40	15000	9,0	Nữ	Yes
5	35	-2000	7,0	Nam	No
6	?	7000	6,0	Nữ	Yes
7	29	8500	8,5	Nam	Yes
8	50	30000	9,5	Nữ	Yes
9	27	8200	?	Nam	No
10	31	7800	7,8	Nữ	Yes

Câu 1

Có 10 quan sát (hàng) và 6 cột (ID và năm thuộc tính). Nếu coi ID chỉ là mã dòng, còn 5 thuộc tính dùng cho mô hình: Tuổi, Lương, Điểm là *định lượng*; Giới tính là *định tính* (danh mục); Mua hàng là nhân nhị phân (Yes/No).

Câu 2

Chỉ tính trên ô có số (bỏ quan sát thiếu từng cột).


Tuổi (9 ô: bỏ ID 6). Tổng 289, trung bình $\bar{x} = 289/9 \approx 32,11$. Sắp tăng: 22, 25, 27, 29, 30, 31, 35, 40, 50 — trung vị (vị trí thứ 5) là 30. Mọi giá trị đều xuất hiện một lần nên *không có một* theo nghĩa thống kê cổ điển.

Lương (9 ô: bỏ ID 2). Gồm cả -2000 (ID 5). Tổng 87400, trung bình $\approx 9722,22$. Sắp tăng: -2000, 5000, 7000, 7800, 8000, 8200, 8500, 15000, 30000 — trung vị = 8000. Mốt: không có mốt cổ điển (một lần mỗi giá trị); giá trị -2000 về nội dung là sai lỗi, không nên diễn giải như mốt.

Điểm (9 ô: bỏ ID 9). Tổng 69,8, trung bình $\approx 7,756$. Sắp tăng: 6,0, 6,5, 7,0, 7,5, 7,8, 8,0, 8,5, 9,0, 9,5 — trung vị = 7,8. Không có mốt cổ điển (mọi tần bằng 1).


Câu 3

Vẽ histogram cho Tuổi (chỉ các ô không thiếu) và boxplot cho Lương (các ô lương không trống, -2000 vẫn là một điểm). Minh họa:



Hệ số bất đối xứng mẫu của Tuổi $\approx 1,20 > 0$ — phân bố Tuổi *lệch phải* (đuôi về phía tuổi lớn). Boxplot Lương: có đuôi dài phía giá trị lớn và có điểm -2000 nằm xa phần còn lại — vừa là điểm bất thường về *nội dung* (lương âm).

Câu 4



Trên 8 cặp (Tuổi, Lương) đồng thời không thiếu, hệ số tương quan Pearson mẫu $r \approx 0,75$ — xu hướng *dương* (tuổi tăng thì lương có xu hướng tăng), nhưng còn điểm lệch (ví dụ -2000). Gợi ý tiền xử lý: điền thiếu; xử lý lỗi -2000 (coi missing hoặc thay bằng giá trị đại diện sau khi làm sạch); có thể biến đổi sau khi lương đã dương và ổn định.

Câu 5

Thiếu: Tuổi tại ID 6 ($1/10 = 10\%$); Lương tại ID 2 (10%); Điểm tại ID 9 (10%). Ảnh hưởng: giảm số cặp đầy đủ cho tương quan; một số phương pháp

không chấp nhận ô trống. Xử lý: điền thống kê hoặc mô hình đơn/đa biến; hoặc loại bản ghi nếu được phép.

Câu 6

Trước khi điền: coi lương âm là không hợp lệ cho bước thống kê — gán thành thiếu cho mục đích tính mean/median điền (để -2000 không kéo trung bình điền vào chỗ trống).

Hai cách điền phổ biến (sau bước trên). Với *trung bình cột*, ví dụ Lương tại ID 2 được điền $\approx 11187,5$; Tuổi và Điểm cũng thay đổi so với median. Dưới đây là toàn bộ bảng sau *điền bằng trung vị*:

ID	Tuổi	Lương	Điểm
1	25	8000	7,5
2	30	8100	8,0
3	22	5000	6,5
4	40	15000	9,0
5	35	8100	7,0
6	30	7000	6,0
7	29	8500	8,5
8	50	30000	9,5
9	27	8200	7,8
10	31	7800	7,8

Chọn median: dữ liệu Lương lệch và có giá trị cực lớn; trung vị bền hơn trung bình khi điền thiếu.

Câu 7

Giá trị không hợp lệ: Lương = -2000 tại ID 5 (không thực tế). Cách xử lý: đánh dấu missing rồi điền; hoặc thay bằng trung vị các lương dương sau khi kiểm tra — nhất quán với Câu 6–9 bên dưới.

Câu 8

Trên các ô Lương không trống trong bảng gốc: $Q_1 = 7000$, $Q_3 = 8500$, $IQR = 1500$, khoảng Tukey $[4750; 10750]$. Các giá trị ngoài khoảng: -2000 , 15000 , 30000 .

Chuẩn hóa $z_i = (x_i - \mu)/\sigma$ với μ , σ mẫu trên các lương không thiếu ($\mu \approx 9722$, $\sigma \approx 8277$). Với ngưỡng $|z| > 3$ không có điểm nào; tuy vậy -2000 và 30000 vẫn là ngoại lai mạnh theo IQR và cần xử lý theo Câu 7.

Câu 9

Sau khi điền thiếu bằng *trung vị* (như Câu 6) và thay lương âm bằng trung vị các lương dương (8100), chuẩn hóa Z-score cột Lương:

$$z = \frac{x - \mu}{\sigma}$$

(ước lượng μ, σ trên 10 giá trị sau làm sạch). Giá trị:

ID	Lương (sau xử lý)	z
1	8000	-0,371995
2	8100	-0,357520
3	5000	-0,806230
4	15000	0,641221
5	8100	-0,357520
6	7000	-0,516740
7	8500	-0,299622
8	30000	2,812397
9	8200	-0,343046
10	7800	-0,400944

Trung bình các z gần 0 và độ lệch chuẩn gần 1: đổi thang đo Lương sang đơn vị “số sigma” để so sánh cùng thang với các thuộc tính khác sau này.

Câu 10

One-hot giới tính: hai cột nhị phân tương ứng Nam và Nữ (Nam $\rightarrow (1, 0)$, Nữ $\rightarrow (0, 1)$). Mua hàng nhị phân: Yes $\rightarrow 1$, No $\rightarrow 0$.

ID	Tuổi	Lương	Điểm	Nam	Nữ	Mua
1	25	8000	7,5	1	0	1
2	30	8100	8,0	0	1	0
3	22	5000	6,5	1	0	1
4	40	15000	9,0	0	1	1
5	35	8100	7,0	1	0	0
6	30	7000	6,0	0	1	1
7	29	8500	8,5	1	0	1
8	50	30000	9,5	0	1	1
9	27	8200	7,8	1	0	0
10	31	7800	7,8	0	1	1

(Các cột số Tuổi, Lương, Điểm ở đây trùng với bảng sau khi điền median và thay lương âm như Câu 6–9.)

Câu 11

- **ID:** bỏ khỏi tập đặc trưng dự báo (chỉ là chỉ số, dễ gây học nhầm nếu mô hình quá phức tạp).
- **Tuổi, Lương, Điểm:** giữ sau khi xử lý thiếu/lỗi; đây là thông tin hữu ích cho Mua hàng.
- **Giới tính:** giữ dưới dạng one-hot như Câu 10.
- Cột nhiều missing/lỗi chưa xử lý sẽ làm giảm chất lượng — cần làm sạch trước hoặc giảm trọng số trong phân tích.

Câu 12

Với chỉ vài biến định lượng và mẫu nhỏ, *giảm chiều đơn giản* (bỏ ID, có thể gộp biến nếu tương quan quá cao sau khi làm sạch) thường đủ.

PCA phù hợp khi có nhiều biến định lượng tương quan cao và cần nén xuống vài thành phần — nên *chuẩn hóa* trước PCA. Ở bài này số chiều định lượng ít và còn biến danh mục; PCA không bắt buộc trừ khi sau này bổ sung nhiều cột liên quan (ví dụ nhiều loại điểm số hoặc chỉ số tổng hợp).