

Bài tập ML — Bài 03: Cây quyết định

Lời giải

Họ tên: ... Mã SV: ...

Bài tập 03 — Cây quyết định

Dùng logarithm nhị phân trong entropy: log hiểu là $\log_2$. Ký hiệu $H(S)$ là entropy của tập nhãn của S (theo các lớp xuất hiện trong S).

Bài 1. Dự đoán mùa trong năm

Dữ liệu huấn luyện (12 dòng đầu) và hai mẫu cần dự báo X, Y.

Mẫu	Thời tiết	Lá cây	Nhiệt độ	Mùa
1	Nắng	Vàng	Trung bình	Thu
2	Tuyết	Xanh	Thấp	Đông
3	Tuyết	Vàng	Thấp	Đông
4	Mưa	Vàng	Trung bình	Thu
5	Mưa	Rụng	Thấp	Đông
6	Tuyết	Rụng	Thấp	Đông
7	Nắng	Rụng	Thấp	Đông
8	Nắng	Xanh	Trung bình	Xuân
9	Nắng	Xanh	Cao	Hè
10	Mưa	Rụng	Trung bình	Thu
11	Mưa	Xanh	Cao	Hè
12	Mưa	Xanh	Trung bình	Xuân
X	Mưa	Vàng	Thấp	?
Y	Tuyết	Rụng	Trung bình	?

(a) Thuật toán ID3 (entropy)

Bước 1 — Lần chia đầu (trên cả 12 mẫu).

Tần số nhãn: Thu (3), Đông (5), Xuân (2), Hè (2).

$$H(S) = -\frac{3}{12} \log \frac{3}{12} - \frac{5}{12} \log \frac{5}{12} - 2 \cdot \frac{2}{12} \log \frac{2}{12} \approx 1,8879.$$

Với mỗi thuộc tính, tính entropy có trọng số sau khi tách theo *tất cả* giá trị của thuộc tính đó, rồi lấy $\text{Gain} = H(S) - H_{\text{sau tách}}$.

Thời tiết. Các nhánh Nắng (4 mẫu), Tuyết (3 mẫu), Mưa (5 mẫu) cho entropy từng nhánh lần lượt khoảng 2,0000; 0; 1,9219. Trung bình có trọng số

$$H_{\text{thời tiết}} \approx 1,4675, \quad \text{Gain} \approx 0,4204.$$

Lá cây. Nhánh Vàng (3 mẫu: Thu, Đông, Thu), Xanh (5 mẫu), Rụng (4 mẫu) cho

$$H_{\text{lá}} \approx 1,1341, \quad \text{Gain} \approx 0,7538.$$

Nhiệt độ. Nhánh Trung bình (5), Thấp (5), Cao (2): nhánh Thấp và Cao thuần nhất (entropy 0); nhánh Trung bình có 3 Thu và 2 Xuân nên entropy khoảng 0,9710. Vậy

$$H_{\text{nhiệt độ}} = \frac{5}{12} H_{(\text{Trung bình})} + \frac{5}{12} \cdot 0 + \frac{2}{12} \cdot 0 \approx 0,4046, \quad \text{Gain} \approx 1,4834.$$

Thuộc tính có gain lớn nhất là **Nhiệt độ** — chọn làm nút gốc.

Bước 2 — Các lá trực tiếp từ gốc.

- Nhiệt độ = **Cao**: hai mẫu 9 và 11 đều là Hè $\Rightarrow$ **Hè**.
- Nhiệt độ = **Thấp**: toàn nhãn Đông $\Rightarrow$ **Đông**.
- Nhiệt độ = **Trung bình**: còn 5 mẫu (1,4,8,10,12) với nhãn Thu–Thu–Xuân–Thu–Xuân.

Bước 3 — Lần chia trên nhánh «Trung bình».

Gọi S' = tập 5 mẫu trên. $H(S') = -\frac{3}{5} \log \frac{3}{5} - \frac{2}{5} \log \frac{2}{5} \approx 0,9710$.


Thuộc tính «Thời tiết». Trong S' không có mẫu nào có thời tiết Tuyết. Nhánh Nắng gồm (1, Thu) và (8, Xuân). Nhánh Mưa gồm (4, Thu), (10, Thu), (12, Xuân). Entropy có trọng số $\approx 0,9510$; Gain $\approx 0,020$.

Thuộc tính «Lá cây»: nhánh «Vàng» gồm (1Thu, 4Thu); «Xanh» gồm (8Xuân, 12Xuân); «Rụng» gồm (10Thu) — đều thuần nhất, entropy từng nhánh là 0. Vậy $H_{\text{sau tách}} = 0$, Gain $\approx H(S') \approx 0,9710$.

Chọn **Lá cây** trong nhánh này.

Cây thu được (mô tả bằng luật if–then).

1. Nếu Nhiệt độ = Cao $\Rightarrow$ Hè.
2. Nếu Nhiệt độ = Thấp $\Rightarrow$ Đông.
3. Nếu Nhiệt độ = Trung bình và Lá cây = Xanh $\Rightarrow$ Xuân.
4. Nếu Nhiệt độ = Trung bình và (Lá cây = Vàng hoặc Rụng) $\Rightarrow$ Thu.



Minh họa cấu trúc cây theo entropy; trên 12 mẫu này Gini và lỗi phân loại cũng cho cùng cấu trúc (mục (c)).

(b) Dự báo X và Y

- X: (Mưa, Vàng, Thấp) — theo luật (2) ⇒ **Đông**.
- Y: (Tuyết, Rụng, Trung bình) — theo luật (4) ⇒ **Thu**.

(c) Gini và lỗi phân loại

Với cùng cách tách đa nhánh như trên, trên bộ 12 mẫu này cả ba tiêu chí (entropy, Gini, lỗi phân loại) đều chọn cùng thứ tự thuộc tính: **Nhiệt độ** ở gốc, rồi **Lá cây** trên nhánh «Trung bình»; dự báo X, Y vẫn là **Đông** và **Thu**.

Bài 2. Đọc / không đọc của lá (10 mẫu học)

Dữ liệu (Huấn luyện: 1–10; kiểm tra: 11, 12.)

Mẫu	Hình dạng	Dạng	Màu	Kích thước	Độc
1	Tròn	Đơn	Đỏ	Nhỏ	Không
2	Tròn	Kép	Đỏ	Nhỏ	Có
3	Tròn	Đơn	Xanh	To	Không
4	Dài	Đơn	Xanh	Nhỏ	Không
5	Dài	Kép	Vàng	Nhỏ	Có
6	Dài	Đơn	Xanh	Vừa	Có
7	Tròn	Kép	Vàng	To	Không
8	Tròn	Kép	Vàng	Vừa	Có
9	Tròn	Đơn	Đỏ	Vừa	Có
10	Dài	Đơn	Đỏ	Vừa	Có
11	Dài	Kép	Đỏ	Vừa	?
12	Tròn	Đơn	Xanh	Nhỏ	?

Trên 10 mẫu, Không và Có có tần 4 và 6. Entropy gốc

$$H(S) = -\frac{4}{10} \log \frac{4}{10} - \frac{6}{10} \log \frac{6}{10} \approx 0,9710.$$

(đ) Theo chỉ số Gini — lần đầu

Gini của tập: $i(S) = 1 - \left(\frac{4}{10}\right)^2 - \left(\frac{6}{10}\right)^2 = 0,48$.

Tách theo **Kích thước**: nhánh “Nhỏ” gồm bốn mẫu 1–2–4–5 với nhãn lần lượt Không, Có, Không, Có; nhánh “To” một mẫu Không; nhánh “Vừa” ba mẫu đều Có. Impurity Gini từng nhánh: “Nhỏ” là $1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = \frac{1}{2}$; “To” và “Vừa” bằng 0 (thuần nhất). Gini có trọng số:


$$\frac{4}{10} \cdot 0,5 + \frac{1}{10} \cdot 0 + \frac{3}{10} \cdot 0 = 0,20, \quad \Delta \approx 0,28$$

lớn nhất so với các thuộc tính còn lại (xem bảng đối chiếu khi tính tay). Vậy chọn **Kích thước** ở gốc.

Nhánh «Kích thước = Nhỏ»

Bốn mẫu còn lại có nhãn Không–Có–Không–Có (entropy 1). Tách theo **Dạng**: «Đơn» (2 Không), «Kép» (2 Có) — thuần nhất. Đây là lần chia thứ hai.

Nhánh «To» và «Vừa» đã thuần «Không» và «Có».



Minh họa cây theo Gini; entropy và lỗi phân loại cho cấu trúc giống hệt trên bộ huấn luyện (mục (f)).

(e) Dự báo mẫu 11 và 12

Theo cây tìm được:

- Mẫu 11 (Dài, Kép, Đỏ, Vừa): Kích thước “Vừa” $\Rightarrow$ **Có**.
- Mẫu 12 (Tròn, Đơn, Xanh, Nhỏ): “Nhỏ” rồi “Đơn” $\Rightarrow$ **Không**.

(f) Entropy và lỗi phân loại

Ở gốc, entropy có trọng số sau khi tách theo Kích thước là 0,4000 (gain 0,5709), lớn hơn các thuộc tính khác; lỗi phân loại có trọng số cũng đạt cực tiểu 0,20 với cùng thuộc tính **Kích thước**. Bước kế trên nhánh «Nhỏ» vẫn chọn **Dạng**. Kết quả dự báo mẫu 11, 12 trùng phần (đ)–(e): **Có** và **Không**.

Bài 3. Quyết định cho vay (10 mẫu học)

Dữ liệu.

Mẫu	Phái	Công việc	Học vấn	Độ tuổi	Quyết định
1	Nam	LĐ Chân tay	Cao đẳng	Trung niên	Không
2	Nữ	LĐ Trí óc	Đại học	Trung niên	Có
3	Nữ	LĐ Chân tay	Phổ thông	Già	Có
4	Nam	LĐ Trí óc	Cao đẳng	Trung niên	Có
5	Nam	LĐ Chân tay	Phổ thông	Thanh niên	Không
6	Nam	LĐ Trí óc	Đại học	Già	Có
7	Nam	LĐ Chân tay	Cao đẳng	Già	Có
8	Nữ	LĐ Chân tay	Phổ thông	Trung niên	Không
9	Nam	LĐ Trí óc	Đại học	Thanh niên	Không
10	Nữ	LĐ Chân tay	Cao đẳng	Già	Có
A	Nữ	LĐ Trí óc	Cao đẳng	Già	?
B	Nam	LĐ Chân tay	Phổ thông	Trung niên	?

(a) Lỗi phân loại

Tại gốc, lỗi gốc $= 1 - \max(\frac{4}{10}, \frac{6}{10}) = 0,40$. Tách theo **Độ tuổi**: Già (4 mẫu toàn «Có»), Thanh niên (2 mẫu toàn «Không»), Trung niên (4 mẫu: hai Không và hai Có—lỗi impurity của nút bằng $1 - \frac{2}{4} = 0,5$). Lỗi có trọng số


$$\frac{4}{10} \cdot 0 + \frac{2}{10} \cdot 0 + \frac{4}{10} \cdot 0,5 = 0,20,$$

giảm nhiều nhất so với Phái, Công việc (lỗi có trọng số 0,40 tại nút đầu) và Học vấn (0,30). Chọn **Độ tuổi** gốc.

Trên nhánh Trung niên, tách tiếp theo **Công việc**: hai nhánh đều thuần (Chân tay $\rightarrow$ Không; Trí óc $\rightarrow$ Có).

Luật (tóm tắt):

1. Độ tuổi = Già $\Rightarrow$ Có.
2. Độ tuổi = Thanh niên $\Rightarrow$ Không.
3. Độ tuổi = Trung niên và công việc thuộc nhóm trí óc $\Rightarrow$ Có.
4. Độ tuổi = Trung niên và công việc chân tay $\Rightarrow$ Không.



Minh họa theo lối phân loại ở gốc; Gini và entropy cũng thu được cùng cấu trúc như trong mục (c).

(b) Dự báo A và B

- A (Nữ, Trí óc, Cao đẳng, Già): theo luật (1) $\Rightarrow$ **Có**.
- B (Nam, Chân tay, Phổ thông, Trung niên): luật (4) $\Rightarrow$ **Không**.

(c) Gini và entropy

Entropy gốc cũng bằng 0,9710 như phần 2 (nhân 4/10 và 6/10 là cặp không–có như nhau).

Tại gốc, entropy có trọng số sau khi tách theo Độ tuổi là 0,4000 (gain 0,5709), lớn nhất; Gini có trọng số 0,2000 (độ giảm 0,2800) cũng đạt cực đại. Bước kế trên «Trung niên» vẫn chọn **Công việc**. Dự báo A, B giữ nguyên **Có** và **Không**.