

# Bài tập ML — Bài 05: Similarity-based learning

## Lời giải

Họ tên: ... Mã SV: ...

### Bài tập 05 — Similarity-based learning

Quy ước khoảng cách Euclidean giữa hai vector  $\mathbf{u}, \mathbf{v}$  là  $\|\mathbf{u} - \mathbf{v}\|_2$ . Với dữ liệu nhị phân, khoảng cách Hamming là  $\sum_i |u_i - v_i|$ .

#### Câu 1. k-NN cơ bản

Vector thử  $\mathbf{x} = (6,5, 55, 5)$ . Tính căn của tổng bình phương sai lệch theo từng chiều (GPA, điểm bài tập, điểm project); sắp xếp tăng theo  $d$ :

| STT | GPA | Assign | Proj | $d$    |
|-----|-----|--------|------|--------|
| 6   | 6,2 | 50     | 5    | 5,009  |
| 3   | 6,0 | 45     | 5    | 10,012 |
| 4   | 5,5 | 40     | 4    | 15,067 |
| 5   | 7,8 | 70     | 7    | 15,188 |
| 2   | 8,2 | 75     | 8    | 20,295 |
| 1   | 9,0 | 88     | 9    | 33,335 |

$k = 3$ : ba láng giềng gần nhất là mẫu 6, 3, 4 — cùng nhãn **Fail**. Đa số: **Fail**.

$k = 1$ : láng giềng mẫu 6 ( $\approx 5,009$ )  $\Rightarrow$  **Fail**.

$k = 5$ : thêm mẫu 5 (**Pass**) và 2 (**Pass**) nhưng vẫn có ba **Fail** trong năm láng giềng đầu tiên không đổi kết luận đa số: năm láng giềng gần nhất gồm 6,3,4,5,2 — **Fail** vẫn chiếm đa số (3 so với 2). Dự đoán: **Fail**.

*Nhận xét:* Với mẫu thử nằm gần cụm điểm GPA thấp / bài tập thấp,  $k$  nhỏ và  $k$  trung bình đều giữ nhãn **Fail**. Chỉ khi  $k$  đủ lớn để kéo thêm nhiều điểm **Pass** xa hơn mới có thể đổi lớp (ở đây  $k = 5$  vẫn chưa đổi).

## Câu 2. k-NN và Min-Max

Dùng  $k = 3$  như mặc định bài tập (đề không ghi  $k$ ).

**Không chuẩn hóa**, thử (172, 80): khoảng cách tăng dần tương ứng mẫu  $4 \rightarrow 2 \rightarrow 3 \rightarrow 1$ ; ba gần nhất là  $B, A, B \Rightarrow \mathbf{B}$ .

**Min-Max** chỉ ước từ *tập huấn luyện* theo từng cột:  $x' = (x - x_{\min}) / (x_{\max} - x_{\min})$ . Cột cao: min = 158, max = 175; cột nặng: min = 60, max = 90. Áp cùng hai tham số cho điểm thử. Sau biến đổi, ba láng giềng gần nhất đều thuộc  $\mathbf{A} \Rightarrow \mathbf{A}$ .

*So sánh*: Chiều *cân nặng* có độ dài tự nhiên lớn hơn (khoảng 30 kg) so với chiều *chiều cao* (khoảng 17 cm) nên *trước chuẩn hóa* khoảng cách Euclidean bị chi phối mạnh bởi cân nặng. Min-Max cân bằng thang đo, nên kết quả phản ánh đồng đều hai đặc trưng — dự đoán đổi từ  $\mathbf{B}$  sang  $\mathbf{A}$ .

## Câu 3. Weighted k-NN

Điểm thử (6, 6). Ba gần nhất (Euclidean): (5, 5) lớp  $\mathbf{A}$  ( $d = \sqrt{2} \approx 1,414$ ); (7, 8)  $\mathbf{B}$  ( $d = \sqrt{5} \approx 2,236$ ); (3, 4)  $\mathbf{A}$  ( $d = \sqrt{13} \approx 3,606$ ).

**k-NN thường**: hai phiếu  $\mathbf{A}$ , một  $\mathbf{B} \Rightarrow \mathbf{A}$ .

**Trọng số**:  $w_i = \frac{1/d_i}{\sum_j 1/d_j}$ . Tổng có trọng số:  $\sum_A w' \approx 0,688$ ,  $\sum_B w' \approx 0,312 \Rightarrow \mathbf{A}$ .

So sánh: hai cách cùng dự đoán  $\mathbf{A}$  (láng giềng gần nhất vẫn thiên về  $\mathbf{A}$ ).

## Câu 4. Nearest centroid

Trung bình theo lớp:

$$\mu_A = \left(\frac{2+3+4}{3}, \frac{1+2+1}{3}\right) = \left(3, \frac{4}{3}\right), \quad \mu_B = \left(\frac{7+8+9}{3}, \frac{6+7+5}{3}\right) = (8, 6).$$

Điểm thử (6, 5):

$$d_A = \sqrt{(6-3)^2 + \left(5 - \frac{4}{3}\right)^2} \approx 4,74, \quad d_B = \sqrt{(6-8)^2 + (5-6)^2} = \sqrt{5} \approx 2,24.$$


Vì  $d_B < d_A$  dự đoán  $\mathbf{B}$ .

## Câu 5. LWR (kernel Gaussian)

Mô hình *tham chiếu*  $h(x) = 1 + 2x$ .

(1)  $h(2,5) = 1 + 2 \cdot 2,5 = 6$ .

(2)  $|x_i - 2,5|$  lần lượt: 1,5; 0,5; 0,5; 1,5.



Hình 1: Câu 4: điểm huấn luyện, centroid hai lớp và điểm thử.

(3) Với  $\tau = 1$ :  $w_i = \exp(-(x_i - 2,5)^2/2)$ :

$$w \approx (0,325; 0,882; 0,882; 0,325).$$

(4) **Bổ sung — hồi quy tuyến tính có trọng số:** Với thiết kế  $[1 \ x]^\top$  và trọng số  $w_i$  ở trên, hệ số WLS tại  $x = 2,5$  cho  $y \in \{3, 5, 7, 9\}$  cho  $\hat{y}(2,5) = 6$  (trùng  $h(2,5)$  vì bốn điểm nằm trên cùng đường thẳng  $y = 1 + 2x$ ).

## Câu 6. COVID symptoms và Hamming

Mã hóa Yes= 1, No= 0. Vector thử  $(1, 1, 1, 1, 0, 0, 0, 0)$ .

Bảng Hamming (đã sort): có hai mẫu trùng khớp hoàn toàn (khoảng cách 0, Positive); tiếp theo  $d = 2$ ,  $d = 3$ ,  $d = 4$ ,  $d = 5 \dots$

**k-NN đa số:** với  $k \in \{1, 3, 5, 7\}$  các láng giềng gần đều cho đa số **Positive**  $\Rightarrow$  dự đoán **Positive**.

**Weighted k-NN** ( $k = 3$ ,  $w_i = 1/d$ , **chuẩn hóa**): hai láng giềng  $d = 0$  (cùng Positive) nhận gần hết trọng số; láng giềng  $d = 2$  (Negative) có trọng số rất nhỏ. Tổng trọng số thiên **Positive**  $\Rightarrow$  **Positive**.

## Phân tích dữ liệu triệu chứng (tập huấn luyện)

Từ 6 ca **Positive** và 4 ca **Negative**:

- **Xuất hiện nhiều nhất trong Positive:** Sốt, Ho khan, Mệt mỏi đều đạt 6/6 (bằng nhau, tối đa).

- **Ít nhất trong Positive: Tiêu chảy** (1/6). Nếu xét toàn tập, **Tiêu chảy** cũng có tổng số lần 1 là nhỏ nhất.
- **Đặc trưng dễ gây nhiễu:** Các triệu chứng hiếm hoặc biến thiên mạnh giữa lớp (*ví dụ* tiêu chảy chỉ gặp ở một ca Positive, hoặc đau ngực chỉ vài ca) có thể làm các mẫu cục bộ “nhảy lớp” khi  $k$  nhỏ.
- **Phù hợp similarity-based learning:** Mỗi bệnh nhân là vector triệu chứng; bệnh cùng nhóm thường có mẫu gần nhau theo Hamming, nên  $k$ -NN/weighted  $k$ -NN diễn giải được theo “các ca tương tự” — gần gũi cách ra quyết định lâm sàng tham chiếu hồ sơ tương tự (mang tính minh họa học tập, không thay thế quy trình y tế).

## Câu hỏi tư duy về $k$ -NN

1. Với  $10^8$  bệnh nhân,  $k$ -NN phải tính khoảng tới (gần như) toàn bộ tập khi không có cấu trúc chỉ mục  $\Rightarrow$  **chậm, tốn bộ nhớ**; cần LSH, KD-tree, hoặc chuyển sang mô hình có huấn luyện tham số rút gọn.
2. **Lazy learning:** không huấn luyện mô hình tường minh trước; chỉ lưu dữ liệu, khi có truy vấn mới đo khoảng và bỏ phiếu.
3. **Nhị phân:** Euclidean trên  $\{0, 1\}$  coi hai bit khác nhau là “1 đơn vị trên trục” nhưng bình phương khác với *đếm lệch bit*; Hamming khớp ngữ nghĩa “khác bao nhiêu triệu chứng” và ổn định khi không muốn giả định hình học  $\mathbb{R}^d$ .
4. **Mất cân bằng lớp:** có ảnh hưởng — lớp đông dễ chiếm đa số láng giềng; nên cân trọng số theo tần suất lớp, chọn  $k$  cẩn thận, hoặc lấy mẫu lại/cân bằng dữ liệu.