

Bài 4.5 — Mô hình Naive Bayes

Lời giải

Họ tên: ... Mã SV: ...

Bài tập 4.5 — Naive Bayes

Giả định **Naive Bayes**: các thuộc tính trong từng câu **độc lập có điều kiện** theo lớp. Dùng **Laplace** với $\alpha = 1$: làm trơn tiên nghiệm và các xác suất điều kiện của thuộc tính *rời rạc*; với từ vựng ở Câu 4.5.4 làm trơn trên $V = 7$ loại từ. Với các biến liên tục (Câu 4.5.1 và 4.5.3), giả thiết phân bố Gaussian trong mỗi lớp với trung bình mẫu và **độ lệch chuẩn mẫu** (chia $n_c - 1$ khi $n_c > 1$).

Khi so sánh lớp có thể dùng log (tổng log-likelihood + log-prior); hằng số chung không làm thay đổi thứ tự.

Câu 4.5.1 — Phê duyệt tín dụng (biến số + Gia đình)

Có 8 khách hàng huấn luyện, $|\text{Yes}| = 4$, $|\text{No}| = 4$ (theo cột Kết quả).

(a) Tiên nghiệm và likelihood

Hai lớp, làm trơn tiên nghiệm:

$$P(\text{No}) = \frac{4+1}{8+2} = \frac{1}{2} = 0,5, \quad P(\text{Yes}) = \frac{4+1}{10} = \frac{1}{2} = 0,5.$$

Thuộc tính **Gia đình** (hai giá trị **Có**, **Không**): trong lớp c có $n_c = 4$ khách,

$$P(\text{giá trị} \mid c) = \frac{\text{số lần xuất hiện trong } c + 1}{n_c + 2}.$$

Đếm: lớp **No** có 2 lần **Có** và 2 lần **Không**, nên

$$P(\text{Có} \mid \text{No}) = \frac{3}{6} = \frac{1}{2}, \quad P(\text{Không} \mid \text{No}) = \frac{1}{2}.$$

Lớp **Yes** có 3 lần **Có** và 1 lần **Không**, nên

$$P(\text{Có} \mid \text{Yes}) = \frac{4}{6} = \frac{2}{3}, \quad P(\text{Không} \mid \text{Yes}) = \frac{1}{3}.$$

Các biến **Tuổi**, **Thu nhập**, **Số tiền vay** coi là liên tục. Ký hiệu lớp chữ thường **yes/no** cho chi tiết tính toán, nhưng ý nghĩa vẫn là Kết quả **Yes/No** của đề.

Lớp no (4 mẫu):

$$\mu_{\text{age}} = 25,75, \quad s_{\text{age}} = 4,5;$$

$$\mu_{\text{inc}} = 19,75, \quad s_{\text{inc}} \approx 3,594;$$

$$\mu_{\text{loan}} = 235, \quad s_{\text{loan}} \approx 36,968.$$

Lớp yes (4 mẫu):

$$\mu_{\text{age}} = 28,5, \quad s_{\text{age}} \approx 5,066;$$

$$\mu_{\text{inc}} = 19,25, \quad s_{\text{inc}} \approx 2,217;$$

$$\mu_{\text{loan}} = 145, \quad s_{\text{loan}} \approx 26,458.$$

Mật độ Gaussian (mỗi biến):

$$f(x \mid c) = \frac{1}{\sqrt{2\pi} s} \exp\left(-\frac{(x - \mu)^2}{2s^2}\right).$$

Phân lớp mẫu mới

Mẫu cần dự đoán: Tuổi = 23, Gia đình **Có**, Thu nhập = 32 (triệu đồng), Số tiền vay = 250 (triệu đồng).

So sánh $\log P(\text{No}) + \log P(\text{Có} \mid \text{No}) + \sum \log f(\cdot \mid \text{No})$ với tương tự cho **yes**. Tính đầy đủ từng hạng tử cho ra:

$$\log \tilde{P}(\text{No}) \approx -16,614, \quad \log \tilde{P}(\text{Yes}) \approx -34,546.$$

Giá trị log lớn hơn rõ rệt thuộc lớp **No**. Vậy dự đoán Kết quả là **No** (tức không phê duyệt theo nhân đề bài).

Câu 4.5.2 — Tennis (toàn rời rạc)

Có 14 mẫu: $|\text{No}| = 5$, $|\text{Yes}| = 9$.

(a) **Tiên nghiệm và likelihood**

$$P(\text{No}) = \frac{5+1}{14+2} = \frac{3}{8} = 0,375, \quad P(\text{Yes}) = \frac{9+1}{16} = \frac{5}{8} = 0,625.$$

Với thuộc tính rời rạc có V giá trị trong tập huấn luyện, trong lớp c có n_c mẫu:

$$P(v | c) = \frac{\text{đếm}(v \text{ trong } c) + 1}{n_c + V}.$$

Lớp No ($n_{\text{No}} = 5$):

Thuộc tính	$P(\cdot \text{No})$ sau Laplace
Outlook	Sunny $\frac{3+1}{5+3} = \frac{1}{2}$; Rainy $\frac{2+1}{8} = \frac{3}{8}$; Overcast $\frac{0+1}{8} = \frac{1}{8}$.
Temp	Hot $\frac{2+1}{5+3} = \frac{3}{8}$; Mild $\frac{2+1}{8} = \frac{3}{8}$; Cool $\frac{1+1}{8} = \frac{1}{4}$.
Humidity	High $\frac{4+1}{5+2} = \frac{5}{7}$; Normal $\frac{1+1}{7} = \frac{2}{7}$.
Windy	False $\frac{2+1}{5+2} = \frac{3}{7}$; True $\frac{3+1}{7} = \frac{4}{7}$.

Lớp Yes ($n_{\text{Yes}} = 9$):

Thuộc tính	$P(\cdot \text{Yes})$ sau Laplace
Outlook	Sunny $\frac{2+1}{9+3} = \frac{1}{4}$; Rainy $\frac{3+1}{12} = \frac{1}{3}$; Overcast $\frac{4+1}{12} = \frac{5}{12}$.
Temp	Hot $\frac{2+1}{12} = \frac{1}{4}$; Mild $\frac{4+1}{12} = \frac{5}{12}$; Cool $\frac{3+1}{12} = \frac{1}{3}$.
Humidity	High $\frac{3+1}{9+2} = \frac{4}{11}$; Normal $\frac{6+1}{11} = \frac{7}{11}$.
Windy	False $\frac{6+1}{9+2} = \frac{7}{11}$; True $\frac{3+1}{11} = \frac{4}{11}$.

(b) **Mẫu** (Sunny, Cool, High, Windy=True)

$$\tilde{P}(c) \propto P(c) P(\text{Sunny} | c) P(\text{Cool} | c) P(\text{High} | c) P(\text{True} | c).$$

Dùng log: $\log \tilde{P}(\text{No}) \approx -3,956$, $\log \tilde{P}(\text{Yes}) \approx -4,978$. Vậy **dự đoán: No**.

(c) **Outlook không có**: (?, Cool, High, Windy=True)

Không quan sát Outlook nên không nhân thêm bất kỳ $P(\text{Outlook} | c)$ nào; chỉ còn $\tilde{P}(c) \propto P(c) P(\text{Cool} | c) P(\text{High} | c) P(\text{True} | c)$.

$\log \tilde{P}(\text{No}) \approx -3,263$, $\log \tilde{P}(\text{Yes}) \approx -3,592$. Vẫn **dự đoán: No**.

Câu 4.5.3 — Tennis với nhiệt độ và độ ẩm số

Outlook và Windy rời rạc (Laplace như Câu 4.5.2).

Với Temperature và Humidity: dùng μ , s mẫu trong từng lớp; mật độ như Câu 4.5.1.


Từ 14 mẫu (nhân yes/no):

Tiên nghiệm: $P(\text{no}) = \frac{3}{8}$, $P(\text{yes}) = \frac{5}{8}$.

Gaussian: lớp **no** (5 mẫu): $\mu_T = 74,6$, $s_T \approx 7,893$; $\mu_H = 84$, $s_H \approx 9,618$.

Lớp **yes** (9 mẫu): $\mu_T = 73$, $s_T \approx 6,164$; $\mu_H \approx 78,222$, $s_H \approx 9,884$.

Likelihood rời rạc cho **sunny/rain/overcast** và **true/false** giống cách đếm Laplace trên bảng đề (ví dụ $P(\text{sunny} \mid \text{no}) = \frac{1}{2}$, $P(\text{sunny} \mid \text{yes}) = \frac{1}{4}$, v.v.).



Hình 1: Câu 4.5.3: các điểm huấn luyện theo hai lớp; dấu sao là mẫu cần phân lớp ở phần (b).

(b) Mẫu (sunny, 66, 90, windy=true)

Cộng log tiên nghiệm hai mật độ Gaussian (tại $T = 66$, $H = 90$) và hai xác suất rời rạc. Kết quả:

$$\log \tilde{P}(\text{no}) \approx -9,189, \quad \log \tilde{P}(\text{yes}) \approx -10,170.$$

Vậy dự đoán: **no**.

Câu 4.5.4 — Email: Multinomial Naive Bayes

Huấn luyện: hai thư **N**, một thư **S**; tổng 3 văn bản.

(a) Tiên nghiệm và likelihood từ

$$P(N) = \frac{2+1}{3+2} = \frac{3}{5}, \quad P(S) = \frac{1+1}{5} = \frac{2}{5}.$$

Gộp mọi lần xuất hiện từ trong cùng lớp:

Lớp N: tổng token = 10 (E1 và E2).

$$P(w_i | N) = \frac{\text{đếm}(w_i) + 1}{10 + 7} = \frac{\text{đếm} + 1}{17}.$$

Cụ thể: $P(w_1 | N) = \frac{2}{17}$, $P(w_2 | N) = \frac{5}{17}$, $P(w_3 | N) = \frac{2}{17}$, $P(w_4 | N) = \frac{1}{17}$, $P(w_5 | N) = \frac{3}{17}$, $P(w_6 | N) = \frac{2}{17}$, $P(w_7 | N) = \frac{2}{17}$.

Lớp S: tổng token = 5 (E3).

$$P(w_i | S) = \frac{\text{đếm} + 1}{5 + 7} = \frac{\text{đếm} + 1}{12}.$$

Ví dụ: $P(w_1 | S) = \frac{2}{12}$, $P(w_7 | S) = \frac{1}{12}$ (và các $P(w_i | S)$ còn lại theo bảng đếm).

(b) E4 với bộ đếm (1, 0, 0, 0, 0, 0, 1)

Chỉ w_1 và w_7 có tần suất dương:

$$\tilde{P}(N) \propto \frac{3}{5} \cdot \frac{2}{17} \cdot \frac{2}{17}, \quad \tilde{P}(S) \propto \frac{2}{5} \cdot \frac{2}{12} \cdot \frac{1}{12}.$$

So sánh log: $\log \tilde{P}(N) \approx -4,791$, $\log \tilde{P}(S) \approx -5,193$. Do đó **dự đoán: N** (không spam).