

Tổng hợp công thức & quy trình làm bài (ôn tập học máy — theo lời giải ôn trong repo)

Mục lục

Phần A — Công thức cần nhớ

1. Khái niệm cơ bản (Ch. 1 — lược trích có công thức nhẹ)

- Batch / mini-batch / SGD: cập nhật tham số theo gradient ước lượng trên toàn tập / lô / một mẫu.
- Regularization: thường cộng thêm $\lambda \|\theta\|_1^2$ hoặc 2 vào loss (ridge/lasso trong lý thuyết chung).

2. Thống kê & tiền xử lý (Ch. 2)

Với danh sách giá trị đã sắp tăng có n phần tử.

- Trung bình mẫu: $\bar{x} = \frac{1}{n} \sum_i x_i$.
- Trung vị: n lẻ $\Rightarrow$ phần tử vị trí $\frac{n+1}{2}$ (đếm 1-based); n chẵn: thường lấy trung bình hai phần tử giữa.
- Mốt: giá trị có tần số cao nhất (có thể nhiều mốt).
- Tứ phân vị: Q_1, Q_3 theo một quy ước vị trí (để có thể cho phép hai cách: vị trí nguyên $(n+1)/4$ hoặc nội suy tuyến tính giữa hai quan sát kề).
- Khoảng tứ phân vị: $IQR = Q_3 - Q_1$.
- Tukey (ngoại lai nhẹ): $x > Q_3 + 1,5 IQR$ (hoặc tương tự phía dưới Q_1).

Rời rạc hóa chia đều tần số k lớp: chia n quan sát đã sắp thành nhóm có số phần tử gần bằng nhau ($\lfloor n/k \rfloor, \dots$ còn dư chia cho nhóm nhỏ nhất có thể), mỗi nhóm $\rightarrow$ một nhãn rời rạc.

Thang đo (interval): W cùng thông tin thang khoảng với V khi $\exists a > 0, b : W = aV + b$ trên các mẫu được xét.

3. Đánh giá mô hình (Ch. 3)

Confusion matrix: hàng = nhãn thực, cột = nhãn dự đoán (giữ cố định quy ước đề).

Đa lớp. Với lớp k : TP_k ô chéo; hàng là tần k trong thực tế; cột là số được dự đoán là k .

$$\begin{aligned} accuracy &= \frac{\sum_k TP_k}{n}, \\ \text{Precision}_k &= \frac{TP_k}{\text{tổng cột đoán là } k}, & \text{Recall}_k &= \frac{TP_k}{\text{tổng hàng thực là } k}, \\ F1_k &= \frac{2 \text{Precision}_k \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}. \end{aligned}$$

Nhị phân (lớp dương P coi trong đề): Đếm TP, FN, FP, TN, n tổng mẫu.

$$\begin{aligned} accuracy &= \frac{TP + TN}{n}, & 1 - accuracy &= \frac{FP + FN}{n}, \\ precision &= \frac{TP}{TP + FP}, & recall = sensitivity = TPR &= \frac{TP}{TP + FN}, \\ specificity = TNR &= \frac{TN}{TN + FP}, & FPR &= \frac{FP}{TN + FP}, \\ F1 &= \frac{2 precision recall}{precision + recall}, & prevalence &= \frac{TP + FN}{n}. \end{aligned}$$

4. Cây quyết định (§4.1)

Đặt $p_c = n_c/N$ là tần nhân lớp c trong nút có N mẫu. Trong các bài ôn log là $\log_2$ trừ khi đề chỉ định khác.

Entropy:

$$H(S) = - \sum_c p_c \log p_c, \quad 0 \leq H \leq \log_2(\text{số nhân khác không trong nút}) \leq \log_2 C.$$

Information Gain / ID3 hay C4.5 (chia đa nhánh theo từng giá trị thuộc tính A):

$$H_{\text{sau tách}(A)} = \sum_v \frac{|S_v|}{|S|} H(S_v), \quad \text{Gain}(S, A) = H(S) - H_{\text{sau tách}(A)}.$$

Impurity Gini (một nút):

$$i(S) = 1 - \sum_c p_c^2 \in [0, 1 - \frac{1}{C}].$$

Gini có trọng số sau khi cắt theo A :

$$G_{\text{sau tách}(A)} = \sum_v \frac{|S_v|}{|S|} i(S_v).$$

Chọn thuộc tính $\arg \max_A (i(S) - G_{\text{sau tách}(A)}) = \arg \min_A G_{\text{sau tách}(A)}$.

Lỗi phân loại có trọng số. Lỗi tại nút: $mis(S) = 1 - \max_c (n_c/N)$. Sau khi tách A :

$$\text{Error}_{\text{sau tách}(A)} = \sum_v \frac{|S_v|}{|S|} mis(S_v).$$

Chọn thuộc tính làm $\text{Error}_{\text{sau tách}}$ *nhỏ nhất* (tức giảm lỗi có trọng số nhiều nhất so với lỗi tại nút gốc hiện tại).

5. Hồi quy tuyến tính & batch GD (§4.2, §4.6.5)

Mô hình $\hat{y}_i = w x_i + b$ (một chiều) hay $\hat{\mathbf{y}} = \mathbf{X}\boldsymbol{\theta}$ (đa chiều, cùng ý).

Hàm chi phí (lời giải dùng hệ số $1/(2m)$):

$$J(w, b) = \frac{1}{2m} \sum_{i=1}^m (y_i - \hat{y}_i)^2.$$

Gradient (batch):

$$\frac{\partial J}{\partial w} = -\frac{1}{m} \sum_i (y_i - \hat{y}_i) x_i, \quad \frac{\partial J}{\partial b} = -\frac{1}{m} \sum_i (y_i - \hat{y}_i).$$

Cập nhật §4.2 (learning rate η): $w \leftarrow w - \eta \frac{\partial J}{\partial w}$, $b \leftarrow b - \eta \frac{\partial J}{\partial b}$.

6. Phân lớp tuyến tính, Perceptron, hinge trên tập sai

Nhân $t \in \{-1, +1\}$. Đầu vào $\mathbf{x}$ (ấn thêm $\tilde{x} = [1, x^\top]^\top$ nếu gộp bias).

Đường quyết định & hàm bước: $s = w^\top x + b$ (hay $\mathbf{w}^\top \tilde{\mathbf{x}}$),

$$\text{sign}(z) = \begin{cases} +1, & z \geq 0, \\ -1, & z < 0. \end{cases}$$

Chi phí trên các mẫu sai $\mathcal{Y}$: $J = \sum_{k \in \mathcal{Y}} (-t_k)(w^\top x_k + b)$.

$$\frac{\partial J}{\partial w} = \sum_{k \in \mathcal{Y}} (-t_k) x_k, \quad \frac{\partial J}{\partial b} = \sum_{k \in \mathcal{Y}} (-t_k).$$

Gradient Descent một bước (§4.6.3, với ρ): $w \leftarrow w - \rho \frac{\partial J}{\partial w}$, $b \leftarrow b - \rho \frac{\partial J}{\partial b}$ (quan trọng: dấu - $\rho \cdot$ gradient).

Thuật toán Rosenblatt (Perceptron) — §4.3: một bước trên một mẫu sai được chọn có hệ thức tương đương $w \leftarrow w + \rho t x$, $b \leftarrow b + \rho t$ (với $\rho > 0$ — so với hinge batch trên chỉ là cách học hai kiểu *đã dùng riêng* trong các câu lời giải).

7. k-Nearest Neighbors (§4.4)

Mã hoá phân loại nhị giá trị $\rightarrow \{0, 1\}$; vector $\mathbf{x} = (x_1, \dots, x_d)$ (tuỳ bài ôn).

Khoảng cách Euclidean:

$$d(\mathbf{x}, \mathbf{q}) = \sqrt{\sum_{\ell} (x_{\ell} - q_{\ell})^2}, \quad d^2(\mathbf{x}, \mathbf{q}) = \sum_{\ell} (x_{\ell} - q_{\ell})^2.$$

Chọn K láng giềng có d nhỏ nhất $\Rightarrow$ bỏ phiếu đa số nhãn.

8. Naive Bayes & Laplace (§4.5)

Độc lập có điều kiện: $\tilde{P}(c \mid \mathbf{v}) \propto P(c) \prod_j P(v_j \mid c)$ (hay so sánh bằng log để tránh underflow).

Tiên nghiệm. Với $\alpha = 1$ (Laplace) và $|\mathcal{C}|$ số lớp: $P(c) = \frac{n_c + \alpha}{n + \alpha|\mathcal{C}|}$.

Rời rạc có V giá trị khả dĩ của thuộc tính trong lớp c (hay $|\mathcal{V}|$ cấu hình của thuộc tính):

$$P(v \mid c) = \frac{\#\{v \text{ trong } c\} + 1}{n_c + V}.$$

Nếu chỉ có 2 giá trị (đếm $|\mathcal{V}| = 2$ ở mẫu): mẫu số có thể có dạng $n_c + |\mathcal{V}|$ - xem lời giải ví dụ Gia đình (Có/Không) với chia cho $n_c + 2$.

Gaussian liên tục trong mỗi lớp c (một chiều):

$$f(x | c) = \frac{1}{\sqrt{2\pi} s_c} \exp\left(-\frac{(x - \mu_c)^2}{2s_c^2}\right).$$

Trong các bài ôn: μ_c là trung bình mẫu trên các điểm thuộc c ; s_c là độ lệch chuẩn mẫu (chia $n_c - 1$ khi $n_c > 1$). Ghi log tiên nghiệm và $\sum \log f(\cdot) + \sum_{\text{rời rạc}} \log P(\cdot | c)$, chọn $\arg \max$ (hoặc tương đương chọn $\arg \max$ tích).

Multinomial trên bag-of-words:

$$P(w_i | c) = \frac{N_{i,c} + 1}{N_c^{\text{tok}} + V}, \quad N_{i,c} = \text{lần xuất hiện của } w_i \text{ trong các văn bản lớp } c.$$

V = kích thước từ điển (ví dụ 7 trong bài ôn đó).

9. Neural network rất nhỏ (§4.6)

Tính độ kích thích s bằng trọng số của các đầu vào cộng bias như trong mạch; hàm bước τ thường là $\tau(s) = +1$ nếu $s \geq 0$ ngược lại -1 (đúng theo đề bài ôn).

OR: có thể dùng $s = -\frac{1}{2} + x_1 + x_2$ (trong ôn của repo).

AND có thể: $s = -\frac{3}{2} + x_1 + x_2$.

MLP ví dụ: tính từng neuron lớp ℓ rồi lớp ra theo các trọng số đề cho — thứ tự đúng theo luồng số của mạch.

10. Phân cụm (Ch. 5)

K-means: hai bước lặp

(1) Gán: mẫu $\rightarrow$ tâm gần nhất theo Euclidean.

(2) Cập nhật: $c_j \leftarrow \text{mean}\{x : x \text{ được gán nút } j\}$.

Tiêu chí dừng: không đổi gán $\vee$ không đổi tâm (trên bài tay). Tie-break $\arg \min$ khoảng cách bằng nhau: quy định trước (ví dụ chọn chỉ số cụm nhỏ nhất).

Agglomerative single linkage (độ cao dendrogram là khoảng cách hai cụm hợp nhất):

$$d_{\text{single}}(U, V) = \min_{u \in U, v \in V} d(u, v).$$

Ghép hai cụm có khoảng cách min trước, lặp cho đến một cụm.

Phần B — Quy trình làm bài theo dạng (bám các lời giải .tex trong repo)

B.1. Chương 2 — Tiền xử lý

1. Sắp các giá trị một chiều tăng dần.
2. Tính trung bình, trung vị, mốt; ghi rõ có nhiều mốt nếu các giá trị có cùng tần suất cực đại.

3. Tính Q_1, Q_3, IQR ; ghi rõ quy ước vị phân vị (vị trí nguyên hoặc nội suy giữa hai quan sát kề) vì các bài ôn có thể dùng hai cách.
4. Boxplot & ngoại lai Tukey: năm số tóm tắt, IQR , so sánh với $Q_{1,3} + 1,5 \text{IQR}$.
5. *Rời rạc hoá chia đều tần số* (k nhóm): lấy dãy đã sắp, chia thành các khúc có số điểm gần bằng nhau như các bài ôn (ví dụ $q + \dots$ với chia nguyên của n/k).¹
6. Thang đo khoảng: chứng minh tồn tại $a > 0, b$ sao cho $W = aV + b$ trên các cặp được cho hoặc bác bỏ nếu dãy không cùng phép affine tăng.

B.2. Chương 3 — Đánh giá mô hình

1. Nếu đề cho dãy luật có thứ tự **if-elseif**: áp đúng thứ tự trên mỗi mẫu rồi đối chiếu nhãn thực.
2. Lập confusion matrix (hàng: thực, cột: đoán) bằng cách đếm từng cặp $(y_i, \hat{y}_i)$.
3. Nhị phân với một lớp dương quy định: đếm TP, FN, FP, TN rồi thế vào các công thức ở Phần A.
4. Đa lớp: accuracy tổng thể $\sum_k \text{TP}_k / n$ và chỉ số theo lớp k như trong Phần A.

B.3. § 4.1 — Cây quyết định

1. Tại nút S : ghi các mẫu và các đặc trưng được phép chia.
2. Với từng đặc trưng có giá trị rời rạc trong S , tách thành vài nhánh $\{S_v\}$ theo đủ các giá trị xuất hiện.
3. Tính chỉ báo của đề: Entropy của S , Gain cho mỗi đặc trưng $\text{Gain}(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v)$; hoặc Gini có trọng số; hoặc lỗi phân có trọng số.
4. Chọn thuộc tính theo chỉ báo đề cho: Gain lớn nhất hoặc Gini có trọng số nhỏ nhất hoặc lỗi có trọng số nhỏ nhất.
5. Lập lại trên từng nhánh chứa mẫu chưa thuần nhãn $\wedge$ vẫn còn đặc trưng dùng được; đặt lá khi chỉ một nhãn còn lại (hoặc hết chia theo ôn tay).

Dự báo mẫu mới: đưa các giá trị đặc trưng vào các luật if-then từng bước từ gốc của cây xuống lá. Trường hợp đề chỉ cho dãy luật if-elseif có thứ tự cố định thì luôn so khớp từ trên xuống và dừng ở luật đầu thoả như phần Đánh giá.

B.4. § 4.2 — Hồi quy tuyến tính + batch GD

1. Xác định m và $\hat{y}_i = wx_i + b$; $J = \frac{1}{2m} \sum_i (y_i - \hat{y}_i)^2$.
2. Tại $(w^{(t)}, b^{(t)})$: tính các dự báo & phần dư $y_i - \hat{y}_i$.
3. $\partial J / \partial w, \partial J / \partial b$ theo Phần A.
4. Cập nhật $w \leftarrow w - \eta \partial J / \partial w, b \leftarrow b - \eta \partial J / \partial b$ (η của đề; đổi $\eta \leftrightarrow \rho$ theo notation đề ôn tay).

¹Các mục công thức chính xem Phần A.

B.5. § 4.3 — Phân lớp tuyến tính (sign) + hinge trên tập sai + Perceptron

1. Tính $s_k = w^\top x_k + b$ rồi $\hat{y}_k = \text{sign}(s_k)$; so với t_k để tìm các mẫu sai.
2. Chi phí chỉ trên tập sai $\mathcal{Y}$: lấy $\partial J/\partial w$, $\partial J/\partial b$ theo Phần A.
3. Với gradient trên tập sai (§ 4.6.3): $w \leftarrow w - \rho \partial J/\partial w$, $b \leftarrow b - \rho \partial J/\partial b$.
4. Với Perceptron một mẫu (§ 4.3): chọn mẫu sai theo thứ tự đề; $w \leftarrow w + \rho t x$, $b \leftarrow b + \rho t$.

B.6. § 4.4 — k -NN

1. Mã hoá thuộc tính rồi rạc theo quy ước đề (vd. Có/Không $\rightarrow 0/1$); xây $\mathbf{x}, \mathbf{q}$ cùng số chiều.
2. Tính $d^2(\mathbf{x}, \mathbf{q})$ rồi sắp tăng d ; lấy K láng giềng nhỏ nhất.
3. Bỏ phiếu nhãn đa số; có thể nhắc lại với K' khác nếu đề hoặc nhận xét yêu cầu.

B.7. § 4.5 — Naive Bayes + Laplace

1. Đếm n, n_c và số nhãn; Laplace $\alpha=1$: $P(c) = \frac{n_c + \alpha}{n + \alpha|\mathcal{C}|}$; với thuộc tính rời rạc có V giá trị khả dụng, dùng $\frac{n_{v,c} + 1}{n_c + V}$ với $n_{v,c}$ là số lần thấy v trong lớp c (theo các ôn 4.5).
2. Gaussian: tính μ_c, s_c trong từng lớp; lấy log mật độ tại mỗi biến liên tục.
3. Nhận các thể hiện mới: cộng $\log P(c) + \sum \log P(v_j | c)$ (bỏ qua thuộc tính thiếu nếu đề nói không quan sát).
4. Chọn lớp có log-score lớn hơn.
5. Multinomial (email): tiên nghiệm lớp; mỗi token $P(w_i | c) = (\text{đếm} + 1)/(N_c + V)$; nhân (log) theo tần suất bộ đếm của văn bản cần phân lớp.

B.8. § 4.6 — Perceptron / MLP tí hon

1. Viết đường biên dạng $\mathbf{w}^\top \mathbf{x} + b = 0$ từ đề đồ họa/phương trình.
2. Thay điểm vào $\tau(s)$: $+1$ nếu $s \geq 0$ ngược lại -1 (hay quy định đề).
3. MLP không ản: tính tuần tự theo chỉ báo các nút từ trái-phải theo các trọng số đề.
4. OR/AND trong $\{0, 1\}^2$: chỉ ra $\mathbf{w}, b$ sao $\tau(\mathbf{w}^\top \mathbf{x} + b)$ khớp bảng (so với ví dụ $-\frac{1}{2} + x_1 + x_2$ cho OR trong lời giải đã ôn).

B.9. Chương 5 — K -means

1. Khởi tạo các tâm $C_j^{(0)}$ theo đề ($j=1, \dots, K$).
2. Bước *gán*: mỗi điểm vào cụm của tâm gần Euclidean nhất (nếu hai khoảng cách bằng nhau, ghi rõ quy tắc phá hoà, vd. chọn cụm có chỉ số nhỏ hơn).
3. Bước *cập nhật*: tâm mới = trung bình toạ độ của điểm trong cụm.
4. Lặp đến khi gán không đổi hoặc các tâm không đổi (trên bài tay); ghi kết quả cụm cuối & tâm.

B.10. Chương 5 — Phân cụm phân cấp (single linkage)

1. Tính ma trận khoảng cách đôi một giữa các điểm.
2. Tìm cặp có khoảng cách nhỏ nhất để ghép thành cụm ở bước hiện tại; độ cao nối trên dendrogram thường bằng khoảng cách của bước đó trong các bài ôn.
3. Sau khi ghép hai cụm U và V , với mọi cụm W còn lại: cập nhật

$$d_{\text{single}}(U \cup V, W) = \min\{d_{\text{single}}(U, W), d_{\text{single}}(V, W)\}.$$

4. Lặp cho đến khi còn một cụm.