

Ôn tập: 2. Tiền xử lý dữ liệu — Lời giải

Họ tên: ... Mã SV: ...

2. Tiền xử lý dữ liệu

Câu 2.1

Cho thuộc tính “tuổi” với dãy giá trị đã sắp tăng dần ($n = 27$):

13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25, 25, 30, 33, 33,
35, 35, 35, 35, 36, 40, 45, 46, 52, 70.

Yêu cầu. (a) Tính trung bình, trung vị, mốt. (b) Tìm tứ phân vị Q_1 , Q_3 (có thể xấp xỉ nếu cần). (c) Vẽ boxplot và nhận xét phân bố. (d) Rời rạc hóa bằng phương pháp *chia đều tần số* với $k = 4$.

(a) Trung bình, trung vị, mốt.

Tổng các giá trị bằng 809, nên trung bình mẫu

$$\bar{x} = \frac{809}{27} \approx 29,96.$$

Vì n lẻ, trung vị là phần tử vị trí thứ $\frac{n+1}{2} = 14$ trên dãy đã sắp, đó là 25.

Đếm tần số: 25 và 35 mỗi giá trị xuất hiện 4 lần; các giá trị khác không quá 2 lần. Vậy có hai mốt: 25 và 35 (đa mốt).

(b) Tứ phân vị Q_1 , Q_3 .


Có hai quy ước phổ biến; đề cho phép xấp xỉ.

Cách vị trí nguyên (1-based): Q_1 ứng vị trí $\frac{1}{4}(n+1) = 7 \Rightarrow$ giá trị thứ 7 là 20. Q_3 ứng vị trí $\frac{3}{4}(n+1) = 21 \Rightarrow$ giá trị thứ 21 là 35. Khi đó $\text{IQR} = 35 - 20 = 15$.

Cách nội suy tuyến tính giữa hai quan sát kề: vị trí Q_1 là 7,5 nên $Q_1 = \frac{20+21}{2} = 20,5$; vị trí Q_3 là 20,5 nên $Q_3 = \frac{35+35}{2} = 35$ và $\text{IQR} = 14,5$.

(c) Boxplot và nhận xét.

Năm số tóm tắt: $\min = 13$, trung vị = 25, $\max = 70$; Q_1, Q_3 có thể lấy theo một trong hai cách ở (b). Ở đây minh họa với phép nội suy tuyến tính: $Q_1 = 20,5$, $Q_3 = 35$, $\text{IQR} = 14,5$. Ngưỡng trên Tukey là $Q_3 + 1,5 \cdot \text{IQR} = 56,75$; vì $70 > 56,75$ nên 70 thường được xem là ngoại lai phía trên. Trung bình ($\approx 29,96$) lớn hơn trung vị (25) — phân bố *lệch phải* (đuôi dài về giá trị lớn).



Hình: boxplot thuộc tính tuổi; râu và đánh dấu ngoại lai theo quy ước khoảng tứ phân vị và hệ số 1,5 thông dụng.

(d) Rời rạc hóa theo chia đều tần số, $k = 4$.

Với $n = 27$, chia làm 4 nhóm có số phần tử gần bằng nhau được $7+7+7+6$ phần tử nếu lấy 7, 7, 7 phần tử nhỏ nhất rồi 6 phần tử còn lại theo đúng thứ tự đã sắp:

- Nhóm 1 (7 giá trị): từ 13 đến 20 — $\{13, 15, 16, 16, 19, 20, 20\}$.
- Nhóm 2 (7 giá trị): từ 21 đến 25 — $\{21, 22, 22, 25, 25, 25, 25\}$.
- Nhóm 3 (7 giá trị): từ 30 đến 35 — $\{30, 33, 33, 35, 35, 35, 35\}$.
- Nhóm 4 (6 giá trị): từ 36 đến 70 — $\{36, 40, 45, 46, 52, 70\}$.

Cách gán nhãn lớp (ví dụ $B_1, \dots, B_4$) có thể theo các khoảng trên cực độ tuổi trong từng nhóm; miễn là mọi điểm trong cùng một nhóm được gán *một* lớp rời rạc và tần số các lớp gần bằng nhau như trên.

Chú ý so với chia độ rộng đều: nếu chia $[\min, \max]$ thành bốn khoảng cùng độ rộng thì các lớp sẽ không còn tần số đều (thường dùng khi đề yêu cầu *chia đều độ rộng*). Ở câu này đề chọn chia đều *tần số*.

Câu 2.2

Cho bảng giá trị sau trên các cột A, B, C, D, E :

Biến	A	B	C	D	E
$V(\cdot)$	1	2	3	4	5
$W_1(\cdot)$	100	200	300	400	500
$W_2(\cdot)$	10	11	12	13	14
$W_3(\cdot)$	8	13	45	6	7
$W_4(\cdot)$	1	4	9	16	25
$W_5(\cdot)$	-10	-8	-6	-4	-2
$W_6(\cdot)$	3	6	9	12	15

Yêu cầu. (1) Xác định thang đo của các giá trị V : (1) định danh, (2) thứ tự, (3) khoảng, (4) tỷ lệ. (2) Những biến $W_1, \dots, W_6$ nào có cùng “thông tin thang đo” với $V(\cdot)$ trong nghĩa thang *khoảng*.

(1) Thang đo của V .

Các mức $1, \dots, 5$ có thứ tự rõ và khoảng cách giữa hai mức liên kế đều là 1, nên *hiệu* giữa hai giá trị có ý nghĩa (thang khoảng). Ngược lại không có căn cứ vật lý để coi một mức nào đó là “không” tuyệt đối của đại lượng theo nghĩa tỷ lệ (và tỷ số hai mức chưa hẳn diễn đạt “gấp bao nhiêu lần” trong thực tế). Do đó chọn loại (3) *thang khoảng* (interval).

(2) Cùng thang khoảng với V .

Hai biểu diễn số cùng thang khoảng nếu tồn tại phép đổi thang affine tăng: $W = aV + b$ với $a > 0$, đúng trên đủ năm cột $(A, \dots, E)$.

- $W_1 = 100V$: lấy $a = 100$, $b = 0$.
- $W_2 = V + 9$: $a = 1$, $b = 9$.
- W_3 : dãy giá trị 8, 13, 45, 6, 7 không cùng thứ tự tăng với V ; không có a , b chung để $W_3 = aV + b$ khớp năm cột — *không cùng*.
- $W_4 = V^2$: khoảng tăng $W(4) - W(3) = 16 - 9 = 7$ nhưng $W(3) - W(2) = 9 - 4 = 5$ — không đồng dạng một đường thẳng theo V — *không cùng*.
- $W_5 = 2V - 12$: $a = 2$, $b = -12$.
- $W_6 = 3V$: $a = 3$, $b = 0$.

Kết luận: các biểu diễn cùng thang khoảng với V : W_1, W_2, W_5, W_6 ; không cùng: W_3, W_4 .